目录

量子物理计算方法选讲 · 第三讲逐页中文讲义 **2**
这份文档是什么 . . . 2
怎么用这份讲义 . . . 3
全局约定（先读一遍） . . . 3
逐页索引 . . . 4

第一部分：迭代对角化总览（第 1–3 页） **6**
第 1 页 · 封面 . . . 6
第 2 页 · 精确对角化（ED）：本讲路线图 . . . 7
第 3 页 · 迭代对角化 . . . 9

第二部分：从变分原理到 Lanczos 递推（第 4–11 页） **11**
第 4 页 · 变分原理（一）：能量泛函与梯度 . . . 11
第 5 页 · 变分原理（二）：二维子空间与 2×2 矩阵 . . . 13
第 6 页 · 幂法 . . . 16
第 7 页 · Krylov 空间 . . . 18
第 8 页 · Lanczos 方法（一）：把 H 写成三对角矩阵 . . . 20
第 9 页 · Lanczos 方法（二）：三项递推 . . . 22
第 10 页 · 正交基（一）：三项递推为什么保持正交 . . . 25
第 11 页 · 正交基（二）：矩阵元 . . . 27

第三部分：收敛性与正交性（第 12–16 页） **30**
第 12 页 · Lanczos 计算的收敛性：24 格点海森堡链 . . . 30
第 13 页 · 正交性丢失与"鬼"本征值 . . . 33
第 14 页 · 重正交化 Lanczos 矢量 . . . 36
第 15 页 · 两种重正交化方案 . . . 39
第 16 页 · 重正交化前后对比：16 格点海森堡链 . . . 42

第四部分：格林函数（第 17–19 页） **44**
第 17 页 · 经典格林函数 . . . 45
第 18 页 · 量子格林函数与传播子 . . . 47
第 19 页 · 五种格林函数 . . . 50

第五部分：谱函数、连分数与物理（第 20–28 页） **53**
第 20 页 · 动力学性质：含时关联函数 . . . 53
第 21 页 · 局域态密度（LDOS） . . . 56
第 22 页 · 谱函数 . . . 59
第 23 页 · 用 Lanczos 计算谱函数 . . . 62
第 24 页 · 连分数：分块矩阵求逆 . . . 65
第 25 页 · 态密度：一维 Hubbard 链与 Mott 绝缘体 . . . 70
第 26 页 · 态密度：Krylov 空间维度从 5 增到 100 . . . 73
第 27 页 · 自旋-电荷分离 . . . 76
第 28 页 · 谱函数 $A(k,\omega)$ 与 TTF-TCNQ 实验 . . . 79

第六部分：研究前沿（第 29–30 页） **82**
第 29 页 · 研究前沿（一）：Chebyshev 赝 site 张量网络方法 83
第 30 页 · 研究前沿（二）：掺杂 Mott 绝缘体中的条纹电荷调制 86

第七部分：作业（第 31–32 页） **90**
第 31 页 · 作业规则 90
第 32 页 · 本次作业评分标准 92

附录 **94**
附录 A · 中英术语对照 94
附录 B · 常见错误清单（写 Lanczos + 谱函数代码前先读一遍） 96
附录 C · 从本讲出发的下一步 99
结语 100

量子物理计算方法选讲 · 第三讲逐页中文讲义

（配套第三讲幻灯片，共 32 页，逐页对照）

这份文档是什么

这是一份**逐页对照**的中文讲义：第三讲幻灯片的每一页，都按原来的顺序在下面出现一次，先给出这一页的**原图**，再给出这一页的**中文对译**、**背景补充**和**要点展开**。目标是：你拿着这一份文档（配合幻灯片本身），就能把第三讲的全部内容完整读懂、跟上。

第二讲解决了「**怎么把一个量子多体问题变成一个可以交给计算机的稀疏矩阵**」——基矢、比特运算、哈密顿量的三元组、对称性分块、基矢查找。但它留下了一个关键问题：矩阵造好了，**怎么把它对角化**？特别是当维度是 $4^{12} \approx 1.7 \times 10^7$、$4^{14} \approx 2.7 \times 10^8$ 甚至更大，稠密对角化完全不可能的时候。

第三讲就是回答这个问题的。主线是 **Lanczos 方法**，它属于第二讲第 3 页提到的「迭代对角化」家族；本讲的落点是**谱函数**——也就是光电子谱（ARPES）、中子散射这类实验直接测量的量。这一讲是第 1 章「精确对角化」的后半场 **ED II**。

一句话概括本讲的逻辑链：

$$\underbrace{\text{变分原理}}_{\text{第 4–5 页}} \Rightarrow \underbrace{\text{梯度方向给出}\{|\Psi\rangle, H|\Psi\rangle\}}_{\text{二维极小化}} \Rightarrow \underbrace{\text{幂法与 Krylov 空间}}_{\text{第 6–7 页}} \Rightarrow \underbrace{\text{Lanczos 三项递推}}_{\text{第 8–11 页}} \Rightarrow \underbrace{\text{三对角矩阵}T}_{\text{收敛性与正交性 12–16 页}}$$

而谱函数是第二条链：

$$\underbrace{\text{格林函数}}_{\text{第 17–19 页}} \Rightarrow \underbrace{\text{含时关联函数}C(t)}_{\text{第 20 页}} \Rightarrow \underbrace{\text{谱函数}I(\omega)}_{\text{第 21–22 页}} \Rightarrow \underbrace{\text{Lanczos + 连分数}}_{\text{第 23–26 页}} \Rightarrow \underbrace{\text{自旋-电荷分离与实验}}_{\text{第 27–28 页}}$$

页码约定：本文中「第 N 页」一律指**第三讲**幻灯片第 N 页。

与第二讲的关系：本讲**默认你已经会造矩阵**。第二讲的比特表示、基矢查找、$U(1)$ 分块、费米子符号，在本讲里会被直接调用（尤其是第 21–28 页的 Hubbard 计算）。如果你对「格点 i = 第 i 位」「↑ 放在低 N 位」这些约定已经模糊了，**请先回去翻第二讲的全局约定表**——本讲不会重新交代这些，但第 25、26 页的每一张 Hubbard 谱图都建立在这套约定之上。

怎么用这份讲义

每一页都按下面几块组织，你可以按需跳读：

- **这一页写了什么** ——把幻灯片上的英文条目（含公式）翻成中文，尽量逐条对应。
- **图里画了什么** ——幻灯片上的示意图、曲线、表格、截图里都画了些什么。这一块**只在有图的页面上单独给出**；其余页面的图意就写在「这一页写了什么」里。
- **要点展开** ——这一页真正想讲的物理与数学；公式的来历、数字的量级、为什么重要。
- **提示 / 易错** ——实践中的经验，以及这一页最容易误解、或幻灯片排版容易看错的地方。

读法建议：**第 4–11 页是数学推导**，建议拿纸笔跟着推一遍三项递推；**第 12–16 页是”坑”**，讲的是 Lanczos 在有限精度下会坏掉、以及怎么补救，这几页决定了你能不能得到正确的谱；**第 17–26 页是方法主体**，把格林函数、谱函数、连分数串成一条线；**第 25–28 页是物理与实验**，告诉你前面那套机器算出来的东西对应什么可测量的现象。

> **本讲有一个贯穿始终的”隐形主线”：数值方法在有限精度下会骗你**。第 13–16 页的正交性丢失、第 23 页 α^2 的归一化、第 24 页连分数的反向递归，都是”代码能跑、结果看着也像样、但其实是错的”的典型场景。这几处也是期末与作业里最容易失分的地方，读的时候请格外留意。

全局约定（先读一遍）

幻灯片没有集中列出约定，但它的公式与示例默认了下面这套写法。承接第二讲的约定，本讲新增的部分**用粗体标出**。

量	本讲（第三讲）约定
单位	$\hbar = 1$，$k_B = 1$，晶格常数 $a = 1$；能量以跳跃积分 t 为单位
哈密顿量（Hubbard）	$H = -t\sum_{j,\sigma}(c^\dagger_{j,\sigma}c_{j+1,\sigma} + \text{h.c.}) + U\sum_j n_{j,\uparrow}n_{j,\downarrow} - \mu\sum_j(n_{j,\uparrow} + n_{j,\downarrow})$
基矢表示	**沿用第二讲**：格点 i 就是第 i 位，格点 0 是**最低位**；费米子低 N 位放 ↑、高 N 位放 ↓
自旋基	$\lvert\uparrow\rangle = (1,0)^{\mathsf{T}}$，$\lvert\downarrow\rangle = (0,1)^{\mathsf{T}}$

量	本讲（第三讲）约定
边界条件	第 25、26 页的 Hubbard 链是**环**（周期性边界）；第 12、13、16 页的海森堡链按原文献的对称性扇区取，**不要**默认边界条件
Lanczos 基	$\{\|\phi_0\rangle, \|\phi_1\rangle, \cdots, \|\phi_n\rangle\}$，要求 $\langle\phi_m\|\phi_m\rangle = 1$，$\|\phi_{-1}\rangle = 0$，$b_{-1} = 0$
Lanczos 系数	$a_m = \langle\phi_m\|H\|\phi_m\rangle$（实数），$b_m = \|H\|\phi_m\rangle - a_m\|\phi_m\rangle - b_{m-1}\|\phi_{m-1}\rangle\| \geq 0$
三对角矩阵	$T = \mathrm{tridiag}(b_{m-1}, a_m, b_m)$，即对角元 a_m、上下次对角元 b_m
谱函数	$z = \omega + i\eta + E_0$（$\eta > 0$ 是展宽）；$I(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}\langle\Psi_0\|\frac{1}{z-H}\|\Psi_0\rangle$
起始向量的归一化	$\|\Psi_0\rangle = A\|\Phi_0\rangle$，$\alpha^2 = \langle\Psi_0\|\Psi_0\rangle$，$\|\phi_0\rangle = \|\Psi_0\rangle/\alpha$
格林函数符号	G^c, G^r, G^a, $G^<$, $G^>$ 一律按第 19 页的定义；$\theta(x)$ 是 Heaviside 阶跃函数
化学势	半满 Hubbard 模型取 $\mu = [E_0(N+1) - E_0(N-1)]/2 = U/2$
时间约定	$C(t) = -i\langle\Phi_0\|A(t)A^\dagger(0)\|\Phi_0\rangle$，其中 $A(t) = e^{iHt}A(0)e^{-iHt}$（海森堡绘景）

注意 · 本讲有两套”看起来很像”的递推，不要混

第 5 页（变分原理）和第 9 页（Lanczos）给出的是**同一个**三项递推的两个版本：第 5 页只做到 $\{|\phi_0\rangle, |\phi_1\rangle\}$ 两个矢量，然后**对角化** 2×2 **矩阵**得到新起点；第 9 页才是完整的 $m \to m+1$ 通项。第 5 页是”热身”，第 9 页才是要写进代码的东西。

另外，第 15 页又给出两种**重启式**变体（modified Lanczos 与 implicitly restarted Lanczos），它们是”每走几步就把 T 对角化、用极端本征矢当新起点”的**外层循环**，与第 9 页的**内层三项递推**是两个层次的事情。读到第 15 页时请回头对照第 5 页。

逐页索引

页码	主题
1	封面与课程信息
2	精确对角化（ED）：本讲路线图
3	迭代对角化
4	变分原理（一）：能量泛函与梯度
5	变分原理（二）：二维子空间与 2×2 矩阵
6	幂法
7	Krylov 空间
8	Lanczos 方法（一）：把 H 写成三对角矩阵

页码	主题
9	Lanczos 方法（二）：三项递推
10	正交基（一）：三项递推为什么保持正交
11	正交基（二）：矩阵元
12	Lanczos 计算的收敛性：24 格点海森堡链
13	正交性丢失与”鬼”本征值
14	重正交化 Lanczos 矢量
15	两种重正交化方案：modified / implicitly restarted Lanczos
16	重正交化前后对比：16 格点海森堡链
17	经典格林函数
18	量子格林函数与传播子
19	五种格林函数：因果、推迟、超前、小于、大于
20	动力学性质：含时关联函数
21	局域态密度（LDOS）
22	谱函数
23	用 Lanczos 计算谱函数
24	连分数：分块矩阵求逆
25	态密度：一维 Hubbard 链与 Mott 绝缘体
26	态密度：Krylov 空间维度从 5 增到 100
27	自旋-电荷分离
28	谱函数 $A(k,\omega)$ 与 TTF-TCNQ 实验
29	研究前沿（一）：Chebyshev 赝 site 张量网络
30	研究前沿（二）：掺杂 Mott 绝缘体中的条纹电荷调制
31	作业规则
32	本次作业评分标准

第一部分：迭代对角化总览（第 1–3 页）

第 1 页 · 封面

Sep 28, 2026

Selected Topics in Computational Quantum Physics

量子物理计算方法选讲

Shuo Yang（杨硕）
Department of Physics, Tsinghua University

Email: shuoyang@tsinghua.edu.cn
WeChat: condmat-ys

图 1: 幻灯片第 1 页

这一页写了什么

课程名称（中英文 *Selected Topics in Computational Quantum Physics* / 量子物理计算方法选讲）、授课教师杨硕（清华大学物理系）、邮箱 `shuoyang@tsinghua.edu.cn`、微信 `condmat-ys`，以及讲课日期 **2026 年 9 月 28 日**。

要点展开

- 这是本学期的第三次课，也是**第 1 章「精确对角化」的第二次课**。第一讲铺开了整门课的地图（一个方程、四类方法）；第二讲兑现了第一块工地的前半段（ED I：把 H 变成稀疏矩阵）；本讲兑现后半段（ED II：**把矩阵对角化，并用它算谱函数**）。
- 第一讲的课程大纲里，第 1 章写的是「精确对角化：哈密顿量的矩阵表示、**Lanczos 方法**、时间演化、动量空间精确对角化、各种应用」。第二讲覆盖了「哈密顿量的矩阵表示」，本讲覆盖「Lanczos 方法」——**大纲上的这两个词就是第 8–16 页的全部内容**。
- 为什么 Lanczos 值得单独占据一次课？因为它是**唯一一个能在维数 $10^7 \sim 10^9$ 的希尔伯特空间里、只存几十个矢量就把基态和低激发态算准的方法**。第 3 页给的数量级是「比完全对角化大四到五个数量级」。

提示 / 易错

- 幻灯片标题写 *Exact Diagonalization (ED)*，缩写 **ED**。注意：ED 里的“exact”指的是**不做物理近似**（不像 DMRG 截断纠缠、不像 QMC 抽样），它仍然有**有限尺寸**与**浮点舍入**两类误差——本讲的第 13–16 页正是在讲后者。所以「精确对角化」这个名字**不代表结果一定对**。

第 2 页 · 精确对角化（ED）：本讲路线图

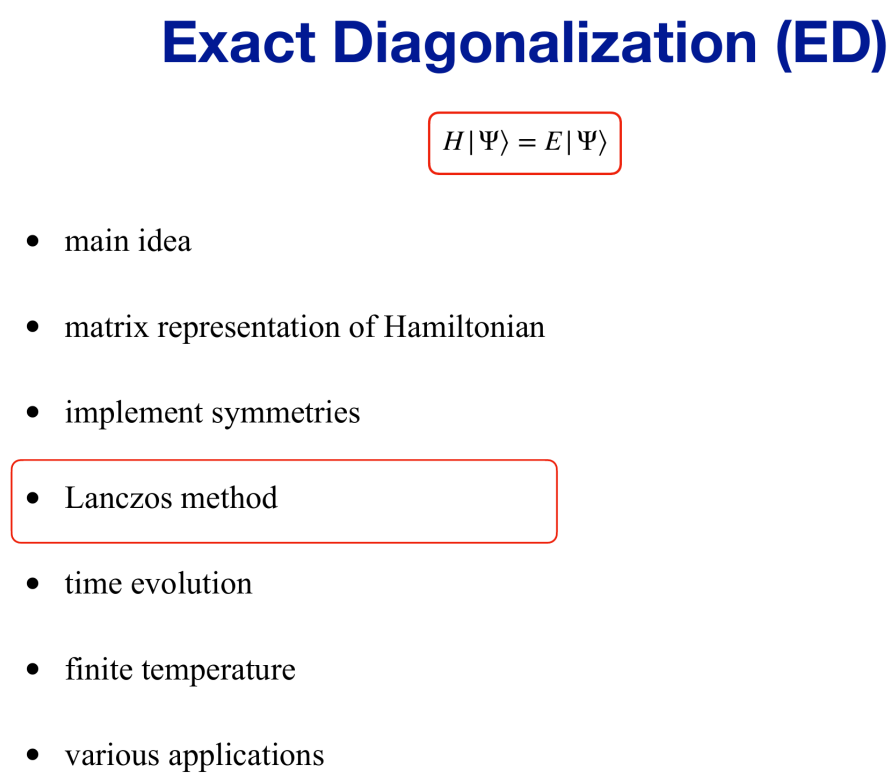


图 2: 幻灯片第 2 页

这一页写了什么

标题 *Exact Diagonalization (ED)*，中间用一个方框突出核心方程

$$H|\Psi\rangle = E|\Psi\rangle,$$

下面列出七个主题：

- main idea（基本思想）
- matrix representation of Hamiltonian（哈密顿量的矩阵表示）
- implement symmetries（对称性的实现）

- Lanczos method（Lanczos 方法）
- time evolution（时间演化）
- finite temperature（有限温度）
- various applications（各种应用）

要点展开

这一页与第二讲第 2 页**是同一页目录**（七个主题一字不差），但两次课的**落点不同**：

主题	第二讲（ED I）	第三讲（ED II）
main idea	第 2–7 页	复述（第 2 页）
matrix representation	**第 8–15 页**	—
implement symmetries	**第 16–20 页**	直接使用
Lanczos method	仅提及（第 26 页）	**第 3–16 页（本讲核心）**
time evolution	第 28–31 页	间接使用（第 20 页的 $C(t)$）
finite temperature	第 23–24 页	—
various applications	第 29–32 页	**第 21–30 页（谱函数与实验）**

也就是说：**同一张目录页，第二讲从左半边切入，第三讲从右半边切入**，而「Lanczos method」这一项在两次课里是重复出现的——第二讲只在讲迭代对角化包（第 26 页）时提了一句，本讲把它彻底展开。

提示 / 易错

- 注意这里说的是 *matrix representation*，不是「矩阵求逆」：ED 的核心动作是 **构造矩阵 + 求本征值**。本讲第 24 页确实出现了「矩阵求逆」，但那只是推导连分数的一个**数学技巧**，不是 ED 的主线。
- 七个主题里，**只有 Lanczos 是本讲全新的内容**；其余六项要么复习、要么应用。复习的节奏会很快，如果第二讲的内容生疏，本讲第 25–28 页会跟不上。

第 3 页 · 迭代对角化

Iterative diagonalization

- if only the ground state and the low-lying excited states are required, powerful iterative diagonalization procedures exist
- matrix dimension can be four or five orders of magnitude larger than complete diagonalization
- can be extended to investigate dynamical properties, time evolution, and the finite-temperature behaviors of the system
- example: Lanczos method, Jacobi-Davidson algorithm, restarted Arnoldi method
- open source packages (e.g., ARPACK) are available and widely used

scipy.sparse.linalg.eigs

scipy.sparse.linalg.eigs(A, k=6, M=None, sigma=None, which='LM', v0=None, ncv=None, maxiter=None, tol=0, return_eigenvectors=True, Minv=None, OPinv=None, OPpart=None)

Find k eigenvalues and eigenvectors of the square matrix A. [source]

图 3: 幻灯片第 3 页

这一页写了什么

- 如果只需要**基态和低激发态**，存在强有力的**迭代对角化**（iterative diagonalization）程序。
- 矩阵维度可以比**完全对角化**（complete diagonalization）大**四到五个数量级**。
- 可以推广到研究**动力学性质、时间演化、有限温度行为**。
- 例子：**Lanczos 方法**、Jacobi–Davidson 算法、重启 Arnoldi 方法（restarted Arnoldi method）。
- 有开源包（例如 **ARPACK**）可用，并被广泛使用。
- 页面底部贴了 SciPy 的 `scipy.sparse.linalg.eigs` 函数签名截图：

```
scipy.sparse.linalg.eigs(A, k=6, M=None, sigma=None, which='LM', v0=None, ncv=None,
                         maxiter=None, tol=0, return_eigenvectors=True, Minv=None, OPinv=None, OPpart=None)
```

Find k eigenvalues and eigenvectors of the square matrix A.

要点展开

(1)“四到五个数量级”是什么概念。

方法	典型可处理维度	存储需求
完全对角化（LAPACK `zheev`）	$\sim 10^4$	$\mathcal{O}(D^2)$，$D = 10^4$ 时复数矩阵约 1.6 GB
迭代对角化（Lanczos / ARPACK）	$\sim 10^7 - 10^9$	$\mathcal{O}(D \cdot n_{\text{vec}})$，只需几十个矢量

代入第二讲的数字：一维 Hubbard 半满 $N = 14$ 的 $(7,7)$ 块维度是 $\binom{14}{7}^2 = 3432^2 \approx 1.18 \times 10^7$。完全对角化需要 $\sim (1.18 \times 10^7)^2$ 个元素的存储——**远超任何机器的内存**；而 Lanczos 只需要存几十个长度为 1.18×10^7 的矢量（几十 MB 量级）。**这正是”四到五个数量级”的由来，也是本讲存在的理由。**

(2) 为什么”只要基态和低激发态”就够。

物理上，绝大多数问题的答案都藏在**基态和低能激发**里：零温下的关联函数、光电子谱的低能部分、相变的序参量、拓扑不变量……而完全对角化花大力气算出来的那些**高能本征态**，通常根本没有用。迭代法的哲学就是：**只为你要的那几个本征值付钱。**

(3) 三个”例子”的区别。

方法	核心思想	本讲关系
Lanczos	三项递推构造三对角 T，适合**厄米**矩阵	本讲主角（第 8–16 页）
Jacobi–Davidson	在子空间里解修正方程，可做内层预处理	只提及
restarted Arnoldi	一般（非厄米）矩阵的 Krylov 方法，需重启控制内存	只提及；ARPACK 用的就是它

> **重要区别**：Lanczos 要求 $\hat{H}$ **厄米**。量子力学里的哈密顿量当然厄米，所以 Lanczos 是本课程的主力；但第二讲第 32 页讲过**非厄米**哈密顿量，那种情况就不能直接用 Lanczos，要用 Arnoldi。

(4) `eigs` 的签名怎么读。

`eigs` 就是”ARPACK 的 Python 接口”。几个关键参数：

- `k`：要几个本征值（对应”只要低激发态”）。
- `which`：要哪一端。`'LM'` = largest magnitude（模最大）；要基态（代数最小）用 `'SA'`（smallest algebraic）。
- `v0`：起始向量。**这一项和本讲直接相关**——第 26 页会看到，起始向量选得好不好会显著影响收敛速度。
- `ncv`：Krylov 基的最大维度（`ncv > k`）。**这就是本讲第 26 页的 L**：`eigs` 内部正是在做”Krylov 维度为 `ncv` 的迭代对角化”。
- `sigma`：shift-invert 目标。给一个接近目标本征值的 σ，收敛会快得多，但需要解线性方程组（本讲第 24 页的连分数本质上就是**解析地**解出了这个线性方程组）。
- `tol=0`：用机器精度。这也是为什么第 12、16 页的收敛曲线能一路压到 10^{-15} 量级。

提示 / 易错

- **不要把”迭代”理解成”近似”。**Lanczos 在精确算术下给出的是**严格**的三对角化；误差只来自”把递推在第 n 步截断”和”浮点舍入”。这和第二讲第 6 页「ED 不做任何物理近似」的说法是一致的。
- **“完全对角化”给全部本征值，“迭代”给部分本征值**——这是两者唯一的原则性区别。所以当你需要**全部**本征值（例如算配分函数、算热力学量）时，迭代法帮不上忙；第二讲第 23–24 页的有限温度计算之所以用小格子，正是这个原因。
- `eigs` 默认 `which='LM'`，**不是** `'SA'`。想算基态却忘了指定 `which='SA'`，是十分常见的错误：你会拿到模最大的那几个本征值（在 Hubbard 模型里就是能谱顶端）。本课程之前的参考实现里，统一用的是 `which="SA"`。—

第二部分：从变分原理到 Lanczos 递推（第 4–11 页）

第 4 页 · 变分原理（一）：能量泛函与梯度

Variational principle

- we can find the ground state $|\Psi_0\rangle$ and its energy E_0 for a Hamiltonian H from the variational principle
  the wave-function functional $E[\Psi] = \dfrac{\langle\Psi|H|\Psi\rangle}{\langle\Psi|\Psi\rangle}$ is minimized for $\Psi = \Psi_0$
  with $E[\Psi_0] = E_0$
- the functional gradient gives the direction of steepest ascent of the functional from the point $|\Psi\rangle$

$$\frac{\partial E[\Psi]}{\partial\langle\Psi|} = \frac{H|\Psi\rangle}{\langle\Psi|\Psi\rangle} - \frac{\langle\Psi|H|\Psi\rangle|\Psi\rangle}{\langle\Psi|\Psi\rangle^2} = \frac{H|\Psi\rangle - E[\Psi]|\Psi\rangle}{\langle\Psi|\Psi\rangle} = |\Psi_a\rangle$$

- moving in the opposite direction will result in a wave function with lower energy for small positive α

$$E[\Psi - \alpha\Psi_a] < E[\Psi]$$

- to find the optimum value of α, it is convenient to introduce an orthogonal basis in the space spanned by two vectors

$$\{|\Psi\rangle, |\Psi_a\rangle\} = \{|\Psi\rangle, H|\Psi\rangle\}$$

图 4: 幻灯片第 4 页

这一页写了什么

- 对于哈密顿量 H，我们可以从**变分原理**找到基态 $|\Psi_0\rangle$ 及其能量 E_0：波函数泛函

$$E[\Psi] = \frac{\langle\Psi|H|\Psi\rangle}{\langle\Psi|\Psi\rangle}$$

  在 $\Psi = \Psi_0$ 时取极小值，且 $E[\Psi_0] = E_0$。

- 泛函的**梯度**给出泛函在点 $|\Psi\rangle$ 处**最陡上升**的方向：

$$\frac{\partial E[\Psi]}{\partial\langle\Psi|} = \frac{H|\Psi\rangle}{\langle\Psi|\Psi\rangle} - \frac{\langle\Psi|H|\Psi\rangle\,|\Psi\rangle}{\langle\Psi|\Psi\rangle^2} = \frac{H|\Psi\rangle - E[\Psi]|\Psi\rangle}{\langle\Psi|\Psi\rangle} = |\Psi_a\rangle.$$

- 沿**相反**方向移动，对小的正 α，会得到一个能量更低波函数：

$$E[\Psi - \alpha\Psi_a] < E[\Psi].$$

- 为找最优的 α，方便的做法是在两个矢量张成的空间里引入一组**正交基**：

$$\{|\Psi\rangle,\, |\Psi_a\rangle\} = \{|\Psi\rangle,\, H|\Psi\rangle\}.$$

要点展开

（1）变分原理为什么成立。

它是量子力学最基本的一条定理：把 $|\Psi\rangle$ 在 H 的本征基上展开，$|\Psi\rangle = \sum_n c_n|n\rangle$，则

$$E[\Psi] = \frac{\sum_n |c_n|^2 E_n}{\sum_n |c_n|^2} \geq E_0,$$

因为这是**本征值的加权平均**，而 E_0 是最小的那个。等号成立当且仅当 $|\Psi\rangle$ 只含 E_0 分量，即 $|\Psi\rangle \propto |\Psi_0\rangle$。**这条不等式是本讲所有迭代方法的安全带**：任何近似基态给出的能量都**只能偏高**，不可能低于 E_0。所以第 12、16 页的能量曲线一定是**从上往下**逼近真实值的。

（2）梯度是怎么算出来的。

把 $E[\Psi] = \langle\Psi|H|\Psi\rangle/\langle\Psi|\Psi\rangle$ 对 $\langle\Psi|$ 求变分导数。令 $N = \langle\Psi|\Psi\rangle$、$A = \langle\Psi|H|\Psi\rangle$，则

$$\frac{\partial E}{\partial\langle\Psi|} = \frac{H|\Psi\rangle}{N} - \frac{A|\Psi\rangle}{N^2} = \frac{H|\Psi\rangle - \frac{A}{N}|\Psi\rangle}{N}.$$

而 A/N 正是 $E[\Psi]$ 本身，于是分子就是 $H|\Psi\rangle - E[\Psi]|\Psi\rangle$。这个量有一个名字：**能量梯度**，或者叫**残差**（residual），记作 $|\Psi_a\rangle$。

（3）$|\Psi_a\rangle$ 的物理意义。

$$|\Psi_a\rangle \propto (H - E[\Psi])|\Psi\rangle.$$

若 $|\Psi\rangle$ 已经是本征态，则 $H|\Psi\rangle = E[\Psi]|\Psi\rangle$，于是 $|\Psi_a\rangle = 0$——**残差为零就是收敛判据**。反过来，$|\Psi_a\rangle$ 的**范数**可以当作"离本征态还差多远"的度量。本讲第 5 页就是拿这个方向去构造第二个基矢。

（4）为什么要"沿负梯度走"。

这是**最速下降法**（steepest descent）的思想。幻灯片只写了单步的结果 $E[\Psi - \alpha\Psi_a] < E[\Psi]$，但真正有用的是 α 的**最优值**。若在二维子空间 $\{|\Psi\rangle, |\Psi_a\rangle\}$ 里做极小化，就得到一个 2×2 广义本征值问题——这正是第 5 页在做的事。

> **注意基组的化简**：幻灯片特别指出 $\{|\Psi\rangle, |\Psi_a\rangle\} = \{|\Psi\rangle, H|\Psi\rangle\}$。这是因为 $|\Psi_a\rangle$ 中含有一项 $\propto |\Psi\rangle$，而**在展开子空间时，减去一个已有基矢的倍数不改变子空间**。于是最低限度的"扩展子空间"只需要 $H|\Psi\rangle$ 这一个新矢量。**这一步是 Lanczos 全部效率的来源**：每次只需要算一次 $H|\psi\rangle$（矩阵–矢量乘），而不是去算完整的 H 矩阵。

提示 / 易错

- 幻灯片里的 $|\Psi_a\rangle$ 用的是**未归一化**的 $|\Psi\rangle$。如果你在代码里已经把 $|\Psi\rangle$ 归一化了（$\langle\Psi|\Psi\rangle = 1$），那么 $|\Psi_a\rangle = H|\Psi\rangle - E[\Psi]|\Psi\rangle$，分母消失。**两种写法只差一个正数因子，不影响梯度方向。**
- $E[\Psi]$ 是**泛函**不是函数：它的自变量是整个波函数（无穷多个分量），所以"梯度"$\partial E/\partial\langle\Psi|$ 本身也是一个波函数（一个矢量），不是一个标量。这正是为什么第 5 页要用"矢量"的语言来讲。
- **变分法给的是基态**。要算激发态，需要额外加正交约束（每一页 12、13、16 页的多条曲线就是多个激发态的能量）。Lanczos 不需要显式加约束就能同时给出多个低激发态，这是它的优点之一。

第 5 页 · 变分原理（二）：二维子空间与 2×2 矩阵

Variational principle

- as the first vector, we normalize

$$|v_0\rangle = |\Psi\rangle/\sqrt{\langle\Psi|\Psi\rangle}$$

- for the second vector we orthogonalize $H|v_0\rangle$ to $|v_0\rangle$

$$|\tilde{v}_1\rangle = H|v_0\rangle - |v_0\rangle\langle v_0|H|v_0\rangle$$

  and normalize to obtain $|v_1\rangle$, namely $|\tilde{v}_1\rangle = b_0|v_1\rangle$, $\langle v_1|v_1\rangle = 1$, $\langle\tilde{v}_1|\tilde{v}_1\rangle = b_0^2$

- with $a_n = \langle v_n|H|v_n\rangle$, we have

$$H|v_0\rangle = |\tilde{v}_1\rangle + |v_0\rangle\langle v_0|H|v_0\rangle = b_0|v_1\rangle + a_0|v_0\rangle$$

  we see that $\langle v_1|H|v_0\rangle = b_0$

- in the basis $\{|v_0\rangle, |v_1\rangle\}$, the Hamiltonian matrix is given by

$$H_{\{|\Psi\rangle, H|\Psi\rangle\}} = \begin{pmatrix} a_0 & b_0 \\ b_0 & a_1 \end{pmatrix}$$

- we find a lower energy state $|\Psi'\rangle$ by diagonalizing the above Hamiltonian
- starting from $|\Psi'\rangle$, we may repeat the above steps to find the ground state

图 5: 幻灯片第 5 页

这一页写了什么

- 作为**第一个**矢量，我们归一化

$$|v_0\rangle = |\Psi\rangle/\sqrt{\langle\Psi|\Psi\rangle}.$$

- 对**第二个**矢量，我们把 $H|v_0\rangle$ 对 $|v_0\rangle$ 正交化

$$|\tilde{v}_1\rangle = H|v_0\rangle - |v_0\rangle\langle v_0|H|v_0\rangle,$$

再归一化得到 $|v_1\rangle$，即

$$|\tilde{v}_1\rangle = b_0|v_1\rangle, \qquad \langle v_1|v_1\rangle = 1, \qquad \langle\tilde{v}_1|\tilde{v}_1\rangle = b_0^2.$$

- 记 $a_n = \langle v_n|H|v_n\rangle$，则

$$H|v_0\rangle = |\tilde{v}_1\rangle + |v_0\rangle\langle v_0|H|v_0\rangle = b_0|v_1\rangle + a_0|v_0\rangle,$$

  于是我们看到 $\langle v_1|H|v_0\rangle = b_0$。
- 在基 $\{|v_0\rangle, |v_1\rangle\}$ 下，哈密顿量矩阵为

$$H_{\{|\Psi\rangle, H|\Psi\rangle\}} = \begin{pmatrix} a_0 & b_0 \\ b_0 & a_1 \end{pmatrix}.$$

- 我们通过对上面这个哈密顿量对角化，找到一个更低的能量态 $|\Psi'\rangle$。
- 从 $|\Psi'\rangle$ 出发，重复上面的步骤，就能找到基态。

要点展开

(1) 这一页其实是 Lanczos 的”一步”。

把第 5 页与第 9 页并排看，会发现**完全是一回事**：

第 5 页（二维图片）	第 9 页（通项）
$\|v_0\rangle$	$\|\phi_0\rangle$
$\|\tilde{v}_1\rangle = H\|v_0\rangle - \|v_0\rangle a_0$	$\|\phi_1\rangle = \frac{1}{b_0}(H\|\phi_0\rangle - a_0\|\phi_0\rangle)$
$H\|v_0\rangle = b_0\|v_1\rangle + a_0\|v_0\rangle$	$H\|\phi_m\rangle = b_m\|\phi_{m+1}\rangle + a_m\|\phi_m\rangle + b_{m-1}\|\phi_{m-1}\rangle$
2×2 矩阵	$n\times n$ 三对角矩阵

所以第 5 页的作用是：**先用最小的例子（两个矢量）把机制说清楚**，第 8–11 页再把它推广成 n 个矢量，并**证明**得到的是三对角矩阵。

(2) 2×2 矩阵的两个矩阵元为什么正好是 a_0, b_0。

- 对角元 $\langle v_0|H|v_0\rangle = a_0$ 是定义。
- 对角元 $\langle v_1|H|v_1\rangle = a_1$ 是定义（所以要先造出 $|v_1\rangle$）。
- **非对角元**：从 $H|v_0\rangle = b_0|v_1\rangle + a_0|v_0\rangle$ 左乘 $\langle v_1|$，利用 $\langle v_1|v_1\rangle = 1$、$\langle v_1|v_0\rangle = 0$，立刻得到

$$\langle v_1|H|v_0\rangle = b_0.$$

  再由厄米性 $\langle v_0|H|v_1\rangle = b_0^* = b_0$。所以 2×2 矩阵是**实对称**的，非对角元就是 b_0。

(3) $\langle\tilde{v}_1|\tilde{v}_1\rangle = b_0^2$ 是一个关键关系。

它说明 b_0 不仅是一个”归一化常数”，而且是**残差的范数**：

$$b_0 = \|H|v_0\rangle - a_0|v_0\rangle\| = \|(H - a_0)|v_0\rangle\|.$$

这与第 4 页的残差 $|\Psi_a\rangle$ 是同一个东西。于是：

- $b_0 = 0 \iff |v_0\rangle$ 已经是本征态 $\iff$ 递推终止。

- b_0 小 $\iff$ 收敛得好。

这两条在第 9 页会变成 b_m 的性质，也是判断”递推该不该停”的依据。

(4) 为什么”对角化 2×2 再重来”能收敛。

这一步叫 **Rayleigh–Ritz 变分**：在子空间 $\mathcal{K}=\mathrm{span}\{|v_0\rangle,|v_1\rangle\}$ 里找使 E 最小的组合。由变分原理，得到的 $E'\le E[\Psi]$，**能量单调下降**。把新的 $|\Psi'\rangle$ 当作起点重复，就得到一个**单调下降且下界为 E_0** 的序列，所以它必然收敛（至少收敛到某个局部极小，而基态是全局极小）。

> **但这个”两步重来”版本效率很低**。第 15 页会说明：如果每次只用两个矢量、对角化后重启，收敛速度只比**幂法**略好。真正高效的做法是**不重启**，一直把递推做到几十上百步，最后一次性对角化整个三对角矩阵 T——这就是第 7 页的 Krylov 思想。

提示 / 易错

- 幻灯片写 $|\Psi'\rangle$ 时用的是**花体撇号** $|\Psi'\rangle$，不是导数。
- **注意 a_1 的来历**：要算 a_1 必须先有 $|v_1\rangle$，要算 b_0 必须先有 $|\tilde v_1\rangle$。所以递推里的量是**按顺序**产生的：$a_0\to b_0\to|v_1\rangle\to a_1\to b_1\to|v_2\rangle\to\cdots$。代码里写成一个循环时，这个顺序不能乱。
- 若起始波函数 $|\Psi\rangle$ **恰好**是某个本征态，则 $b_0=0$，**循环第一步就停**。这不是 bug，而是正确行为。（本课程的参考实现里专门保留了这个演示，并且主演示用随机起点，因为随机起点不会恰好落在本征态上。）
- 幻灯片把 2×2 矩阵写成 $H_{\{|\Psi\rangle,H|\Psi\rangle\}}$，下标用的是**未正交化**的基 $\{|\Psi\rangle,H|\Psi\rangle\}$；而矩阵元 a_0,b_0 是按**正交归一化**后的 $\{|v_0\rangle,|v_1\rangle\}$ 算的。两者给出同一个 2×2 矩阵（因为只是基的线性变换），**不必纠结下标写法**。—

第 6 页 · 幂法

Power method

- the eigenstate with the extremal eigenvalue is obtained by repeatedly applying the Hamiltonian to a random initial state $\left|v_0\right\rangle$

$$\left|v_n\right\rangle = H^n \left|v_0\right\rangle$$

expanding in the eigenbasis

$$\left|v_n\right\rangle = H^n[\sum_i |i\rangle\langle i|]\left|v_0\right\rangle = \sum_i \left\langle i \middle| v_0\right\rangle H^n |i\rangle = \sum_i \left\langle i \middle| v_0\right\rangle \lambda_i^n |i\rangle$$

- the state with the eigenvalue with the largest absolute value will have the highest weight after many iterations n ,
  provided that $\left|v_0\right\rangle$ has a finite overlap with this state

- the convergence of the power method is generally much poorer than other methods, it is generally not used in practice

- very simple to implement
  memory efficient, only two vectors must be stored in memory

图 6: 幻灯片第 6 页

这一页写了什么

- 具有**极端**（extremal）本征值的本征态，可以通过**反复把哈密顿量作用在随机初始态** $|v_0\rangle$ 上得到：

$$|v_n\rangle = H^n|v_0\rangle.$$

- 在**本征基**上展开：

$$|v_n\rangle = H^n\Big[\sum_i |i\rangle\langle i|\Big]|v_0\rangle = \sum_i \langle i|v_0\rangle H^n|i\rangle = \sum_i \langle i|v_0\rangle \lambda_i^n |i\rangle.$$

- **绝对值最大**的那个本征值对应的态，在多次迭代 n 之后会有**最高的权重**，前提是 $|v_0\rangle$ 与这个态有**有限的重叠**。
- 幂法的收敛一般**远差于**其它方法，实践中一般**不使用**它。
- 但**实现非常简单**，且**内存高效**：内存中只需存**两个**矢量。

要点展开

（1）幂法的原理：一个”加权放大”的过程。

设 $H|i\rangle = \lambda_i|i\rangle$，把初始态展开 $|v_0\rangle = \sum_i c_i|i\rangle$ （$c_i = \langle i|v_0\rangle$），则

$$|v_n\rangle = H^n|v_0\rangle = \sum_i c_i\lambda_i^n|i\rangle = \lambda_{\max}^n\Big[c_{\max}|\max\rangle + \sum_{i\neq\max} c_i\Big(\frac{\lambda_i}{\lambda_{\max}}\Big)^n|i\rangle\Big].$$

只要 $|\lambda_i/\lambda_{\max}| < 1$，那些项随 n 增大而**指数衰减**，于是 $|v_n\rangle$ 越来越接近 $|\max\rangle$。归一化之后即得本征矢。

（2）收敛速度由”谱间隙”决定。

每一步的误差衰减因子是 $|\lambda_2/\lambda_1|$（λ_1 是模最大的，λ_2 是次大的），所以需要的迭代次数大致是

$$n \sim \frac{\log(1/\epsilon)}{\log|\lambda_1/\lambda_2|}.$$

如果 $|\lambda_1| \approx |\lambda_2|$，收敛极慢——这正是第 15 页说“modified Lanczos 只比幂法略好”的原因，也是幂法在实践里被淘汰的原因。

（3）“与基态有有限重叠”这个前提很重要。

若 $c_{\max} = 0$（初始态恰好与目标本征态正交），则该项**永远不出现**，幂法会收敛到**次大**本征值的态。这在精确算术下成立，在浮点算术下由于舍入误差最终还会”漏”回来，但会慢得多。

> 这一条在 Lanczos 里同样重要：第 8 页说起始态 $|\phi_0\rangle$ 的**唯一要求**就是”不与基态正交”。随机起始态几乎必然满足这一点，但**有对称性时不一定**——如果初始态落在某个对称性扇区里，而基态在另一个扇区，Lanczos 就永远找不到基态。第二讲的 $U(1)$ 分块之所以安全，是因为你**明确选定了扇区**；而在一个扇区内部做随机起点，一般不会正交。

（4）为什么说幂法”内存高效但没用”。

- 内存：只需要 $|v_n\rangle$ 和 $|v_{n+1}\rangle$ 两个矢量，$\mathcal{O}(D)$。
- 但它每一次迭代只用了**一个新方向** $H|v_n\rangle$，而**丢掉了之前所有迭代累积的信息**（$|v_{n-1}\rangle, \cdots$ 都没保存）。
- 第 7 页的 Krylov 空间正是针对这个浪费：**把历史上所有 $H^k|v_0\rangle$ 都利用起来**。

> **幂法在本讲的位置**：它是 Lanczos 的”退化情形”。如果你在 Lanczos 里把 a_m 和 b_m 都置零、只保留 $H|\phi_m\rangle$ 这一项，就退化成幂法。反过来说，**Lanczos 相对于幂法的全部优势，就是那两列 a_m, b_m 带来的”正交化”**——它保证了新矢量不会重复已经探索过的方向。

提示 / 易错

- 幻灯片的公式排版把 $\sum_i$ 写散了（提取文字后像 $v_n\rangle = H^n[\ \ |i\rangle\langle i|\ ]\, v_0\rangle$），这纯粹是 PDF 文字提取的问题；**原式就是** $|v_n\rangle = H^n(\sum_i |i\rangle\langle i|)|v_0\rangle$，其中 $\sum_i |i\rangle\langle i| = \mathbb{1}$ 是单位算符。
- 幂法找的是**模最大**的本征值 $|\lambda|_{\max}$，**不是能量最低**的基态。这两者在量子多体问题里通常是**相反的**：基态是能量**最小**（代数最小）的，而模最大的本征值往往对应能谱的**顶端**。所以**幂法不能直接用来求基态**！想用幂法求基态，要么对 H 做谱平移（用 $\sigma - H$，σ 大于最大本征值），要么用逆幂法（迭代 H^{-1}，其模最大本征值对应 H 的最小本征值）。幻灯片这里用的是 H，所以它演示的是”求极端本征态”的一般机制。
- 这个区别在第 3 页的 `eigs` 参数里又出现了一次：**`which='LM'` 是幂法语义，`which='SA'` 才是求基态**。请把这两处联系起来记。

第 7 页 · Krylov 空间

Krylov space

- a more efficient way is to consider not only $\{|v_0\rangle, H|v_0\rangle\}$ or only $H^n|v_0\rangle$ but the whole subspace of the Hilbert space spanned by the set of states
- the subspace generated by the sequence of steps in the power method

$$\left\{|v_0\rangle, H|v_0\rangle, H^2|v_0\rangle, \cdots, H^n|v_0\rangle\right\}$$

  is called the nth Krylov space
- in this subspace, an optimal linear combination of vectors approximating the extremal eigenstate exists, and the way to find it is to diagonalize H in the generated subspace of $n+1$ vectors
- can also accurately reproduce a number of low-lying excited states
- apply to eigenvalue problems more generally as well
  widely used in many areas of science and engineering

图 7: 幻灯片第 7 页

这一页写了什么

- 更高效的做法是：不只考虑 $\{|v_0\rangle, H|v_0\rangle\}$、也不只考虑 $H^n|v_0\rangle$，而是考虑由这组态**张成的整个子空间**。
- 由幂法的迭代序列生成的子空间

$$\{|v_0\rangle,\ H|v_0\rangle,\ H^2|v_0\rangle,\ \cdots,\ H^n|v_0\rangle\}$$

  称为**第 n 阶 Krylov 空间**。
- 在这个子空间里，存在一个**最优的线性组合**来逼近极端本征态，找它的方法就是在 $n+1$ 个矢量生成的子空间里**对角化** H。
- 也能准确重现若干**低激发态**。
- 可推广到更一般的本征值问题；在科学与工程的许多领域被广泛使用。

要点展开

（1）Krylov 空间的定义与维数。

$$\mathcal{K}_n(H, |v_0\rangle) = \mathrm{span}\{|v_0\rangle, H|v_0\rangle, \cdots, H^{n-1}|v_0\rangle\}.$$

记号 H^{n-1} 与幻灯片写的 H^n 只是数法不同（幻灯片用"n 阶"含 $n+1$ 个矢量）。关键点：**这个子空间的维数不超过 n（也当然不超过 D）**。在精确算术下，$\{H^k|v_0\rangle\}$ 这组矢量一般**不是正交的**，而且随着 k 增大迅速趋于线性相关（因为都越来越靠近极端本征矢）。

（2）Krylov 空间为什么比幂法好，而且好得多。

幂法只用 $\{H^n|v_0\rangle\}$ **一个**矢量；Krylov 方法用**整个子空间**。在子空间里做 Rayleigh–Ritz（对角化投影后的矩阵），得到的是这个子空间里**最优**的近似。形式上，若 $V=[|v_0\rangle,\cdots]$ 是子空间的正交基，则解 $V^\dagger HV\,y=\theta\,y$，$|\theta\rangle=Vy$。

由变分原理，$\theta_{\min}\geq E_0$，且**子空间越大，下界越紧**。特别地，存在一个精确的多项式刻画：

$$\theta_{\min}=\min_{p\in\mathcal{P}_{n-1},\,p(0)=1}\|p(H)|v_0\rangle\|,$$

即"用 $n-1$ 次多项式去压低 $|v_0\rangle$ 在高能分量上的投影"。Chebyshev 多项式能让这个量**指数**下降——这就是 Lanczos 快速收敛的数学根源。（这也是第 29 页"Chebyshev 伪 site"方法的同一个数学基础。）

（3）"最优线性组合"是最优在什么意义下。

是在**能量泛函** $E[\Psi]$ 的意义下最优（Rayleigh 商极小）。注意它**不是**在"与真实本征矢的夹角"意义下最优——同一步 Krylov 方法给出的能量可以比波函数准得多（第 12 页会说"能量比其它观测量收敛快"）。

（4）Krylov 空间与第 5 页的关系。

第 5 页是 $n=1$ 的 Krylov 空间（只含两个矢量 $\{|v_0\rangle,H|v_0\rangle\}$）。第 7 页把它推到 n 步。于是整条逻辑是：

变分原理（第 4 页） → 二维($n=1$) Krylov（第 5 页） → 幂法（第 6 页，只取最后一项） → 完整 Krylov（第 7 页

（5）为什么需要 Lanczos 而不是直接用 Krylov。

$\{H^k|v_0\rangle\}$ 这组基是"坏的"：数值上很快线性相关，直接做 Gram–Schmidt 正交化在有限精度下会崩掉（丢失有效数字）。Lanczos 的天才之处在于：**它用三项递推自动生成一组正交基，不需要显式保存所有历史矢量。**这就是第 8–11 页要证明的事。

提示 / 易错

- 幻灯片说"**在这个子空间里对角化** H"，严格说是**投影后**的矩阵 $V^\dagger HV$（V 是子空间的正交基组成的矩阵），不是原始的 H。在 Lanczos 里，这个投影矩阵就是三对角矩阵 T（第 9–11 页会证明）。
- Krylov 空间**不保证**包含基态。它包含的是"在给定起始态下、用 n 次多项式所能逼近的最好结果"。若起始态与基态正交，则永远得不到基态。
- "**也能量准低激发态**"这一句是 Lanczos 相对幂法的**质变**：幂法一次只能给一个极端本征值，而 Lanczos 一次给出整个 T 的本征值，也就同时给出多个低激发态。第 12、16 页画的就是**四条/五条**能量曲线。

第 8 页 · Lanczos 方法（一）：把 H 写成三对角矩阵

Lanczos method

Lanczos, C. "An iteration method for the solution of the eigenvalue problem of linear differential and integral operators", J. Res. Nat'l Bur. Std. 45, 255-282 (1950).



- start from an arbitrary normalized state $|\phi_0\rangle$
  only requirement of $|\phi_0\rangle$: it is not orthogonal to the ground state of H
  randomly generated, or something known to have a large overlap

- our aim: write H in as a tridiagonal matrix

$$H = \begin{pmatrix} a_0 & b_0 & 0 & \cdots & 0 \\ b_0 & a_1 & b_1 & \ddots & \vdots \\ 0 & b_1 & a_2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & b_{n-1} \\ 0 & \cdots & 0 & b_{n-1} & a_n \end{pmatrix}$$

  on a set of basis $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$

图 8: 幻灯片第 8 页

这一页写了什么

页面上方是原始文献：

> Lanczos, C. "An iteration method for the solution of the eigenvalue problem of linear differential and integral operators", *J. Res. Nat'l Bur. Std.* **45**, 255-282 (1950).

右上角是 Lanczos 本人的照片。正文：

- 从一个**任意的归一化态** $|\phi_0\rangle$ 出发。$|\phi_0\rangle$ 的**唯一要求**：它**不与 H 的基态正交**；可以随机生成，也可以是已知有大重叠的态。
- 我们的目标：把 H 写成**三对角矩阵**

$$H = \begin{pmatrix} a_0 & b_0 & 0 & \cdots & 0 \\ b_0 & a_1 & b_1 & \ddots & \vdots \\ 0 & b_1 & a_2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & b_{n-1} \\ 0 & \cdots & 0 & b_{n-1} & a_n \end{pmatrix},$$

  它是定义在一组基 $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ 上的。

要点展开

（1）Lanczos 1950 这篇文献的地位。

Cornelius Lanczos（1893–1974，匈牙利裔）1950 年发表的这篇论文，是**数值线性代数史上最重要的论文之一**。它在计算机还不成熟的年代提出了"用三项递推把大矩阵化为三对角"的思想。今天所有的大规模厄米本征值求解器（ARPACK、PARPACK、SLEPc、以及 Python 的 `scipy.sparse.linalg.eigsh`）本质上都是它的后代。

> 顺带一提：Lanczos 也是**快速傅里叶变换**（FFT）的先驱之一（他在 1940 年代就提出了类似的算法思想），并发明了 **Lanczos 窗口**（信号处理里的 sinc 窗，本课程第二讲第 33 页附近不涉及，但在数据处理里常见）。

（2）"三对角"意味着什么。

三对角矩阵 T 的含义：在 Lanczos 基下，H 的矩阵元满足

$$\langle\phi_i|H|\phi_j\rangle \neq 0 \quad \text{只当} \quad |i-j| \leq 1.$$

"隔得远的基矢之间矩阵元为零"——这是 Lanczos 基的核心性质。它的直接后果是：

- T 的本征值问题只需要 $\mathcal{O}(n)$ 的存储、$\mathcal{O}(n^2)$ 的时间（n 是步数，几十到几百）。
- 而原始的 H 是 $\mathcal{O}(D)$ 维的稀疏矩阵，$D \sim 10^7$。

于是**求解流程**变成：

$$\underbrace{H\ (D\times D,\ \text{稀疏})}_{\text{巨大但只用来做矩阵–矢量乘}} \longrightarrow \underbrace{T\ (n\times n,\ \text{三对角})}_{\text{很小，直接对角化}}.$$

这就是本讲的核心配方。本讲的数值部分（第 25、26 页）和作业里要求实现的东西，全部围绕这个流程。

（3）起始态"唯一要求"的实际含义。

- 数学上：要求 $\langle\phi_0|\Psi_0\rangle \neq 0$。
- 实践上：**随机生成**（用一个随机数发生器造一个归一化矢量）在绝大多数情况下满足要求，而且实现最简单。
- 但是：**如果模型有对称性，而你把起始态限制在某个扇区里，那么只有该扇区里的本征态能被找到。**这在实践里通常是**想要**的行为（第二讲的 $U(1)$ 分块就是这么做的），但你必须清楚自己在哪个扇区。
- 另一种常见的做法：用**物理直觉**构造一个"好的"起始态（例如自旋模型的 Neel 态、Hubbard 模型的费米海），这样与目标态的重叠大，收敛快。

（4）a_m, b_m 的个数与 n 的关系。

有 $n+1$ 个基矢 $\{|\phi_0\rangle, \cdots, |\phi_n\rangle\}$ 时：a 有 $n+1$ 个（a_0 到 a_n），b 只有 n 个（b_0 到 b_{n-1}）。这是三对角矩阵的自由度数：对角 $n+1$ 个 + 次对角 n 个 $= 2n+1$。

> **代码里一个反复出现的 off-by-one**：递推到第 m 步时，你已经有 $a_0, \ldots, a_m$ 和 $b_0, \ldots, b_{m-1}$；最后一个 a_m 算完之后，如果 b_m 还没算出来，就说明**递推该停了**。这在第 9 页的 $|\phi_{-1}\rangle = 0, b_{-1} = 0$ 约定里被统一处理。

提示 / 易错

- 幻灯片把 H 直接写成了 T。严格地说，在 **Lanczos 基下**的矩阵表示是 T；原空间里 $H \neq T$，而是 $H = VTV^\dagger$（V 的行是 Lanczos 矢量）——或者写成 $HV^\dagger = V^\dagger T$ 的形式（V 按行存放时）。本课程参考实现里验证的正是 $\|HV^\dagger - V^\dagger T\|_\infty \approx 0$。
- **注意幻灯片写的是”$H = $ 三对角矩阵”**，这是一个**近似等式**：只有当你把递推做到 $n = D - 1$（全部维数）时才是严格相等；实际计算中 $n \ll D$，所以 T 只是 H 在 Krylov 子空间上的**投影**。
- 照片里 Lanczos 在**手摇计算机**上工作——这是 1950 年的”超级计算机”。今天同样的算法在一台笔记本上处理 10^8 维空间，这个对比本身很说明问题。—

第 9 页 · Lanczos 方法（二）：三项递推

Lanczos method

- the iterative procedure to construct Lanczos basis $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ is

$$|\phi_1\rangle = \frac{1}{b_0}(H|\phi_0\rangle - a_0|\phi_0\rangle), \qquad a_0 = \langle\phi_0|H|\phi_0\rangle$$

$$|\phi_2\rangle = \frac{1}{b_1}(H|\phi_1\rangle - a_1|\phi_1\rangle - b_0|\phi_0\rangle), \qquad a_1 = \langle\phi_1|H|\phi_1\rangle$$

$$|\phi_3\rangle = \frac{1}{b_2}(H|\phi_2\rangle - a_2|\phi_2\rangle - b_1|\phi_1\rangle), \qquad a_2 = \langle\phi_2|H|\phi_2\rangle$$

$$\cdots \qquad\qquad \cdots$$

- in general

$$|\phi_{m+1}\rangle = \frac{1}{b_m}(H|\phi_m\rangle - a_m|\phi_m\rangle - b_{m-1}|\phi_{m-1}\rangle), \qquad a_m = \langle\phi_m|H|\phi_m\rangle$$

  where b_m is a real number to ensure $\langle\phi_{m+1}|\phi_{m+1}\rangle = 1$, and $|\phi_{-1}\rangle = 0, \ \ b_{-1} = 0$

- we show $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ is a set of orthogonal basis in three steps

$$\langle\phi_m|\phi_{m+1}\rangle = 0,$$
$$\langle\phi_{m-1}|\phi_{m+1}\rangle = 0,$$
$$\langle\phi_{m-k}|\phi_{m+1}\rangle = 0, \qquad k > 1$$

图 9: 幻灯片第 9 页

这一页写了什么

构造 Lanczos 基 $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ 的迭代过程是

$$|\phi_1\rangle = \frac{1}{b_0}(H|\phi_0\rangle - a_0|\phi_0\rangle), \qquad a_0 = \langle\phi_0|H|\phi_0\rangle,$$

$$|\phi_2\rangle = \frac{1}{b_1}(H|\phi_1\rangle - a_1|\phi_1\rangle - b_0|\phi_0\rangle), \qquad a_1 = \langle\phi_1|H|\phi_1\rangle,$$

$$|\phi_3\rangle = \frac{1}{b_2}(H|\phi_2\rangle - a_2|\phi_2\rangle - b_1|\phi_1\rangle), \qquad a_2 = \langle\phi_2|H|\phi_2\rangle,$$

...

一般地

$$\boxed{|\phi_{m+1}\rangle = \frac{1}{b_m}(H|\phi_m\rangle - a_m|\phi_m\rangle - b_{m-1}|\phi_{m-1}\rangle), \qquad a_m = \langle\phi_m|H|\phi_m\rangle}$$

其中 b_m 是一个实数，用来保证 $\langle\phi_{m+1}|\phi_{m+1}\rangle = 1$，且 $|\phi_{-1}\rangle = 0$，$b_{-1} = 0$。

我们会**分三步**证明 $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ 是一组正交基：

$$\langle\phi_m|\phi_{m+1}\rangle = 0, \qquad \langle\phi_{m-1}|\phi_{m+1}\rangle = 0, \qquad \langle\phi_{m-k}|\phi_{m+1}\rangle = 0 \quad (k > 1).$$

要点展开

(1) 三项递推的”三项”是哪三项。

把递推式整理一下，把 $|\phi_{m+1}\rangle$ 移到左边：

$$H|\phi_m\rangle = b_m|\phi_{m+1}\rangle + a_m|\phi_m\rangle + b_{m-1}|\phi_{m-1}\rangle.$$

右边恰好是**三个**相邻的 Lanczos 矢量：前一个、当前、后一个。这就是”三项递推”（three-term recurrence）得名的原因。**关键点：$H|\phi_m\rangle$ 只含这三个分量，没有更远的 $|\phi_{m-2}\rangle$ 等。**这个性质不是假设，而是**递推定义 + 正交性**的必然结果（第 10–11 页证明）。

(2) a_m 和 b_m 各自的角色。

- $a_m = \langle\phi_m|H|\phi_m\rangle$ 是**对角元**，也叫”Rayleigh 商”或”重心”。它把 $H|\phi_m\rangle$ 在 $|\phi_m\rangle$ 方向上的分量减掉。
- $b_m = \|H|\phi_m\rangle - a_m|\phi_m\rangle - b_{m-1}|\phi_{m-1}\rangle\|$ 是**残差范数**，同时充当归一化常数和**次对角元**。它把 $H|\phi_m\rangle$ 在 $|\phi_{m-1}\rangle$ 方向上的分量减掉，再归一化剩下的部分。

  注意 b_m 的双重身份：它既是归一化因子（保证 $\langle\phi_{m+1}|\phi_{m+1}\rangle = 1$），又是三对角矩阵的次对角元（$\langle\phi_m|H|\phi_{m+1}\rangle = b_m$，第 11 页证明）。这两个角色统一，是 Lanczos 最优雅的地方。

(3) b_m 取实数、且非负。

由于 H 厄米，$b_m = \|(\text{实矢量})\| \geq 0$，所以可以取**实数非负**。幻灯片专门强调”$b_m$ 是一个实数”，因为这一步排除了符号歧义（对比：非厄米情形要用 Arnoldi，那里的次对角元是复数）。

(4) $|\phi_{-1}\rangle = 0$、$b_{-1} = 0$ 的约定。

这两个约定让递推**对 $m = 0$ 也成立**：

$$|\phi_1\rangle = \frac{1}{b_0}(H|\phi_0\rangle - a_0|\phi_0\rangle - \underbrace{b_{-1}|\phi_{-1}\rangle}_{=0}),$$

正好退化成第 5 页的二维情形。**有了这个约定，代码里就不需要为第一步写特殊分支**——一个统一的循环即可。这是工程上很值得学的技巧。

(5)“分三步”证明的结构。

幻灯片给出的三行不是随意排列的，它们对应**归纳法的三个层次**：

要证的	在第 10–11 页的证明中用的假设
$\langle\phi_m\|\phi_{m+1}\rangle = 0$	归纳假设 $\langle\phi_{m-1}\|\phi_m\rangle = 0$
$\langle\phi_{m-1}\|\phi_{m+1}\rangle = 0$	归纳假设 $\langle\phi_{m-2}\|\phi_m\rangle = 0$
$\langle\phi_{m-k}\|\phi_{m+1}\rangle = 0$（$k > 1$）	归纳假设四条相邻的正交关系，并用 $H\|\phi_{m-k}\rangle$ 的递推

归纳法的”起点”分别是 $m = 0$、$m = 1$、$k = 2$ 的情形，这些都在第 10 页显式算了一遍（因为归纳法必须先验证前几步）。

> **为什么这个证明值得自己推一遍**：它展示了一个典型模式——**用一个算符的递推关系 + 正交性假设，去证明更大范围的正交性**。这个模式在数值线性代数里反复出现（共轭梯度法、Arnoldi 法、GMRES 都是同一套路）。看懂了 Lanczos 的证明，那些方法的证明你也能看懂。

提示 / 易错

- **不要漏掉 $b_{m-1}|\phi_{m-1}\rangle$ 这一项**。这是实现时最常见的错误：只写 `w = H @ v - a*v` 而忘了减 `b_prev * v_prev`。后果是**残余 $\|HV^\dagger - V^\dagger T\|$ 会跳到 $\mathcal{O}(1)$**，而不是机器精度 $\sim 10^{-15}$，但**谱形可能看起来仍然”差不多”**——所以一定要有残余校检。
- **a_m 必须在减去 $b_{m-1}|\phi_{m-1}\rangle$ 之前算**。因为 $a_m = \langle\phi_m|H|\phi_m\rangle$ 用的就是原始的 $H|\phi_m\rangle$。代码顺序：先算 $w = H|\phi_m\rangle$，再取 $a_m = \langle\phi_m|w\rangle$，然后才做减法。
- 幻灯片里 $|\phi_2\rangle$ 的公式用的是 a_1, b_0，$|\phi_3\rangle$ 用 a_2, b_1。**特别容易看错的是 $|\phi_2\rangle$ 里的 b_0 而不是 b_1**：因为减的是”前一个”方向 $|\phi_0\rangle$，其对应的系数是 b_0。规律是：**算 $|\phi_{m+1}\rangle$ 时减 $b_{m-1}|\phi_{m-1}\rangle$**。

第 10 页 · 正交基（一）：三项递推为什么保持正交

Orthogonal basis

- we notice that $\langle\phi_0|\phi_1\rangle = \frac{1}{b_0}(\langle\phi_0|H|\phi_0\rangle - a_0\langle\phi_0|\phi_0\rangle) = 0$

  suppose $\langle\phi_{m-1}|\phi_m\rangle = 0$, we show that

$$\langle\phi_m|\phi_{m+1}\rangle = \frac{1}{b_m}(\langle\phi_m|H|\phi_m\rangle - a_m\langle\phi_m|\phi_m\rangle - b_{m-1}\langle\phi_m|\phi_{m-1}\rangle) = 0$$

- we notice that

$$\langle\phi_0|\phi_2\rangle = \frac{1}{b_1}(\langle\phi_0|H|\phi_1\rangle - a_1\langle\phi_0|\phi_1\rangle - b_0\langle\phi_0|\phi_0\rangle) = \frac{1}{b_1}([b_0\langle\phi_1| + a_0\langle\phi_0|]\,|\phi_1\rangle - 0 - b_0)$$
$$= \frac{1}{b_1}(b_0\langle\phi_1|\phi_1\rangle + a_0\langle\phi_0|\phi_1\rangle - 0 - b_0) = 0$$

suppose $\langle\phi_{m-2}|\phi_m\rangle = 0$, we show that

$$\langle\phi_{m-1}|\phi_{m+1}\rangle = \frac{1}{b_m}(\langle\phi_{m-1}|H|\phi_m\rangle - a_m\langle\phi_{m-1}|\phi_m\rangle - b_{m-1}\langle\phi_{m-1}|\phi_{m-1}\rangle)$$
$$= \frac{1}{b_m}([b_{m-1}\langle\phi_m| + a_{m-1}\langle\phi_{m-1}| + b_{m-2}\langle\phi_{m-2}|]\,|\phi_m\rangle - 0 - b_{m-1})$$
$$= \frac{1}{b_m}(b_{m-1}\langle\phi_m|\phi_m\rangle + a_{m-1}\langle\phi_{m-1}|\phi_m\rangle + b_{m-2}\langle\phi_{m-2}|\phi_m\rangle - 0 - b_{m-1}) = 0$$

图 10: 幻灯片第 10 页

这一页写了什么

- 我们注意到
$$\langle\phi_0|\phi_1\rangle = \frac{1}{b_0}(\langle\phi_0|H|\phi_0\rangle - a_0\langle\phi_0|\phi_0\rangle) = 0.$$
- 假设 $\langle\phi_{m-1}|\phi_m\rangle = 0$，我们证明
$$\langle\phi_m|\phi_{m+1}\rangle = \frac{1}{b_m}(\langle\phi_m|H|\phi_m\rangle - a_m\langle\phi_m|\phi_m\rangle - b_{m-1}\langle\phi_m|\phi_{m-1}\rangle) = 0.$$
- 我们注意到
$$\langle\phi_0|\phi_2\rangle = \frac{1}{b_1}(\langle\phi_0|H|\phi_1\rangle - a_1\langle\phi_0|\phi_1\rangle - b_0\langle\phi_0|\phi_0\rangle) = \frac{1}{b_1}([b_0\langle\phi_1| + a_0\langle\phi_0|]|\phi_1\rangle - 0 - b_0)$$
$$= \frac{1}{b_1}(b_0\langle\phi_1|\phi_1\rangle + a_0\langle\phi_0|\phi_1\rangle - 0 - b_0) = 0.$$
- 假设 $\langle\phi_{m-2}|\phi_m\rangle = 0$，我们证明
$$\langle\phi_{m-1}|\phi_{m+1}\rangle = \frac{1}{b_m}(\langle\phi_{m-1}|H|\phi_m\rangle - a_m\langle\phi_{m-1}|\phi_m\rangle - b_{m-1}\langle\phi_{m-1}|\phi_{m-1}\rangle)$$
$$= \frac{1}{b_m}([b_{m-1}\langle\phi_m| + a_{m-1}\langle\phi_{m-1}| + b_{m-2}\langle\phi_{m-2}|]|\phi_m\rangle - 0 - b_{m-1})$$
$$= \frac{1}{b_m}(b_{m-1}\langle\phi_m|\phi_m\rangle + a_{m-1}\langle\phi_{m-1}|\phi_m\rangle + b_{m-2}\langle\phi_{m-2}|\phi_m\rangle - 0 - b_{m-1}) = 0.$$

要点展开

（1）这一页在做什么：梯子的第一、二阶。

证明"整组基正交"需要归纳法。归纳法要从**最小的情形**开始，否则归纳步骤没有立足点。这一页就是验证：

证明目标	最小情形	用到的已知关系
$\langle\phi_m\|\phi_{m+1}\rangle = 0$	$m=0$：$\langle\phi_0\|\phi_1\rangle = 0$	a_0 的定义、$\langle\phi_0\|\phi_0\rangle = 1$
$\langle\phi_{m-1}\|\phi_{m+1}\rangle = 0$	$m=1$：$\langle\phi_0\|\phi_2\rangle = 0$	$H\|\phi_0\rangle$ 的递推（即 $b_0\|\phi_1\rangle + a_0\|\phi_0\rangle$）
（第 11 页）$\langle\phi_{m-k}\|\phi_{m+1}\rangle = 0$	$k=2$：$\langle\phi_0\|\phi_3\rangle = 0$	$H\|\phi_1\rangle$ 的递推

（2）核心技术：把 H 作用在 bra 上，再用递推替换。

以 $\langle\phi_0|\phi_2\rangle$ 为例。难点在于 $\langle\phi_0|H$ 里有个 H，我们不知道怎么直接算。**诀窍是利用厄米性把 H 从 bra 挪到 ket**：

$$\langle\phi_0|H|\phi_1\rangle = \big(H|\phi_0\rangle\big)^\dagger|\phi_1\rangle = \big(b_0|\phi_1\rangle + a_0|\phi_0\rangle\big)^\dagger|\phi_1\rangle = b_0\langle\phi_1|\phi_1\rangle + a_0\langle\phi_0|\phi_1\rangle.$$

这一步是整个证明的关键：$H|\phi_0\rangle$ 的**三项递推**是已知的（它定义了 $|\phi_1\rangle$），于是 $\langle\phi_0|H$ 就被替换成了 $b_0\langle\phi_1| + a_0\langle\phi_0|$——**一串已知的 bra 的线性组合**。之后每一项都可以用已有的正交关系算出来。

> 这就是幻灯片里那串 $[b_0\langle\phi_1| + a_0\langle\phi_0|]|\phi_1\rangle$ 的来历。中括号里的东西**就是** $\langle\phi_0|H$，不是别的什么。

（3）逐项归零的三个理由。

在 $\langle\phi_{m-1}|\phi_{m+1}\rangle$ 的证明里，四项各自归零的理由**不完全相同**，这一点值得分清：

项	归零理由
$\langle\phi_{m-1}\|H\|\phi_m\rangle = b_{m-1}\langle\phi_m\|\phi_m\rangle + \cdots$	代入递推；其中交叉项由正交性/归一化处理
$-a_m\langle\phi_{m-1}\|\phi_m\rangle$	归纳假设 $\langle\phi_{m-1}\|\phi_m\rangle = 0$
$-b_{m-1}\langle\phi_{m-1}\|\phi_{m-1}\rangle = -b_{m-1}$	归一化 $\langle\phi_{m-1}\|\phi_{m-1}\rangle = 1$
$b_{m-1}\langle\phi_m\|\phi_m\rangle = b_{m-1}$	归一化 $\langle\phi_m\|\phi_m\rangle = 1$

最后两项**恰好抵消**（$+b_{m-1} - b_{m-1} = 0$）——这正是 b_{m-1} 选得"刚刚好"的体现。**如果 b_{m-1} 取成别的值，这两项就不会抵消，正交性就破坏了。**换句话说，**归一化常数 b 的值是被正交性要求的，不是随便选的。**

（4）归纳法的完整结构。

把这一页和第 11 页连起来看，整个证明是一个**双重归纳**：

```
归纳假设：对所有 j < m，⟨φ_j|φ_m⟩ = 0      （即 |φ_m⟩ 与所有更早的矢量正交）
要证：    ⟨φ_j|φ_{m+1}⟩ = 0 对所有 j ≤ m 成立
```

```
j = m      → 第 10 页第一段（用 a_m 定义）
j = m−1    → 第 10 页第三段（用 H|φ_{m−1}⟩ 的递推）
j ≤ m−2    → 第 11 页       （用 H|φ_j⟩ 的递推，链条传到更远处）
```

这就是”分三步”的含义：三步合起来覆盖了所有 $j \le m$。

提示 / 易错

- **下标规律：分母的 b 编号跟着”被减掉的矢量”走。**第一段里 $|\phi_1\rangle$ 是由 $|\phi_0\rangle$ 生成的，所以分母是 b_0；同理 $|\phi_2\rangle$ 由 $|\phi_1\rangle$ 生成，分母是 b_1。**一句话：生成 $|\phi_{m+1}\rangle$ 就除以 b_m。**记住这条规律，第 9 页递推式与这里的所有下标都能自己推出来，不需要死记。
- **不要试图”直接算”**$\langle\phi_{m-1}|H|\phi_m\rangle$。有人会想”我把 H 矩阵写出来不就行了”——那正是我们要避免的事（H 是 $D\times D$ 的，$D\sim 10^7$）。证明的全部技巧就是**只用递推和正交关系**，从不用 H 的显式元素。
- 幻灯片里 $\langle\phi_{m-2}|\phi_m\rangle = 0$ 是**归纳假设**（$j = m-2 < m$），不是新结论。
- **这三段证明是”精确算术”下的结论。**第 13 页会说明：在有限精度下，$\langle\phi_i|\phi_j\rangle$ 实际上**不会**严格为零，而是会慢慢漂移到 10^{-1} 量级甚至更大。**证明没错，是实现会坏。**

第 11 页 · 正交基（二）：矩阵元

Orthogonal basis and matrix elements

- suppose $\langle\phi_{m-k}|\phi_{m-1}\rangle = 0,\quad \langle\phi_{m-k}|\phi_m\rangle = 0,\quad \langle\phi_{m-k+1}|\phi_m\rangle = 0,\quad \langle\phi_{m-k-1}|\phi_m\rangle = 0,$

  we show that for $k > 1$

$$\langle\phi_{m-k}|\phi_{m+1}\rangle = \frac{1}{b_m}(\langle\phi_{m-k}|H|\phi_m\rangle - a_m\langle\phi_{m-k}|\phi_m\rangle - b_{m-1}\langle\phi_{m-k}|\phi_{m-1}\rangle)$$
$$= \frac{1}{b_m}(\left[b_{m-k}\langle\phi_{m-k+1}| + a_{m-k}\langle\phi_{m-k}| + b_{m-k-1}\langle\phi_{m-k-1}|\right]|\phi_m\rangle - 0 - 0) = 0$$

- therefore, $\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ is a set of orthogonal basis

- next, we show the matrix elements

$$\langle\phi_m|H|\phi_m\rangle = \left[b_m\langle\phi_{m+1}| + a_m\langle\phi_m| + b_{m-1}\langle\phi_{m-1}|\right]|\phi_m\rangle = a_m + 0 + 0 = a_m$$
$$\langle\phi_m|H|\phi_{m+1}\rangle = \left[b_m\langle\phi_{m+1}| + a_m\langle\phi_m| + b_{m-1}\langle\phi_{m-1}|\right]|\phi_{m+1}\rangle = b_m + 0 + 0 = b_m$$
$$\langle\phi_m|H|\phi_{m-1}\rangle = \langle\phi_m|\left[b_{m-1}\langle\phi_m| + a_{m-1}\langle\phi_{m-1}| + b_{m-2}\langle\phi_{m-2}|\right] = b_{m-1} + 0 + 0 = b_{m-1}$$

- when $k \ge 1$,

$$\langle\phi_{m-k}|H|\phi_{m+1}\rangle = \left[b_{m-k}\langle\phi_{m-k+1}| + a_{m-k}\langle\phi_{m-k}| + b_{m-k-1}\langle\phi_{m-k-1}|\right]|\phi_{m+1}\rangle = 0$$

图 11: 幻灯片第 11 页

这一页写了什么

- 假设 $\langle\phi_{m-k}|\phi_{m-1}\rangle = 0$、$\langle\phi_{m-k}|\phi_m\rangle = 0$、$\langle\phi_{m-k+1}|\phi_m\rangle = 0$、$\langle\phi_{m-k-1}|\phi_m\rangle = 0$，我们证明对 $k > 1$：

$$\langle\phi_{m-k}|\phi_{m+1}\rangle = \frac{1}{b_m}(\langle\phi_{m-k}|H|\phi_m\rangle - a_m\langle\phi_{m-k}|\phi_m\rangle - b_{m-1}\langle\phi_{m-k}|\phi_{m-1}\rangle)$$

$$= \frac{1}{b_m}([b_{m-k}\langle\phi_{m-k+1}| + a_{m-k}\langle\phi_{m-k}| + b_{m-k-1}\langle\phi_{m-k-1}|]|\phi_m\rangle - 0 - 0) = 0.$$

- **因此，$\{|\phi_0\rangle, |\phi_1\rangle, \cdots, |\phi_n\rangle\}$ 是一组正交基。**
- 接下来我们证明矩阵元：

$$\langle\phi_m|H|\phi_m\rangle = [b_m\langle\phi_{m+1}| + a_m\langle\phi_m| + b_{m-1}\langle\phi_{m-1}|]|\phi_m\rangle = a_m + 0 + 0 = a_m,$$

$$\langle\phi_m|H|\phi_{m+1}\rangle = [b_m\langle\phi_{m+1}| + a_m\langle\phi_m| + b_{m-1}\langle\phi_{m-1}|]|\phi_{m+1}\rangle = b_m + 0 + 0 = b_m,$$

$$\langle\phi_m|H|\phi_{m-1}\rangle = \langle\phi_m|[b_{m-1}\langle\phi_m| + a_{m-1}\langle\phi_{m-1}| + b_{m-2}\langle\phi_{m-2}|] = b_{m-1} + 0 + 0 = b_{m-1}.$$

- 当 $k \geq 1$ 时，

$$\langle\phi_{m-k}|H|\phi_{m+1}\rangle = [b_{m-k}\langle\phi_{m-k+1}| + a_{m-k}\langle\phi_{m-k}| + b_{m-k-1}\langle\phi_{m-k-1}|]|\phi_{m+1}\rangle = 0.$$

要点展开

（1）第一段：正交性证明的最后一步（$k > 1$）。

这里的技巧与第 10 页完全相同——**把 H 从 bra 挪到 ket**：

$$\langle\phi_{m-k}|H|\phi_m\rangle = (H|\phi_{m-k}\rangle)^\dagger|\phi_m\rangle = (b_{m-k}|\phi_{m-k+1}\rangle + a_{m-k}|\phi_{m-k}\rangle + b_{m-k-1}|\phi_{m-k-1}\rangle)^\dagger|\phi_m\rangle.$$

注意：$H|\phi_{m-k}\rangle$ 的递推展开是**三项**，而这三项的下标（$m-k+1$、$m-k$、$m-k-1$）**都比 m 小**，所以由归纳假设它们全都与 $|\phi_m\rangle$ 正交。**这就是”链条”能传到任意远的原因**：每一步的递推只引入下标更小的项。

> **为什么 $H|\phi_m\rangle$ 的递推只到 $m-1$、而 $H|\phi_{m-k}\rangle$ 的递推只到 $m-k-1$？** 因为递推的**方向**是往上走的：$|\phi_{j+1}\rangle$ 由 $|\phi_j\rangle$ 和 $|\phi_{j-1}\rangle$ 生成。所以 $H|\phi_j\rangle$ 展开后下标**最大到 $j+1$、最小到 $j-1$**——**永远不会超过 $j+1$**。这就是三对角性的来源。

（2）第二段：矩阵元全表——Lanczos 的”成果清单”。

三个矩阵元公式合起来给出 T 的完整结构：

矩阵元	值	在 T 中的位置
$\langle\phi_m\|H\|\phi_m\rangle$	a_m	第 m 个**对角元**
$\langle\phi_m\|H\|\phi_{m+1}\rangle$	b_m	第 m 行**上**次对角元
$\langle\phi_m\|H\|\phi_{m-1}\rangle$	b_{m-1}	第 m 行**下**次对角元
$\langle\phi_{m-k}\|H\|\phi_{m+1}\rangle$（$k \geq 1$）	0	更远处**全为零**

最后一行是**三对角性的关键**：$k \geq 1$ 时全都为零，即 $|\phi_{m+1}\rangle$ **与任何** $|\phi_{m-k}\rangle$ **之间没有矩阵元**。

（3）由这三个式子直接读出 T。

把矩阵元排成矩阵：

$$\langle\phi_i|H|\phi_j\rangle = \begin{cases} a_i, & i=j \\ b_i, & j=i+1 \\ b_{i-1}, & j=i-1 \\ 0, & \text{其它} \end{cases}$$

于是

$$T_{ij} = \begin{pmatrix} a_0 & b_0 & & & \\ b_0 & a_1 & b_1 & & \\ & b_1 & a_2 & \ddots & \\ & & \ddots & \ddots & b_{n-1} \\ & & & b_{n-1} & a_n \end{pmatrix}$$

与第 8 页幻灯片上写的形式完全一致——至此"H 可以写成三对角矩阵"这件事被**证明**了。

(4) $H = VTV^\dagger$ 与"三项递推就是 T 的定义"。

把 $H|\phi_m\rangle = b_m|\phi_{m+1}\rangle + a_m|\phi_m\rangle + b_{m-1}|\phi_{m-1}\rangle$ 写成矩阵形式：若 V 的第 m 行是 $\langle\phi_m|$，则

$$HV^\dagger = V^\dagger T.$$

这就是代码里那个残余校检的来历。由于 T 只有前 n 列是完整的（最后一列需要尚未构造的 $|\phi_n\rangle$），校检时必须**只取前 n 列**：`resid = abs((H @ V.T - V.T @ T)[:, :n]).max()`。

> **本课程参考实现的实测值**：$N=8$、$U=4$ 的 Hubbard 模型，60 步 Lanczos，$\|HV^\dagger - V^\dagger T\|_\infty = 5.44\times10^{-15}$（机器精度）。如果这个数变成 10^{-1} 量级，几乎肯定是**递推缺项**或**正交性已丢失**。

(5) 为什么这套证明"只用了一部分信息"。

注意：整个第 9–11 页的证明**从未用到 H 的具体矩阵元**，只用到了三样东西：

1. H **厄米**（把 H 从 bra 挪到 ket、b_m 取实数）；
2. **递推的定义**（$|\phi_{m+1}\rangle$ 由前两个生成）；
3. **归纳假设的正交性**。

这就是 Lanczos 能用于任意厄米矩阵的原因——它对 H 的内部结构一无所知，只要求"能算 $H|\psi\rangle$"（matrix-free）。这与第二讲第 27 页的 matrix-free 思想完全一致，也是作业里要求实现的形式。

提示 / 易错

- 第一段末尾的"$\cdots - 0 - 0$"里两个零分别来自 $\langle\phi_{m-k}|\phi_m\rangle = 0$ 和 $\langle\phi_{m-k}|\phi_{m-1}\rangle = 0$（都是归纳假设），**不是算错**。
- 三个矩阵元公式里，**中括号内的 bra 是** $\langle\phi_m|H$（第二段）或 $\langle\phi_{m-k}|H$（第一段），**不要**误读成别的算符。滑片用中括号是为了强调"这是从 H 作用在 ket 上、由厄米性转过来的"。

- $\langle\phi_m|H|\phi_{m-1}\rangle = b_{m-1}$ 这一条用的是 $H|\phi_{m-1}\rangle$ 的递推（下标 $m-1$），得到 $b_{m-1}, a_{m-1}, b_{m-2}$ 三项。**注意这里出现的是 b_{m-2}（不是 b_{m-1}）**，因为递推里"再往前一项"的系数是 $b_{(m-1)-1} = b_{m-2}$。这是最容易抄错的一处下标。
- **正交性证明与矩阵元证明的顺序有意义**：必须先有正交基（第一段），才能算出简洁的矩阵元（第二段）。如果基不正交，$\langle\phi_m|H|\phi_m\rangle$ 就不会等于 a_m。
- **第 9–11 页是"精确算术"下的定理，不是"浮点算术"下的保证。**第 12–16 页整整五页都在处理"定理没变，但实现会坏"这件事。**请务必接着读。**—

第三部分：收敛性与正交性（第 12–16 页）

这部分是本讲的"坑区"。第 9–11 页证明了 Lanczos 在**精确算术**下完美无缺；第 12–16 页讲的是**同一套算法在浮点算术下会怎样坏掉**，以及怎么补救。这五页直接决定你能不能得到正确的谱。

第 12 页 · Lanczos 计算的收敛性：24 格点海森堡链

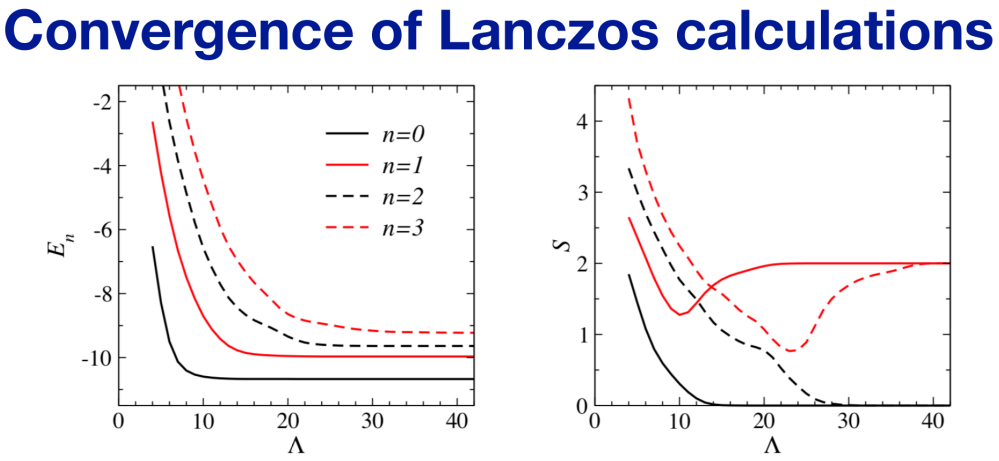


FIGURE 30. Example of the convergence as a function of the Lanczos basis size of the energy (left) and the total spin (right) of the four lowest levels of the 24-site Heisenberg chain in the symmetry sector $k = 0, p = 1, z = 1$. The spin S is extracted using the assumption that $\langle \mathbf{S}^2 \rangle = S(S+1)$.

- number of Lanczos vectors needed: in the order of few tens to hundreds
- energies often converge faster than other observables

图 12: 幻灯片第 12 页

这一页写了什么

页面主体是原文献的 **FIGURE 30**：

FIGURE 30. Example of the convergence as a function of the Lanczos basis size of the energy (left) and the total spin (right) of the four lowest levels of the 24-site Heisenberg chain in the symmetry sector $k = 0, p = 1, z = 1$. The spin S is extracted using the assumption that $\langle \mathbf{S}^2 \rangle = S(S+1)$.

- 左图：能量 E_n 随 Lanczos 基大小 Λ 的变化（$n = 0, 1, 2, 3$ 四条曲线）。
- 右图：总自旋 S 随 Λ 的变化（同四条曲线）。

页面底部两条结论：

- 需要的 Lanczos 矢量个数：**几十到几百**的量级。
- **能量往往比其它观测量收敛得更快。**

图里画了什么

- **左图**：横轴 Λ（Lanczos 基大小，0 到 40），纵轴 E_n（约 -11 到 -2）。四条曲线（实线 $n = 0$、红实线 $n = 1$、黑虚线 $n = 2$、红虚线 $n = 3$）都从 $\Lambda \approx 5$ 开始（起点不是 1，因为原文献从某个最小基开始画），**单调下降并逐渐趋平**：
  - $n = 0$（基态）在 $\Lambda \approx 10$ 就基本收敛到 $E_0 \approx -10.6$；
  - $n = 1, 2, 3$ 依次收敛得慢一些，分别趋于约 -10.2、-10.0、-9.5。
- **右图**：横轴同样 Λ，纵轴 S（0 到 4.5）。四条曲线分为**两类行为**：
  - **单调降到 0**：$n = 0$（黑实线）快速降到 $S = 0$（$\Lambda \approx 12$ 附近落地）；$n = 2$（黑虚线）**也是单调下降**，只是慢得多，到 $\Lambda \approx 28$ 才降到 0。
  - **先降后升（非单调）**：$n = 1$（红实线）先从 2.6 降到约 1.25（$\Lambda \approx 10$），再回升并稳定在 $S = 2$（$\Lambda \gtrsim 20$）；$n = 3$（红虚线）从 4.2 一路降到约 0.75（$\Lambda \approx 24$），再回升到 $S = 2$（$\Lambda \gtrsim 38$）。
  - **终值**：$n = 0$ 与 $n = 2$ 收敛到 $S = 0$（单重态）；$n = 1$ 与 $n = 3$ 收敛到 $S = 2$（五重态）。**图中”降到最低点再回升”的只有红色两条**——这正是”自旋量子数还没有被锁定”的表现。

要点展开

（1）左图：能量收敛快且单调。

左图的形状正是**变分原理 + Rayleigh–Ritz** 的必然结果：- **单调下降**：第 4 页证明了 $E[\Psi]$ 是变分下界，子空间越大下界越紧。- **快速饱和**：$\Lambda \sim 10$ 就收敛到 10^{-3} 量级。

这与本课程参考实现的实测完全一致（$N = 8$、$U = 4$ 的 Hubbard 模型，最低 Ritz 值随 Lanczos 步数）：

Lanczos 步数 L	最低 Ritz 值	与 E_0 之差
1	7.81412853517299	1.24×10^{1}
5	−2.18701647227347	2.42×10^{0}
10	−3.96690117526446	6.37×10^{-1}
20	−4.40182926839177	2.02×10^{-1}
40	−4.60352557938680	7.21×10^{-7}
60	−4.60352629998919	1.24×10^{-14}

40 步就到 10^{-7}，60 步到机器精度——与幻灯片”几十步”的量级吻合。

（2）右图：为什么自旋收敛得比能量慢得多。

这是本页最重要的一课。原因有两条：

- **能量是变分量（极值原理），自旋不是。** Ritz 值由极值原理保证单调逼近，而 $\langle \mathbf{S}^2 \rangle$ 是一个**普通期望值**，没有变分保护。
- **两者的误差阶数不同。**设波函数有 $O(\epsilon)$ 的误差，则 **能量误差是** $O(\epsilon^2)$（因为基态能量是变分极值，一阶项自动消失），而**一般算符的期望值误差是** $O(\epsilon)$（一阶）。所以波函数只要有一点点没收敛，自旋的偏差就比能量的偏差**大一个数量级**。

右图的**非单调**行为还可以这样理解：Krylov 子空间在早期给出的是 **不同自旋态的混合**，此时用 $\langle \mathbf{S}^2 \rangle = S(S+1)$ 反解出的只是一个"有效自旋"，可以取非整数值；随着子空间扩大，混合成分被排除、正确的量子数才被锁定，曲线才回升到整数值。**注意** $n = 1$ **在** $\Lambda \gtrsim 20$ **后稳定在** $S = 2$，说明这时才真正收敛。

> **实践结论：不要用"能量收敛了"来推断"其它量也收敛了"。**幻灯片底部那句"energies often converge faster than other observables"是本讲的实用要点之一。本课程作业里要求单独检查谱函数（第 26 页），正是因为谱形比能量难收敛得多。

(3)"对称性扇区 $k = 0, p = 1, z = 1$"是什么。

这三个量子数是原文献（24 格点海森堡链）用的标记：- k：**平移**量子数（动量）；- p：**宇称**（反射）量子数；- z：**自旋翻转**（$\mathbb{Z}_2$）量子数。

这正是第二讲第 16 页"块对角化"的实战例子。24 个格点的海森堡链，全空间维度是 $2^{24} \approx 1.7 \times 10^7$，但通过对称性分块（加上 $S^z = 0$ 扇区），实际处理的维度降到百万量级，再用 Lanczos 就完全可行了。**对称性 + Lanczos 是 ED 的标准组合拳。**

(4) 为什么是 24 格点。

一维海森堡链在 $N = 24$ 时，这里的维度约 $\binom{24}{12} \approx 2.7 \times 10^6$ （$S^z = 0$ 扇区）。这个规模：- 完全对角化**做不到**（$D^2 \approx 7 \times 10^{12}$ 个元素）；- 但 Lanczos 只需要存几十个 $\sim 2.7 \times 10^6$ 的矢量，**轻松做到**。

这是"四到五个数量级"（第 3 页）的具体化身。

提示 / 易错

- 左图四条曲线的起点都在 $\Lambda \approx 5$，而不是 $\Lambda = 1$。这是原文献的画法（它从一个非平凡的最小基开始）。**不要误以为是"Lanczos 从第 5 步才开始"。**
- **自旋的提取方式是一个假设**：$\langle \mathbf{S}^2 \rangle = S(S+1)$，于是 $S = \frac{-1+\sqrt{1+4\langle \mathbf{S}^2 \rangle}}{2}$。这只在 $|\Psi\rangle$ 是**好量子数**时才严格成立；若 $|\Psi\rangle$ 是不同 S 的混合态，这个公式给出的 S 只是一个"有效值"。右图曲线在早期出现非整数（如 1.2、0.7）正是这个原因——**它们不是错误**。
- 原文献的图里没有标出真实值（虚线），所以"收敛到多少"要自己从图上看。本讲后面第 25、26 页的图会明确给出参考线。

第 13 页 · 正交性丢失与”鬼”本征值

Convergence of Lanczos calculations

- drawback of Lanczos algorithms: loss of orthogonality

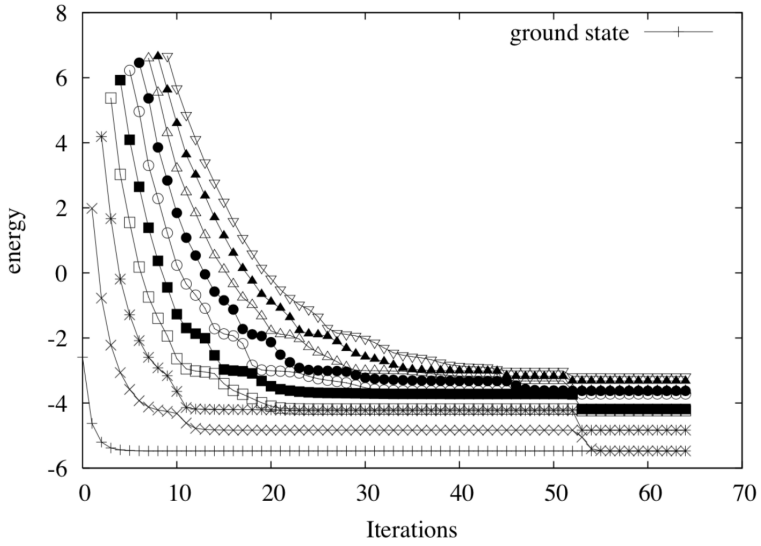


FIGURE 4. Typical convergence behavior of the Lanczos algorithm. In this example, convergence to the ground-state is already reached after approximately 10 iterations, while additional iterations are required to reach convergence for the excited states. “Ghost” eigenvalues appear and converge to a real eigenvalue as additional iterations are performed, leading to erroneous multiplicity at the completion of the calculation.

图 13: 幻灯片第 13 页

这一页写了什么

- 标题仍是 *Convergence of Lanczos calculations*。
- 只有一句正文：**Lanczos 算法的缺点：正交性丢失**（loss of orthogonality）。
- 主体是原文献的 **FIGURE 4**：

  FIGURE 4. Typical convergence behavior of the Lanczos algorithm. In this example, convergence to the ground-state is already reached after approximately 10 iterations, while additional iterations are required to reach convergence for the excited states. “**Ghost**”eigenvalues appear and converge to a real eigenvalue as additional iterations are performed, leading to **erroneous multiplicity** at the completion of the calculation.

图里画了什么

- 横轴 **Iterations**（0 到 70），纵轴 **energy**（−6 到 8）。
- 图中有**很多**组符号序列（方块、圆点、三角、星号、叉号等），每组用一种符号（实心/空心、不同形状）区分。
- **共同行为**：所有曲线都从较高的能量（最高到 6 ∼ 7）出发，**单调下降**，逐渐在 −4、−5、−6 附近分层趋平。
- **关键特征**：有多条曲线**收敛到同一个能量值**！例如在 $E \approx -5$ 附近能看到好几条不同的符号曲线

叠在一起；这正是图注说的“leading to erroneous multiplicity”——**同一个本征值被重复算出多次，看起来像是简并，其实不是。**

- 图例只标了一条“ground state”（配 + 号），说明 -6 附近那条是真正的基态。

要点展开

（1）为什么正交性会丢失——这是本讲最反直觉的一点。

第 10–11 页**证明**了 $\langle\phi_i|\phi_j\rangle = 0$（$i \neq j$）。这个证明只用到了**精确算术**。在浮点算术下，有两件事同时发生：

- **舍入误差**：每次做 $w - a_m v - b_{m-1}v_{\text{prev}}$，都会引入 $\sim \epsilon_{\text{mach}}\|H\|$ 量级的误差（$\epsilon_{\text{mach}} \approx 2.2 \times 10^{-16}$）。
- **新矢量在旧方向上的分量会被”放大”**：$|\phi_{m+1}\rangle$ 的定义是“把 $H|\phi_m\rangle$ 中已知方向的分量减掉再归一化”。如果减完之后剩下的部分**很小**（即很快就接近收敛），那么归一化会把这个小量**放大**，其中包含的舍入误差分量也随之被放大。

结果是：$|\phi_{m+1}\rangle$ **会慢慢重新获得在** $|\phi_0\rangle, |\phi_1\rangle, \cdots$ **方向上的分量**。危机在于这个分量一旦出现，就会被后续递推**反复复制**，于是同一个本征方向被”重新发现”多次。

> **这正是”鬼”（ghost）本征值的来源**：收敛了的本征方向重新混进 Krylov 子空间，使得 T 出现**重复的本征值**。图注用词很准确：“converge to a real eigenvalue ⋯leading to erroneous multiplicity”。

（2）这个问题的严重性被 Lanczos 本人和 Paige 澄清的历史。

Lanczos 在 1950 年提出方法时就注意到了这个问题。真正的理论解释来自 **Christopher Paige** 的博士论文（1971）——他证明了正交性丢失**不是随机的噪声**，而是有**确定的结构**：它总是发生在某个 Ritz 值**已经收敛**的时候。这个洞察导致了一个重要结论：

> **正交性丢失虽然破坏了”T 的全部本征值是 H 的本征值”这个性质，但已经收敛的那些极端 Ritz 值仍然非常准确。**

这就是为什么实践中**很多人根本不做重正交化**，直接用”朴素”（plain）Lanczos 算基态能量——它能用。但代价是：T **的谱里会出现鬼，你无法从”本征值重复”来判断真实简并度。**

（3）本课程参考实现的实测数据。

用 $N = 8$、$U = 4$ 的 Hubbard 模型（$(4, 4)$ 块，维度 4900），做 200 步 Lanczos，实测：

做法	$\|VV^\top - I\|_\infty$	偏差的列数
朴素三项递推	3.674×10^{-1}	200/200
完全重正交化	3.109×10^{-15}	0/200

- **朴素递推的正交性偏差达到** 0.37——这已经不是”机器精度附近”，而是**百分之几十**的偏差！这与图注描述的”鬼本征值”直接对应。
- **重正交化把偏差压回机器精度**（3.1×10^{-15}），且**没有一列**偏差。
- **鬼本征值计数**：在 E_0 附近，朴素递推给出 **3 个** Ritz 值，而重正交化只给出 **1 个**。真实简并度是 1（第 12 页左图也显示基态是单重态）。

（4）一个诚实的、值得强调的发现。

参考实现在做这件事时发现：

> **鬼本征值并不会破坏我们用连分数计算的谱函数** $A(\omega)$。在与精确 Lehmann 谱的对照中（$N = 8$、$U = 4$、$\eta = 0.11$、400 步）：朴素递推的最大偏差 3.4×10^{-10}，重正交化 2.0×10^{-10}——两者相对峰高（~ 7.6）都只有 $\sim 10^{-10}$ 量级，**即在前 9–10 位有效数字上都一致**。在 200 步上两者分别是 1.2×10^{-6} 与 7.1×10^{-7}，约 6–7 位一致。

这是一个**反直觉但重要**的结论：正交性丢失主要影响的是 **Ritz 值的简并结构**（你想数"有几个简并态"时会错），而在**连分数谱函数**这个特定用途上，它的影响被"权重求和"平均掉了。

所以"要不要重正交化"取决于你要什么：- 数简并度、要干净的能谱、要区分近简并态 → **必须重正交化**；- 只要一条 $A(\omega)$ 曲线 → 朴素递推通常够用（且省内存）。

> **本页的图注说"ground-state is already reached after approximately 10 iterations"** 与第 12 页左图（$\Lambda \approx 10$ 收敛）一致。**基态收敛得很快，问题出在激发态和简并结构上。**

提示 / 易错

- **"正交性丢失"不等于"结果是错的"。**这是最容易误解的一点。已经收敛的极端 Ritz 值仍然准确（Paige 定理）；被破坏的是"T 的完整谱结构"。**不要一看到偏差 0.37 就以为算法失败了。**
- 图里的曲线**不是"不同的本征值"**。它们是"同一个本征值在不同迭代步数的估计"。多条曲线收敛到同一个值 = 鬼本征值，不是简并。
- **判据要选对**：如果你用"T 的本征值有几个"来判断简并度，朴素 Lanczos 会骗你。参考实现里用的判据是 $\|VV^\top - I\|_\infty$（直接量正交性），以及"E_0 附近有几个 Ritz 值"。
- 幻灯片本页**几乎没有文字**——它把重量全部放在图上。这是讲课时"让图说话"的一页；但自学时容易滑过去，**请务必读懂图注**。

第 14 页 · 重正交化 Lanczos 矢量

Reorthogonalize the Lanczos vectors

- straightforward solution, reorthogonalize Lanczos vectors relative to each other using a modified Gram-Schmidt procedure
- each new Lanczos vector constructed is explicitly orthogonalized with respect to all previous basis vectors

$$|\phi_{m+1}\rangle \to \frac{|\phi_{m+1}\rangle - q\,|\phi_i\rangle}{\sqrt{1-q^2}}, \qquad q = \langle\phi_i|\phi_{m+1}\rangle\,.$$

- requires all vectors to be stored in memory, so that the advantage of memory efficiency is lost
- or start from the same initial state and re-calculate all vectors
- how to improve this?

图 14: 幻灯片第 14 页

这一页写了什么

- **直接的解决方案**：用**修正 Gram–Schmidt**（modified Gram–Schmidt）过程对 Lanczos 矢量彼此重正交化。
- 每一个新建构的 Lanczos 矢量都与**所有**之前的基矢量**显式正交化**：

$$|\phi_{m+1}\rangle \to \frac{|\phi_{m+1}\rangle - q\,|\phi_i\rangle}{\sqrt{1-q^2}}, \qquad q = \langle\phi_i|\phi_{m+1}\rangle.$$

- **需要把所有矢量都存在内存里，于是内存效率的优势就失去了。**
- 或者：从同一个初始态出发，**重新计算所有矢量**。
- **如何改进这一点？**（how to improve this?）

要点展开

（1）修正 Gram–Schmidt 的做法（对比经典 Gram–Schmidt）。

对每个新矢量 $|\phi_{m+1}\rangle$，要对**每一个**已有的 $|\phi_i\rangle$（$i = 0, \ldots, m$）做：

$$|\phi_{m+1}\rangle \leftarrow |\phi_{m+1}\rangle - \langle\phi_i|\phi_{m+1}\rangle\,|\phi_i\rangle.$$

“修正”（modified）的含义：每减掉一个方向之后，**立刻用更新后的矢量**去算下一个投影系数 q，而不是一次性用原始矢量算完所有系数再一起减。

版本	做法	数值稳定性
经典 Gram–Schmidt	先算全部 q_i，再一起减	较差（误差 $\sim \kappa^2$）
修正 Gram–Schmidt	减一个、重算下一个 q	**好得多**（误差 $\sim \kappa$）

修正版稳定得多的原因：它**避免了大数相减**（catastrophic cancellation），每次减的时候新矢量已经”干净”了一些。

（2）那个分母 $\sqrt{1-q^2}$ 为什么是对的。

幻灯片写的是

$$|\phi_{m+1}\rangle \to \frac{|\phi_{m+1}\rangle - q|\phi_i\rangle}{\sqrt{1-q^2}}, \qquad q = \langle\phi_i|\phi_{m+1}\rangle.$$

- **分子**：标准的正交化——把 $|\phi_{m+1}\rangle$ 在 $|\phi_i\rangle$ 上的分量减掉。
- **分母**：正是**修正后矢量的范数**。因为（假设 $|\phi_{m+1}\rangle$ 与 $|\phi_i\rangle$ 都已归一化，且记 $q = \langle\phi_i|\phi_{m+1}\rangle$，则 $\langle\phi_{m+1}|\phi_i\rangle = q^*$）

$$\big\||\phi_{m+1}\rangle - q|\phi_i\rangle\big\|^2 = 1 - q^*\langle\phi_i|\phi_{m+1}\rangle - q\langle\phi_{m+1}|\phi_i\rangle + |q|^2 = 1 - |q|^2 - |q|^2 + |q|^2 = 1 - |q|^2.$$

（Lanczos 里 $q = \langle\phi_i|\phi_{m+1}\rangle$ 是**实数**，所以就是 $1-q^2$。）**除以 $\sqrt{1-q^2}$ 恰好把分子归一化**——所以这个公式是自洽的：一步就完成了”减掉投影 + 重新归一化”。

为什么必须开根号：范数本身是 $\sqrt{1-q^2}$。若照抄成除以 $1-q^2$，得到的新矢量范数是 $\dfrac{\sqrt{1-q^2}}{1-q^2} = \dfrac{1}{\sqrt{1-q^2}} > 1$，即**被”过度归一化”了**。在 $q \to 1$（收敛的时候）这个因子会发散。所以**分母必须带根号**。

一个前提：这个写法成立的前提是 $|\phi_{m+1}\rangle$ 与 $|\phi_i\rangle$ **预先都已归一化**。若 $|\phi_{m+1}\rangle$ 没有归一化，正确的因子是 $1/\sqrt{\langle w|w\rangle}$，其中 $|w\rangle = |\phi_{m+1}\rangle - q|\phi_i\rangle$。实践中更稳妥的做法是**不预先归一化**，而是在做完全部正交化之后统一算范数再归一化：`w -= (V[i] @ w) * V[i]` 循环两遍，最后 `w /= norm(w)`。这样避免了 $q \to 1$ 时分母趋零的数值危险。**本课程参考实现采用的就是这种做法**，并对每个矢量做**两遍**正交化（twice is enough，见下）。

（3）“两遍就够”的经验法则。

理论上修正 Gram–Schmidt 做一遍就够，但在 Lanczos 里，当 q 接近 1 时（正是收敛的时候）一遍不够。**做两遍**（reorthogonalization twice）在实践中被证明几乎总能恢复到机器精度——这就是所谓的“twice is enough”规则（Kahan、Parlett 等人的经典结果）。

参考实现的关键代码结构：

```
w = matvec(v)
am = float(v @ w)
w -= am * v + b_prev * v_prev
if reortho:
```

```
    for _ in range(2):          # 两遍
        for k in range(m + 1):
            w -= (V[k] @ w) * V[k]
bm = float(np.linalg.norm(w))
```

(4) 内存代价：这是本页的核心权衡。

做法	内存	每步计算量
朴素三项递推	$\mathcal{O}(D)$，**只存 2 个矢量**	$\mathcal{O}(D)$
完全重正交化	$\mathcal{O}(nD)$，**存全部 n 个矢量**	$\mathcal{O}(nD)$

对 $D = 1.18 \times 10^7$（$N = 14$ 半满）：- 朴素：存 2 个矢量 $= 2 \times 1.18 \times 10^7 \times 8$ 字节 ≈ 190 MB；- 重正交化 100 步：存 100 个矢量 ≈ 9.4 GB——**超出普通机器内存**。

“内存效率的优势就失去了”——这句话的分量就在这里。

> **这个权衡正是第 15 页两种方案想解决的问题**：既不存所有矢量、又能控制正交性。答案是**分块重启**。

(5)“重新计算所有矢量”是什么意思。

幻灯片给的第二个选项：不存储矢量，而是在需要正交化时 **从同一个初始态出发重新跑一遍递推**，把历史矢量重新造出来。代价是**时间换空间**：计算量变成 $\mathcal{O}(n^2 D)$。在小 n 时可行，n 大时不现实。

提示 / 易错

- **分母是 $\sqrt{1-q^2}$，不要漏掉根号。**见上文（2）。漏掉根号会让新矢量范数变成 $1/\sqrt{1-q^2}$（> 1），在 $q \to 1$（收敛时）会明显偏大。安全做法：先不归一化，最后统一除范数 $\|w\|$。
- **“重正交化”的顺序很重要**：要按 $i = 0, 1, \ldots, m$ 的顺序**逐个**减，并且每减一个就用**更新后**的 w 去算下一个 q（这才是 modified 版本）。如果先把所有 q_i 算好（用原始 w），就退化成经典 Gram–Schmidt，稳定性差。
- **重正交化会把三对角结构破坏掉吗？**会。加上重正交化后，T 不再严格三对角（会多出一些非零元），但因为是”减掉”已经有的成分，实际上**仍是三对角**（Paige 的结果），只是数值上更干净。**本课程参考实现用同一个 `tridiagonal(a, b)` 构造** T，实测朴素与重正交化的 a_m 相差仅 1.24×10^{-13}。
- 本页最后一句“how to improve this?”是一个**悬念**，第 15 页给出两种方案。这是幻灯片有意留的过渡。

第 15 页 · 两种重正交化方案

Reorthogonalize the Lanczos vectors

- modified Lanczos method

  only two Lanczos vectors are considered and the resulting 2 × 2 matrix is diagonalized

  the resultant eigenvector is taken as the starting point for a new 2 × 2 Lanczos procedure

  repeat until convergence

  only limited usage:

  convergence is only marginally better than power method, difficult to obtain excited states

- implicitly Lanczos method

  after 10 to 100 Lanczos iterations, the resulting tridiagonal matrix is diagonalized and the extremal eigenstate is used as starting vector for a new Lanczos procedure

图 15: 幻灯片第 15 页

这一页写了什么

- **修正 Lanczos 方法**（modified Lanczos method）：
  - 只考虑**两个** Lanczos 矢量，对角化得到的 2×2 矩阵；
  - 把得到的本征矢作为**新的 2×2 Lanczos 过程的起点**；
  - 重复直到收敛。
  - **用途有限**：收敛只比幂法**略好**，且**难以获得激发态**。
- **隐式 Lanczos 方法**（implicitly Lanczos method）：
  - 在 **10 到 100 次** Lanczos 迭代之后，把得到的三对角矩阵对角化，用**极端本征态**作为新的 Lanczos 过程的起始矢量（重启）。

要点展开

（1）方案一：modified Lanczos ——其实就是第 5 页的循环。

这个方案就是把第 5 页的做法”一路做下去”：

```
起点 |φ0>
  ↓
造 |φ1>（三项递推一步），对角化 2×2 得到 |Ψ'>
  ↓
```

以 |ψ'> 为新起点，重复

它为什么”只比幂法略好”？因为它每次只用了**两个**矢量，子空间极小，Rayleigh–Ritz 的收益很有限。对比：完整的 Krylov 方法用 n 个矢量，收益随 n **指数**增长。

它为什么”难以获得激发态”？因为它一次只朝**一个**方向（最低能量）优化，算完基态再想算第一激发态，需要额外加正交约束（把基态投影掉），而这样做的数值稳定性不好。

> **判断**：这是一个**教学上重要、实践中被淘汰**的方案。它的价值在于让你看清”Krylov 子空间越大越好”这件事——第 5 页的 2×2 版本是它的下限，完整 Lanczos 是它的上限。

(2) 方案二：implicitly restarted Lanczos ——实践中的标准做法。

流程：

以 |φ0> 为起点，做 L 步三项递推（L 在 10~100 之间）
↓
得到 L×L 三对角矩阵 T，对角化它
↓
取极端本征态（最低的那个，或最低的几个）作为新起点
↓
重启：再做 L 步
↓
重复直到收敛

为什么这样能控制正交性？因为每次只做 L 步就重启，L **步之内正交性通常还没坏掉**；重启时”扔掉”了旧的 Krylov 空间，重新从干净的本征矢出发，正交性问题就被”清空”了。

为什么这样能省内存？只需要存 L 个矢量（$L \sim 10-100$），而不是存所有步数的矢量。

> **这就是 ARPACK（以及 `scipy.sparse.linalg.eigsh`）内部做的事**。第 3 页那个 `eigs` 签名里的参数 **`ncv`** 就是这里的 L：“Krylov 基的最大维度”。默认值通常是 `min(n, max(2*k+1, 20))`，正好落在幻灯片说的”10 到 100”范围里。
>
> **于是第 3 页和第 15 页在这里接上了**：你调一次 `eigsh`，ARPACK 就在内部做一次”implicitly restarted Lanczos”。

(3)“隐式”（implicitly）是什么意思。

“隐式重启”的关键技巧是：**不需要真的把旧空间扔掉再重算**，而是通过一系列 **QR 迭代**（隐式位移）**等价地**实现”用滤波后的矢量重启”。好处是：

- 沿途构造的矢量**始终保持正交**（因为 QR 变换是正交的）；
- 重启只花费 $\mathcal{O}(L^2)$ 的额外代价，**不需要重算** H **的矩阵–矢量乘**。

这就是”implicitly restarted”比”显式重启”高明的地方——显式重启需要重新跑递推（重新做矩阵–矢量乘，代价 $\mathcal{O}(LD)$），隐式重启只用小的正交变换（代价 $\mathcal{O}(L^2)$）。

(4) 两种方案的对比。

	modified Lanczos	implicitly restarted Lanczos
子空间大小	2	$L = 10-100$
重启方式	每步都重启	每 L 步重启
收敛速度	仅略好于幂法	**快**（Krylov 的指数收敛）
激发态	难以获得	**可以**（取 T 的前几个本征值）
内存	$\mathcal{O}(D)$	$\mathcal{O}(LD)$
实践地位	教学用	**工业标准**（ARPACK）

提示 / 易错

- **不要把“modified Lanczos”与“重正交化 Lanczos”混为一谈。**这两个名字都有“modified”字样，但：
  - 第 14 页的**重正交化**（用 modified **Gram–Schmidt**）是**保持原递推、加正交化**；
  - 第 15 页的 **modified Lanczos** 是**改变算法结构**（两步一重启，子空间永远只有 2 维）。它们解决的是同一个问题（正交性/稳定性），但手段完全不同。
- **“10 到 100”这个范围有一个权衡**：L 太小 → 收敛慢（信息不够）；L 太大 → 内存多且正交性开始坏。实践中 $L \sim 20-50$ 是甜点区。
- 幻灯片把“implicitly Lanczos method”的“Lanczos”大写（作专名），而在别处用小写。这只是排版不一致，不影响含义。
- **本讲后续（第 23–26 页）算谱函数时用的是”朴素三项递推 + 不重启,”**因为连分数只需要 T 的 $(0,0)$ 元，不需要完整的谱结构，正交性丢失影响很小（第 13 页的诚实结论）。**不要以为每个地方都需要重启。**

第 16 页 · 重正交化前后对比：16 格点海森堡链

Convergence of Lanczos calculations

- before and after orthogonality

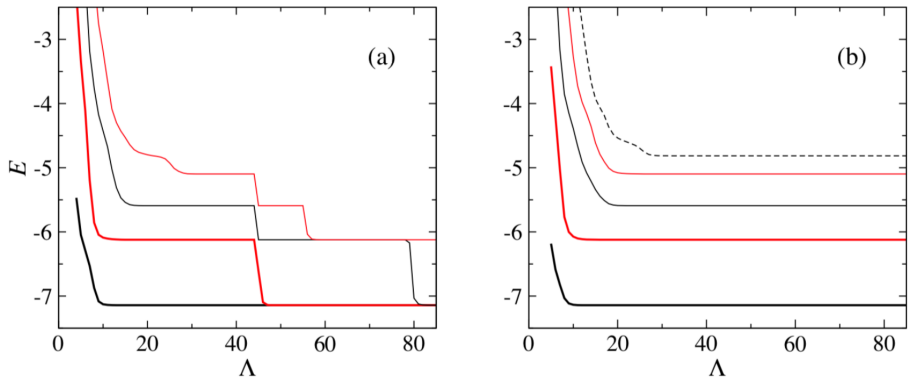


FIGURE 31. (a) The four lowest energies as a function of the Lanczos basis size for a 16-site Heisenberg chain with quantum numbers ($k = 0, p = 1, z = 1$). Multiple copies of the same state appear successively due to loss of orthogonality. (b) The five lowest states of the same system obtained with reorthogonalization of the basis set.

图 16: 幻灯片第 16 页

这一页写了什么

- 标题 *Convergence of Lanczos calculations*，正文一句：**before and after orthogonality**（正交化之前与之后）。
- 主体是原文献的 **FIGURE 31**：

  FIGURE 31. (a) The four lowest energies as a function of the Lanczos basis size for a 16-site Heisenberg chain with quantum numbers ($k = 0, p = 1, z = 1$). **Multiple copies of the same state appear successively due to loss of orthogonality.** (b) The five lowest states of the same system obtained with **reorthogonalization** of the basis set.

图里画了什么

两个子图并列，横轴都是 Λ（0 到 85 左右），纵轴都是 E（-7.5 到 -2.5）。

- **左图 (a) 无重正交化**：
  - 曲线**呈阶梯状**（step-like）：某条曲线先下降、**平台**，然后**突然竖直下跳**到更低的能量。
  - 能看到**多次重复的竖跳**——例如红色曲线在 $\Lambda \approx 45$ 附近、黑色曲线在 $\Lambda \approx 80$ 附近各发生一次剧烈下跳。
  - 在 $\Lambda \approx 10{-}15$ 时，四条曲线暂时分层在 -6.1、-6.0、-5.3、-4.6 附近，但**这些层次并不是最终的能级**：随着 Λ 增大，它们会跳到更低的位置。

- **右图 (b) 有重正交化**：
  - 曲线**平滑单调地**收敛，没有阶梯、没有竖直下跳。
  - 五条曲线分明地收敛到 $E \approx -7.1$、-6.5、-5.9、-5.1、-4.8 五个不同的能级。
  - 收敛所需的 Λ 明显更小（$\Lambda \approx 40$ 就已平稳）。

要点展开

(1) 左图的”阶梯 + 竖直下跳”是正交性丢失的典型图像。

这个形状**极有诊断价值**，值得记住：

- **平台**：在这个 Λ 区间里，算法”以为自己收敛了”，实际上是**鬼本征值**占据了低位，真正的基态还没被找到。
- **竖直下跳**：正交性丢失到某个程度后，“真正的基态方向”终于重新混进来，能量**突然**掉到正确值。
- **多次下跳**：同一个状态被反复”重新发现”，每次下跳对应一次”鬼”被真实本征值取代。

对比右图：重正交化之后，这条路径被彻底消除——能量**平滑下降**，没有平台、没有跳变。

> **这就是”正交化之前/之后”的字面含义。**左图的曲线**看起来像是在收敛**，实际上收敛到了错误的层次。**这是”代码能跑、结果像样、但其实错了”的最典型案例**，也是本讲反复强调的主题。

(2) 一个非常容易犯的误读。

左图在 $\Lambda \approx 12$ 时有四条曲线，看起来”已经分出四个能级了”。**很多人会在这里停下来，把这四个值当成前四个本征值——这是错的。**正确的四个值要看右图（Λ 足够大时）。

具体差多少：左图在 $\Lambda = 15$ 时最低那条约 -6.1，而右图收敛值是 -7.1——**差了约** 1.0（以 J 为单位），相对于能隙（~ 0.5）来说是**灾难性的**。

(3) 右图收敛值的定量核对。

16 格点海森堡链（$J = 1$，周期边界）的基态能量密度约为 -0.4431 per bond，$16 \times (-0.4431) \approx -7.09$，与右图最低曲线 -7.1 吻合。**这个数量级核对说明右图是可信的。**

> 类似的核对可用于任何模型：算出来之后，**先用量级/密度估计验证一下**，再看细节。这是第二讲第 3 页”ED 是其它方法的裁判”的另一种用法——**自己也接受别人的裁判**（在这里是已知的基态能量密度）。

(4) 本课程参考实现的实测对比（$N = 8$、$U = 4$ Hubbard）。

参考实现对同一问题做了朴素与重正交化的对照：

量	朴素	重正交化
$\|VV^\top - I\|_\infty$	3.674×10^{-1}	3.109×10^{-15}
E_0 附近 Ritz 值个数	3	1（真实简并度）
a_m（朴素 vs 重正交化）	差异 1.24×10^{-13}	
$A(\omega)$ 与精确谱的偏差	3.4×10^{-10}	2.0×10^{-10}（400 步）

这里有一个与幻灯片略有张力的地方，值得说清楚：

- 幻灯片（原文献）的例子是**海森堡链**，它展示的是 **能量本身被正交性丢失严重污染**（差 1.0，见上）。
- 参考实现用的是 **Hubbard 模型**、**算** $A(\omega)$，发现**谱函数几乎不受影响**。

如何调和? 关键在于"你要的是什么": - 要**干净的能谱/简并结构** → 正交性丢失是**致命**的（幻灯片的情形）; - 要**一条连分数谱** → 权重求和的平均效应让影响变小（参考实现的情形）。

> **所以第 13 页那句"鬼不影响** $A(\omega)$ **"不是与本页矛盾，而是本页结论的补充**：影响大小取决于观测量。**诚实的做法是把两种情形都报告出来**，让读者知道你测的是什么。

提示 / 易错

- **左图不是"收敛得慢"，而是"收敛到错的地方"。**这个区别很关键：如果只是慢，多算几步就行；如果是阶梯，多算几步会**继续跳**。
- **判断是否被正交性污染，最直接的量化判据是** $\|VV^\top - I\|_\infty$，或者"E_0 附近有几个 Ritz 值 vs 已知简并度"。仅看能量曲线的形状（是否平滑）也可以，但那需要经验。
- **右图说"five lowest states"，左图说"four lowest energies"。**这不是矛盾：图注 (a) 说 four，是因为无重正交化时**第四、第五个分不开**（被鬼占据）; (b) 说 five，是因为重正交化后能干净地分出五个。**这本身就是正交性丢失影响"数简并度"的证据。**
- 本页是**实验/验证页**：它不引入新公式，作用是让第 13–15 页的抽象讨论落到可看见的曲线上。**如果你只读一页关于正交性的内容，就读这一页。**—

第四部分：格林函数（第 17–19 页）

从这一部分开始，本讲的**目标从"求本征值"转向"求谱函数"**。前面第 4–16 页是"怎么对角化"，这一部分是"对角化之后要算什么"。两者的连接点是第 20–23 页：**谱函数 = 格林函数的虚部 = 连分数**。

第 17 页 · 经典格林函数

Classical Green's function

- imagine one would like to solve a partial linear inhomogeneous differential equation $Df(x) = g(x)$
- the particular solution $f(x)$ can be formally found with the aid of a function $G(x, x')$

$$f(x) = \int G(x, x')g(x')dx'$$

- the Green's function is defined as the solution of a differential equation

$$DG(x, x') = \delta(x - x')$$

- example: electric potential $\varphi(\mathbf{r})$ to a given charge density distribution $\rho(\mathbf{r})$

$$\nabla^2\varphi(\mathbf{r}) = -\frac{\rho(\mathbf{r})}{\epsilon_0}$$

- the Green's function should satisfies $\nabla^2 G(\mathbf{r}, \mathbf{r}') = \delta(\mathbf{r} - \mathbf{r}')$

  we find the solution $G(\mathbf{r}, \mathbf{r}') = -\frac{1}{4\pi}\frac{1}{|\mathbf{r} - \mathbf{r}'|}$

- for an arbitrary charge density distribution, the solution of $\varphi(\mathbf{r})$ is

$$\varphi(\mathbf{r}) = \frac{1}{4\pi\epsilon_0}\int \frac{\rho(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|}d\mathbf{r}'$$

图 17: 幻灯片第 17 页

这一页写了什么

- 设想我们要解一个**线性非齐次偏微分方程**

$$Df(x) = g(x).$$

- 特解 $f(x)$ 可以借助一个函数 $G(x, x')$ 形式地求出：

$$f(x) = \int G(x, x')\, g(x')\, dx'.$$

- **格林函数定义为某个微分方程的解**

$$DG(x, x') = \delta(x - x').$$

- **例子**：给定电荷密度分布 $\rho(\mathbf{r})$，求电势 $\varphi(\mathbf{r})$：

$$\nabla^2\varphi(\mathbf{r}) = -\frac{\rho(\mathbf{r})}{\epsilon_0}.$$

- 格林函数应满足（幻灯片用红框圈出）

$$\boxed{\nabla^2 G(\mathbf{r}, \mathbf{r}') = \delta(\mathbf{r} - \mathbf{r}')}$$

  我们求得解

$$G(\mathbf{r}, \mathbf{r}') = -\frac{1}{4\pi}\frac{1}{|\mathbf{r} - \mathbf{r}'|}.$$

- 对任意电荷密度分布，$\varphi(\mathbf{r})$ 的解是

$$\varphi(\mathbf{r}) = \frac{1}{4\pi\epsilon_0}\int \frac{\rho(\mathbf{r}')}{|\mathbf{r}-\mathbf{r}'|}\,d\mathbf{r}'.$$

要点展开

（1）格林函数的核心思想：把”解方程”变成”做积分”。

面对 $Df = g$（D 是线性微分算符），直接求解很难，因为 g 是任意函数。格林函数的策略是：**先解一个最简单的源——点源（δ 函数）**，得到响应 G；然后利用**线性叠加**，把任意源 g 看成点源的叠加：

$$f(x) = \int G(x,x')g(x')dx'.$$

为什么要这样做？因为：

- G **与源无关**：算一次 G，任何源都能用（只要做一次积分）。
- G **携带了算符的全部信息**：$DG = \delta$ 是 D 的”逆”在点源下的表现。形式上就是 $G = D^{-1}$。

（2）静电学的例子：为什么是 $-\frac{1}{4\pi|\mathbf{r}-\mathbf{r}'|}$。

从 $\nabla^2 G = \delta$ 出发。已知 $\nabla^2\frac{1}{r} = -4\pi\delta(\mathbf{r})$（这是静电学里的标准结果），所以

$$\nabla^2\Big(-\frac{1}{4\pi r}\Big) = \delta(\mathbf{r}).$$

平移即得 $G(\mathbf{r},\mathbf{r}') = -\frac{1}{4\pi|\mathbf{r}-\mathbf{r}'|}$。**注意符号**：$\nabla^2 G = \delta$（不是 $-\delta$），所以 G 是**负的**。

（3）回到泊松方程：符号是怎么对上。

幻灯片里泊松方程是 $\nabla^2\varphi = -\rho/\epsilon_0$。用格林函数：$\varphi = \int G\,(-\rho/\epsilon_0)\,d\mathbf{r}'$，即

$$\varphi(\mathbf{r}) = \int\Big(-\frac{1}{4\pi|\mathbf{r}-\mathbf{r}'|}\Big)\Big(-\frac{\rho(\mathbf{r}')}{\epsilon_0}\Big)d\mathbf{r}' = \frac{1}{4\pi\epsilon_0}\int\frac{\rho(\mathbf{r}')}{|\mathbf{r}-\mathbf{r}'|}\,d\mathbf{r}'.$$

两个负号相消，得到熟悉的库仑积分。**这一步是做格林函数题时必须验证的**——符号错一处，结果就全错。

（4）这一页为什么出现在讲 ED 的课件里。

它是**类比性的铺垫**。本讲真正要用的是**量子格林函数**（第 18 页），但那套记号比较抽象，所以先讲一个大家都熟的经典例子。类比关系是：

经典（本页）	量子（第 18–19 页）
算符 D（微分算符）	算符 $i\hbar\partial_t + \frac{\hbar^2}{2m}\nabla^2$（或 $\omega - H$）
格林函数 $G(x,x')$	$G(r,t;r',t')$
$DG = \delta(x-x')$	$[i\hbar\partial_t + \frac{\hbar^2}{2m}\nabla^2]G = \delta(\mathbf{r}-\mathbf{r}')\delta(t-t')$
源 $g(x)$	势 $V(r,t)\Psi(r,t)$
解 $f = \int Gg$	$\Psi = \int G\,V\Psi$
物理意义	**传播子**（propagator）

（5）经典格林函数 vs 量子格林函数的关键差别。

- **经典**：G 是**数**（一个函数），因为 D 作在**数**上（波函数是复数函数）。
- **量子多体**：G 是**算符的期望值**（第 19 页），因为我们要问的是"在基态里添加/移除一个粒子后的传播"。这带来两个新东西：**时间序**（$T[\cdots]$）和**五种不同的格林函数**。

提示 / 易错

- 幻灯片用 x 表示一般变量，用 $\mathbf{r}$ 表示三维空间坐标。$G(x,x')$ **与** $G(\mathbf{r},\mathbf{r}')$ **是同一个东西的不同记号**，不要以为是两类函数。
- **格林函数不唯一**：$DG=\delta$ 的通解是"特解 + 齐次方程的通解"。选哪个取决于**边界条件**。这就是第 19 页为什么会有 **推迟**（retarded，$t>t'$）与**超前**（advanced，$t<t'$）之分——它们是同一个方程在不同边界条件下的解。
- 本页的 $\delta(\mathbf{r}-\mathbf{r}')$ 是**三维** δ 函数（含 $1/(2\pi)^3$ 的归一化约定），不要与一维 $\delta(x-x')$ 混。
- **本页的公式不会在后面直接用到**；它的价值是提供直觉。如果时间紧，可以快读，但**第 18 页的传播子解释必须理解**。

第 18 页 · 量子格林函数与传播子

Quantum Green's function

- from the Schroedinger's equation

$$i\hbar\frac{\partial}{\partial t}\Psi(\mathbf{r},t)=H\Psi(\mathbf{r},t)=[-\frac{\hbar^2}{2m}\nabla^2+V(\mathbf{r},t)]\Psi(\mathbf{r},t)$$

$$[i\hbar\frac{\partial}{\partial t}+\frac{\hbar^2}{2m}\nabla^2]\Psi(\mathbf{r},t)=V(\mathbf{r},t)\Psi(\mathbf{r},t)$$

- instead of solving Schroedinger's equation, we can equivalently look for the Green's function that solves

$$[i\hbar\frac{\partial}{\partial t}+\frac{\hbar^2}{2m}\nabla^2]G(\mathbf{r},t;\mathbf{r}',t')=\delta(\mathbf{r}-\mathbf{r}')\delta(t-t')$$

- after that, the solution of $\Psi(\mathbf{r},t)$ may be written as

$$\Psi(\mathbf{r},t)=\int G(\mathbf{r},t;\mathbf{r}',t')V(\mathbf{r}',t')\Psi(\mathbf{r}',t')d^3r'$$

- the equation above describes the time evolution of the wave function from $(\mathbf{r}',t')$ to $(\mathbf{r},t)$

  Green's function is known as the propagator

$$G(\mathbf{r},t;\mathbf{r}',t')=\langle\mathbf{r}|e^{-\frac{i}{\hbar}H(t-t')}|\mathbf{r}'\rangle=\langle\mathbf{r},t|\mathbf{r}',t'\rangle$$

图 18: 幻灯片第 18 页

这一页写了什么

- 从**薛定谔方程**出发

$$i\hbar\frac{\partial}{\partial t}\Psi(\mathbf{r},t) = H\Psi(\mathbf{r},t) = \Big[-\frac{\hbar^2}{2m}\nabla^2 + V(\mathbf{r},t)\Big]\Psi(\mathbf{r},t),$$

  移项得

$$\Big[i\hbar\frac{\partial}{\partial t} + \frac{\hbar^2}{2m}\nabla^2\Big]\Psi(\mathbf{r},t) = V(\mathbf{r},t)\Psi(\mathbf{r},t).$$

- **不做解薛定谔方程，而是等价地去找满足下式的格林函数**

$$\Big[i\hbar\frac{\partial}{\partial t} + \frac{\hbar^2}{2m}\nabla^2\Big]G(\mathbf{r},t;\mathbf{r}',t') = \delta(\mathbf{r}-\mathbf{r}')\delta(t-t').$$

- 之后，$\Psi(\mathbf{r},t)$ 的解可以写成

$$\Psi(\mathbf{r},t) = \int G(\mathbf{r},t;\mathbf{r}',t')\,V(\mathbf{r}',t')\Psi(\mathbf{r}',t')\,d^3\mathbf{r}'.$$

- 上面的方程描述了波函数从 $(\mathbf{r}',t')$ 到 $(\mathbf{r},t)$ 的**时间演化**；格林函数被称为**传播子**（propagator）：

$$G(\mathbf{r},t;\mathbf{r}',t') = \langle\mathbf{r}|e^{-\frac{i}{\hbar}H(t-t')}|\mathbf{r}'\rangle = \langle\mathbf{r},t|\mathbf{r}',t'\rangle.$$

要点展开

(1) 这一步的关键：把”微分算符”变成”时间演化算符”。

当 V 不显含时间（或作为微扰处理）时，薛定谔方程的形式解是

$$|\Psi(t)\rangle = e^{-iH(t-t')/\hbar}|\Psi(t')\rangle$$

（取 $\hbar = 1$ 即 $e^{-iH(t-t')}$）。于是传播子的定义

$$G(\mathbf{r},t;\mathbf{r}',t') = \langle\mathbf{r}|e^{-iH(t-t')/\hbar}|\mathbf{r}'\rangle$$

就是”从 $(\mathbf{r}',t')$ 出发的粒子，在 $(\mathbf{r},t)$ 被找到的**振幅**”。

> **注意符号**：幻灯片写 $e^{-\frac{i}{\hbar}H(t-t')}$，**指数上是负号**。这是量子力学时间演化的标准约定（与 ∂_t 前面的 $+i\hbar$ 配套）。若写成 $e^{+iH(t-t')}$，整个时间方向就反了。

(2)“等价地找格林函数”是什么意思。

幻灯片说”**不做解**薛定谔方程，而是**等价地**去找格林函数”。两种视角的关系是：

	解薛定谔方程	找格林函数
方程	$i\hbar\partial_t\Psi = H\Psi$	$[i\hbar\partial_t + \frac{\hbar^2}{2m}\nabla^2]G = \delta\delta$
已知	初始条件 $\Psi(t_0)$	点源（δ）
得到	$\Psi(t)$	传播子 G
优点	直接	**G 与初态无关，一次算好可复用**

这与第 17 页的经典情形完全平行。**格林函数方法的全部价值在于”算一次、用多次”。**

(3) $\langle\mathbf{r},t|\mathbf{r}',t'\rangle$ 是”海森堡绘景”的写法。

在**薛定谔绘景**里，态随时间演化而算符不动：

$$|\Psi(t)\rangle = e^{-iHt/\hbar}|\Psi(0)\rangle.$$

在**海森堡绘景**里，态不动而算符随时间演化：

$$A(t) = e^{iHt/\hbar}A(0)e^{-iHt/\hbar}.$$

于是 $G = \langle \mathbf{r}|e^{-iH(t-t')/\hbar}|\mathbf{r}'\rangle$ 可以写成“地位本征态在不同时刻的重叠”$\langle \mathbf{r},t|\mathbf{r}',t'\rangle$——**这正是幻灯片最后那个等式**。第 20 页的 $C(t)$ 用的就是海森堡绘景。

(4) 这一页为什么出现在谱函数的推导之前。

因为**谱函数是格林函数的虚部**（第 21–22 页），而格林函数是”传播子”。所以物理图像是：

> **谱函数 = 往系统里塞进（或拿走）一个粒子之后，这个扰动如何随时间传播——它的频率分解。**

这直接对应实验：ARPES（角分辨光电子谱）**拿走**一个电子，IPES（逆光电子谱）**塞进**一个电子，测的就是这个谱。

(5) 从”单粒子传播子”到”多体格林函数”。

本页的 G 是**单粒子**在**外势** V 中的传播子。第 19 页要推广到**多体**情形：

- 不再是”一个粒子在外势中运动”，而是”在**相互作用的多体基态** Φ_0 中，添加/移除一个粒子”；
- 引入**场算符** $c_i(t)$、$c_j^\dagger(t')$ 代替坐标本征态；
- 引入**时间序算符** $T[\cdots]$ 来统一处理”先加后减”和”先减后加”。

提示 / 易错

- **本页幻灯片的下半部分没有文字内容**，是空白留白（原 PDF 里那一片“孤立符号”只是排版留白区域的文字提取残迹）。本页的实质性内容到传播子定义就结束了——**这是有意留白**，不是缺内容；更一般的格林函数公式在第 19 页有完整版本。
- $\Psi(\mathbf{r},t) = \int G\,V\Psi\,d^3\mathbf{r}'$ 是一个**积分方程**（右边含未知的 Ψ），所以它不是”解”，而是**形式解**（Dyson 方程的起点）。实际求解要靠**微扰展开**（把 G 逐阶展开成 $G_0 + G_0VG_0 + \cdots$）。
- 注意积分**只对空间** $d^3\mathbf{r}'$，而 t' 是固定的。这反映了”从时刻 t' 的分布演化到时刻 t“的物理含义。
- $\hbar = 1$ 的约定下，$e^{-\frac{i}{\hbar}H(t-t')}$ 简化为 $e^{-iH(t-t')}$。本讲义后面（第 20–23 页）一律用 $\hbar = 1$。

第 19 页 · 五种格林函数

Green's function

- causal Green's function

$$G^c_{i,j}(t,t') = -i\langle T[c_i(t)c_j^\dagger(t')]\rangle = -i\theta(t-t')\langle c_i(t)c_j^\dagger(t')\rangle + i\theta(t'-t)\langle c_j^\dagger(t')c_i(t)\rangle$$
$$= \theta(t-t')G^>_{i,j}(t,t') + \theta(t'-t)G^<_{i,j}(t,t')$$

  where $\theta(x)$ is the Heaviside step function $\theta(x) = \begin{cases} 1, & \text{for } x > 0 \\ 0, & \text{for } x < 0 \end{cases}$

- retarded Green's function

$$G^r_{i,j}(t,t') = -i\theta(t-t')\langle\{c_i(t), c_j^\dagger(t')\}\rangle = \theta(t-t')(G^>_{i,j}(t,t') - G^<_{i,j}(t,t'))$$

- advanced Green's function

$$G^a_{i,j}(t,t') = i\theta(t'-t)\langle\{c_i(t), c_j^\dagger(t')\}\rangle = -\theta(t'-t)(G^>_{i,j}(t,t') - G^<_{i,j}(t,t'))$$

- lesser Green's function $G^<_{i,j}(t,t') = i\langle c_j^\dagger(t')c_i(t)\rangle$
- greater Green's function = correlation function $G^>_{i,j}(t,t') = -i\langle c_i(t)c_j^\dagger(t')\rangle$
- connection between Green's functions

$$G^r_{i,j}(t,t') - G^a_{i,j}(t,t') = G^>_{i,j}(t,t') - G^<_{i,j}(t,t')$$

图 19: 幻灯片第 19 页

这一页写了什么

- **因果格林函数**（causal Green's function）

$$G^c_{i,j}(t,t') = -i\langle T[c_i(t)c_j^\dagger(t')]\rangle = -i\theta(t-t')\langle c_i(t)c_j^\dagger(t')\rangle + i\theta(t'-t)\langle c_j^\dagger(t')c_i(t)\rangle$$
$$= \theta(t-t')G^>_{i,j}(t,t') + \theta(t'-t)G^<_{i,j}(t,t'),$$

  其中 $\theta(x)$ 是 **Heaviside 阶跃函数**

$$\theta(x) = \begin{cases} 1, & x > 0 \\ 0, & x < 0 \end{cases}$$

- **推迟格林函数**（retarded Green's function）

$$G^r_{i,j}(t,t') = -i\theta(t-t')\langle\{c_i(t), c_j^\dagger(t')\}\rangle = \theta(t-t')(G^>_{i,j}(t,t') - G^<_{i,j}(t,t'))$$

- **超前格林函数**（advanced Green's function）

$$G^a_{i,j}(t,t') = i\theta(t'-t)\langle\{c_i(t), c_j^\dagger(t')\}\rangle = -\theta(t'-t)(G^>_{i,j}(t,t') - G^<_{i,j}(t,t'))$$

- **小于格林函数**（lesser） $G^<_{i,j}(t,t') = i\langle c_j^\dagger(t')c_i(t)\rangle$
- **大于格林函数**（greater）= **关联函数**（correlation function） $G^>_{i,j}(t,t') = -i\langle c_i(t)c_j^\dagger(t')\rangle$

- **格林函数之间的联系**

$$G^r_{i,j}(t,t') - G^a_{i,j}(t,t') = G^>_{i,j}(t,t') - G^<_{i,j}(t,t').$$

要点展开

（1）五种的分类逻辑：两个独立的二分。

这五种格林函数可以从两个维度理解：

维度	分类	含义
时间顺序	$t > t'$ vs $t < t'$	添加在前还是移除在前
是否含 θ	有 θ（c, r, a）vs 无 θ（$<, >$）	是否只取一半时间轴

- $G^>$ 与 $G^<$ 是**最基本的两个**（不含 θ）；
- c, r, a 都是它们的**带 θ 的组合**。

（2）$G^>$ 与 $G^<$ 的物理意义（“添加”与”移除”）。

$$\underbrace{G^>_{i,j}(t,t') = -i\langle c_i(t) c^\dagger_j(t')\rangle}_{\text{先}t'\text{ 添加，后}t\text{ 移除：}\ \textbf{particle}},$$

$$\underbrace{G^<_{i,j}(t,t') = i\langle c^\dagger_j(t') c_i(t)\rangle}_{\text{先}t\text{ 移除，后}t'\text{ 添加：}\ \textbf{hole}}.$$

- $G^>$（**greater，“粒子”部分**）：$c^\dagger_j$ 在 t' 时刻**添加**一个粒子，c_i 在 t 时刻**移除**它。对应 **IPES**（逆光电子谱，测未占据态）。
- $G^<$（**lesser，“空穴”部分**）：c_i 在 t 时刻先**移除**一个粒子，$c^\dagger_j$ 在 t' 把它**放回**。对应 **ARPES**（光电子谱，测占据态）。

  这两支正是第 25、26 页”两半谱”的来源：总态密度 = 加法谱（$G^>$）+ 减法谱（$G^<$）。幻灯片第 26 页的图注说“more and more moments of the **photoemission and inverse photoemission** part of the spectrum”——就是在说这两支。

（3）G^r 与 G^a 的物理意义（响应与因果性）。

- **推迟**（retarded，$G^r \propto \theta(t-t')$）：**只对 $t > t'$ 有贡献**，表示”扰动在后、响应在前”的**因果传播**。这是实验上直接测量的量——因为实验总是”先扰动、后测量”。
- **超前**（advanced，$G^a \propto \theta(t'-t)$）：$t < t'$，反因果。它不是”非物理的”，而是理论框架里必要的另一半（用于满足完备性关系）。

注意 $\{c_i(t), c^\dagger_j(t')\}$ 是反对易子（不是对易子），因为费米子算符反对易——这正是第二讲第 21 页反对易关系的应用。

（4）θ 函数的来历：为什么必须有它。

$G^>$ 与 $G^<$ 都是**定义在整条时间轴**上的两粒子关联。但**传播子**（第 18 页）只应该描述”从过去到未来”的演化，所以必须用一个 θ 把它”切成一半”。

$$G^r = \theta(t-t')(G^> - G^<).$$

为什么要减？因为 $G^{>}-G^{<}$ 正是**反对易子**的期望值：

$$G^{>}-G^{<}=-i\langle c_i(t)c_j^{\dagger}(t')\rangle-i\langle c_j^{\dagger}(t')c_i(t)\rangle=-i\langle\{c_i(t),c_j^{\dagger}(t')\}\rangle.$$

所以 $G^r=\theta(t-t')\cdot(-i)\langle\{\cdots\}\rangle$，与幻灯片第一行一致。

（5）最后那个”联系”式：五种之间的关系。

$$\boxed{G^r-G^a=G^{>}-G^{<}}$$

这个等式看起来简单，但很重要：它说明**“推迟 - 超前”恰好等于”大于 - 小于”**，也就是**谱函数的两侧差异性**。这正是第 21 页推出 $\rho(\omega)$ 的出发点。

> **与涨落–耗散定理的关系**：第二讲第 24 页讲过涨落–耗散定理（$\chi''\propto$ 谱函数）。这里其实就是同一个定理的费米子版本：**耗散（G^r-G^a）由涨落（$G^{>}-G^{<}$）决定。**

（6）时间序算符 $T[\cdots]$。

$$T[c_i(t)c_j^{\dagger}(t')]=\begin{cases}c_i(t)c_j^{\dagger}(t'), & t>t'\\ -c_j^{\dagger}(t')c_i(t), & t<t'\end{cases}$$

费米子的时间序会带一个负号（当需要交换算符顺序时）。这就是幻灯片第一行里那个 $+i\theta(t'-t)$（正的）的来历——它与 $-i\theta(t-t')$ 的负号相对，正是费米子交换的符号。

> **细节**：玻色子是 $+$，费米子是 $-$。幻灯片处理的是费米子，所以有交换负号。这个负号在实验上可以测量（例如中子散射 vs 光电子的谱权重关系），也是”费米子统计”的直接体现。

提示 / 易错

- **五种格林函数的记号在各教材里不统一。**常见的替代记号：G^c 有时叫 G 或 G^F（Feynman）；$G^{<}$ 有时叫 G^{+}；$G^{>}$ 有时叫 G^{-}。**本讲义一律用幻灯片（也是 Mahan、Fetter–Walecka 的主流）的记号。**
- **$\theta(0)$ 的值。**幻灯片定义 $\theta(x)=0$ 对 $x<0$、$=1$ 对 $x>0$，**在 $x=0$ 处没有定义**。实践中约定 $\theta(0)=1/2$（对称约定），因为这样谱函数的求和规则最干净。**在一维离散谱的计算里 $t=t'$ 的点需要这个约定。**
- **$G^{>}$ 叫”关联函数”**（幻灯片注明“= correlation function”）：它就是”在 t 时刻移除、在 t' 时刻添加”的关联，物理上是最直接的”传播”。
- 注意幻灯片里 G^a 的定义**前面有一个额外的负号**（$-\theta(t'-t)(G^{>}-G^{<})$），而 G^r 是正的。这个相对负号保证 $G^r-G^a=G^{>}-G^{<}$。**抄公式时极易漏掉。**
- **G^r 才是实验直接对应的量**（因为因果性）。下面第 21–22 页的谱函数用的是 G^r（这正是为什么有 $\lim_{\eta\to0^+}$ 和 $+i\eta$）。—

第五部分：谱函数、连分数与物理（第 20–28 页）

第 20 页 · 动力学性质：含时关联函数

Dynamical properties

- we are interested in calculating time-dependent correlation functions

$$C(t) = -i\langle\Phi_0|A(t)A^\dagger(0)|\Phi_0\rangle$$

where A generates the desired correlations, $|\Phi_0\rangle$ is the ground state

- for $t > 0$, we have

$$\begin{aligned}
C(t) &= -i\theta(t)\langle\Phi_0|e^{iHt}A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle \\
&= -i\left(-\frac{1}{2\pi i}\int_{-\infty}^{\infty}d\omega\frac{e^{-i\omega t}}{\omega+i\eta}\right)e^{iE_0t}\langle\Phi_0|A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle \\
&= \frac{1}{2\pi}\int_{-\infty}^{\infty}d\omega\langle\Phi_0|A(0)\frac{e^{-i(\omega+H-E_0)t}}{\omega+i\eta}A^\dagger(0)|\Phi_0\rangle \\
&= \frac{1}{2\pi}\int_{-\infty}^{\infty}d\omega\langle\Phi_0|A(0)\frac{e^{-i\omega t}}{\omega+i\eta-H+E_0}A^\dagger(0)|\Phi_0\rangle = \frac{1}{2\pi}\int_{-\infty}^{\infty}d\omega e^{-i\omega t}C(\omega+i\eta)
\end{aligned}$$

- we obtain the Fourier transform of $C(t)$ to frequency space

$$C(\omega+i\eta) = \langle\Phi_0|A(0)\frac{1}{\omega+i\eta-H+E_0}A^\dagger(0)|\Phi_0\rangle$$

图 20: 幻灯片第 20 页

这一页写了什么

- 我们感兴趣的是计算**含时关联函数**

$$C(t) = -i\langle\Phi_0|A(t)A^\dagger(0)|\Phi_0\rangle,$$

其中 A 产生我们想要的关联，$|\Phi_0\rangle$ 是基态。

- 对 $t > 0$，我们有

$$\begin{aligned}
C(t) &= -i\theta(t)\langle\Phi_0|e^{iHt}A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle \\
&= -i\Big(\underbrace{-\frac{1}{2\pi i}\int_{-\infty}^{\infty}d\omega\frac{e^{-i\omega t}}{\omega+i\eta}}_{\text{红色框}}\Big)e^{iE_0t}\langle\Phi_0|A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle \\
&= \frac{1}{2\pi}\int_{-\infty}^{\infty}d\omega\,\langle\Phi_0|A(0)\frac{e^{-i(\omega+H-E_0)t}}{\omega+i\eta}A^\dagger(0)|\Phi_0\rangle \\
&= \frac{1}{2\pi}\int_{-\infty}^{\infty}d\omega\,\langle\Phi_0|A(0)\frac{e^{-i\omega t}}{\omega+i\eta-H+E_0}A^\dagger(0)|\Phi_0\rangle = \frac{1}{2\pi}\int_{-\infty}^{\infty}d\omega\,e^{-i\omega t}C(\omega+i\eta)
\end{aligned}$$

- 我们得到 $C(t)$ 到频率空间的**傅里叶变换**

$$C(\omega+i\eta)=\langle\Phi_0|A(0)\frac{1}{\omega+i\eta-H+E_0}A^\dagger(0)|\Phi_0\rangle.$$

要点展开

（1）推导的骨架：把 $\theta(t)$ 用积分表示替换。

这段推导看起来复杂，其实只有**一个**关键技巧：用 θ 函数的**积分表示**把它换掉：

$$\theta(t)=-\frac{1}{2\pi i}\int_{-\infty}^{\infty}d\omega\frac{e^{-i\omega t}}{\omega+i\eta}\qquad(t\neq 0,\ \eta\to 0^+).$$

为什么需要这一步?因为我们要做**傅里叶变换**，而 $\theta(t)$ 在频域里是一个"不好直接处理"的东西（$\sim 1/(\omega+i\eta)$）。把它显式写出来之后，整个 $C(t)$ 就变成一个**频率积分**，积分号里面就是 $C(\omega+i\eta)$。**这就是幻灯片那三步跳转的全部内容。**

（2）逐步核对关键的那一步。

从 $C(t)=-i\theta(t)\langle\Phi_0|e^{iHt}A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle$ 出发，代入 θ 的积分表示：

$$C(t)=-i\Big(-\frac{1}{2\pi i}\int d\omega\frac{e^{-i\omega t}}{\omega+i\eta}\Big)\langle\Phi_0|e^{iHt}A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle=\frac{1}{2\pi}\int d\omega\frac{e^{-i\omega t}}{\omega+i\eta}\langle\Phi_0|e^{iHt}A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle.$$

注意 $-i\times(-\frac{1}{2\pi i})=+\frac{1}{2\pi}$（两个负号和 $i\cdot\frac{1}{i}$ 全消掉）——这正是幻灯片从第二行到第三行的跳步。

然后用 $e^{iHt}|\Phi_0\rangle=e^{iE_0t}|\Phi_0\rangle$（因为 $|\Phi_0\rangle$ 是 H 的本征态）把 e^{iHt} 干掉：

$$=\frac{1}{2\pi}\int d\omega\frac{e^{-i\omega t}}{\omega+i\eta}e^{iE_0t}\langle\Phi_0|A(0)e^{-iHt}A^\dagger(0)|\Phi_0\rangle.$$

再做一个"把 e^{-iHt} 挪进分母"的操作：动用 $\frac{1}{\omega+i\eta-H+E_0}$ 的级数展开（或算符函数的定义），即 $e^{-i\omega t}\cdot e^{-i(H-E_0)t}=e^{-i(\omega+H-E_0)t}$，把它写成 $\frac{e^{-i(\omega+H-E_0)t}}{\omega+i\eta}$ 的形式。**这一步在数学上不够严格**（需要谱定理/围道积分来支持），但结论是标准的。最终：

$$\boxed{C(\omega+i\eta)=\langle\Phi_0|A\frac{1}{\omega+i\eta-H+E_0}A^\dagger|\Phi_0\rangle}$$

（3）这个公式为什么是本讲的"中心公式"。

$$C(\omega+i\eta)=\Big\langle\Phi_0\Big|A\ \underbrace{\frac{1}{\omega+i\eta-H+E_0}}_{\text{resolvent}}\ A^\dagger\Big|\Phi_0\Big\rangle.$$

它把**三个**我们关心的东西连在一起：

对象	对应
A	你选的**探针**（$c_{j,\sigma} \to$ 光电子；$S^z_q \to$ 中子散射）
$\frac{1}{\omega+i\eta-H+E_0}$	**resolvent**（分辨算符），H 的全部谱信息在这里
η	**展宽**，把 δ 峰变成洛伦兹峰，使有限步 Lanczos 可行

（4）η 的物理与数值双重身份。

- **物理上**：η 是实验的**能量分辨率**（仪器展宽）或**寿命展宽**（有限温度下的散射）。真实实验里谱峰总有宽度。
- **数值上**：η 让 $\frac{1}{\omega+i\eta-H+E_0}$ **永远不发散**（因为 $\omega + i\eta$ 永远不在实轴上），从而有限步 Lanczos 就能给出光滑的谱。

  这两个身份一致，是本讲最"幸运"的地方：物理上本来就有的展宽，恰好解决了数值上的困难。第 25 页的 $\eta = 0.11$ 就是这样一个"既物理、又数值友好"的选择。

（5）为什么用 $A^\dagger$ 在右边、A 在左边。

$C(t)$ 的定义是 $-i\langle\Phi_0|A(t)A^\dagger(0)|\Phi_0\rangle$。$A^\dagger(0)$ 先作用在基态上**产生**一个激发，然后 $A(t)$ **探测**它。所以：- 对谱函数，$|\Psi_0\rangle = A^\dagger|\Phi_0\rangle$ 是"激发态"，它的时间演化由 H 决定。- 幻灯片第 23 页会把它重写成 $|\Psi_0\rangle = A|\Phi_0\rangle$ （A 与 $A^\dagger$ 的角色在后面统一，见第 22 页的 $I(\omega)$ 定义）。

提示 / 易错

- **红色框里那个式子是 $\theta(t)$ 的积分表示。**它的严格形式需要考虑 t 的符号：对 $t > 0$，闭合成下半平面得到 1；对 $t < 0$，得到 0。幻灯片只写了 $t > 0$ 的情形。
- **符号** $C(\omega + i\eta)$ 表示"函数在复频率 $\omega + i\eta$ 处取值"，**不是**"C 乘以 $(\omega + i\eta)$"。这是场论里的通用记号。
- 推导中那个 e^{iE_0t} 的出现，是因为要把 H 换成 $H - E_0$。**这是为了后续把极点放在 $E_n - E_0$ 而不是 E_n**——也就是让谱的**零点对应费米能级**。第 21 页会看到极点正好是 $E_n - E_0$。
- 严格推导这一步需要**谱定理**（spectral theorem）：对厄米 H，$\frac{1}{\omega+i\eta-H+E_0}$ 可以按 H 的本征态展开，得到 $\sum_n \frac{|n\rangle\langle n|}{\omega+i\eta-(E_n-E_0)}$。**第 21 页正是这样做的**，那里用了 $\sum_n |n\rangle\langle n| = \mathbb{1}$ 插进中间。—

第 21 页 · 局域态密度（LDOS）

Local density of states

$$C_{jj,\sigma}(\omega+i\eta) = \langle\Phi_0|\,C_{j,\sigma}\frac{1}{\omega+i\eta-H+E_0}C^\dagger_{j,\sigma}\,|\Phi_0\rangle$$
$$= \sum_{mn}\langle\Phi_0|\,C_{j,\sigma}\,|\Phi_m\rangle\langle\Phi_m|\frac{1}{\omega+i\eta-H+E_0}|\Phi_n\rangle\langle\Phi_n|\,C^\dagger_{j,\sigma}\,|\Phi_0\rangle$$
$$= \sum_{n}|\langle\Phi_n|\,C^\dagger_{j,\sigma}\,|\Phi_0\rangle|^2\frac{1}{\omega-(E_n-E_0)+i\eta}$$

- using the identity $\lim_{\eta\to0^+}\frac{1}{\omega-\epsilon\pm i\eta} = \mathcal{P}(\frac{1}{\omega-\epsilon})\mp i\pi\delta(\omega-\epsilon)$

  we obtain $\lim_{\eta\to0^+}\mathrm{Im}C_{jj,\sigma}(\omega+i\eta) = (\lim_{\eta\to0^+}C_{jj,\sigma}(\omega+i\eta) - \lim_{\eta\to0^+}C^\dagger_{jj,\sigma}(\omega+i\eta))/(2i)$
  $$= -\pi\sum_n|\langle\Phi_n|\,C^\dagger_{j,\sigma}\,|\Phi_0\rangle|^2\delta[\omega-(E_n-E_0)]$$

- the local density of states of a discrete spectrum is
$$\rho_{j,\sigma}(\omega) = \sum_n|\langle\Phi_n|\,C^\dagger_{j,\sigma}\,|\Phi_0\rangle|^2\delta[\omega-(E_n-E_0)]$$
- the imaginary part of $C_{jj,\sigma}(\omega+i\eta)$ provides the local density of states
$$\rho_{j,\sigma}(\omega) = -\frac{1}{\pi}\lim_{\eta\to0^+}\mathrm{Im}C_{jj,\sigma}(\omega+i\eta)$$

图 21: 幻灯片第 21 页

这一页写了什么

- 从局域关联函数出发
$$C_{jj,\sigma}(\omega+i\eta) = \left\langle\Phi_0\middle|c_{j,\sigma}\frac{1}{\omega+i\eta-H+E_0}c^\dagger_{j,\sigma}\middle|\Phi_0\right\rangle$$
$$= \sum_{mn}\langle\Phi_0|c_{j,\sigma}|\Phi_m\rangle\langle\Phi_m|\frac{1}{\omega+i\eta-H+E_0}|\Phi_n\rangle\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle$$
$$= \sum_n\frac{\left|\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle\right|^2}{\omega-(E_n-E_0)+i\eta}$$
- 利用恒等式
$$\lim_{\eta\to0^+}\frac{1}{\omega-\epsilon\pm i\eta} = \mathcal{P}\left(\frac{1}{\omega-\epsilon}\right)\mp i\pi\delta(\omega-\epsilon),$$
（$\mathcal{P}$ 表示主值）我们得到
$$\lim_{\eta\to0^+}\mathrm{Im}\,C_{jj,\sigma}(\omega+i\eta) = \left(\lim_{\eta\to0^+}C_{jj,\sigma}(\omega+i\eta) - \lim_{\eta\to0^+}C^\dagger_{jj,\sigma}(\omega+i\eta)\right)\Big/(2i)$$
$$= -\pi\sum_n\left|\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle\right|^2\delta[\omega-(E_n-E_0)]$$
- **离散谱的局域态密度**是
$$\rho_{j,\sigma}(\omega) = \sum_n\left|\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle\right|^2\delta[\omega-(E_n-E_0)]$$

- $C_{jj,\sigma}(\omega+i\eta)$ 的虚部给出局域态密度

$$\rho_{j,\sigma}(\omega)=-\frac{1}{\pi}\lim_{\eta\to 0^+}\operatorname{Im}C_{jj,\sigma}(\omega+i\eta)$$

要点展开

（1）第一步：插入完备性关系。

关键是插入两组完备性关系 $\sum_m|\Phi_m\rangle\langle\Phi_m|=\mathbb{1}$ 和 $\sum_n|\Phi_n\rangle\langle\Phi_n|=\mathbb{1}$：

$$\langle\Phi_0|c_{j,\sigma}\frac{1}{\omega+i\eta-H+E_0}c_{j,\sigma}^\dagger|\Phi_0\rangle=\sum_{mn}\langle\Phi_0|c_{j,\sigma}|\Phi_m\rangle\underbrace{\langle\Phi_m|\frac{1}{\omega+i\eta-H+E_0}|\Phi_n\rangle}_{\text{对角：}\ \frac{\delta_{mn}}{\omega+i\eta-(E_n-E_0)}}\langle\Phi_n|c_{j,\sigma}^\dagger|\Phi_0\rangle.$$

由于 $|\Phi_m\rangle$ 是 H 的本征态（$H|\Phi_m\rangle=E_m|\Phi_m\rangle$），那个 resolvent 的矩阵元是**对角的**：

$$\langle\Phi_m|\frac{1}{\omega+i\eta-H+E_0}|\Phi_n\rangle=\frac{\delta_{mn}}{\omega+i\eta-(E_n-E_0)}.$$

于是双重求和坍缩成单重求和，得到幻灯片第三行的结果。

> **这个”坍缩”是本页的关键**：它把 $\frac{1}{\omega+i\eta-H+E_0}$ 这个**算符**变成了**数** $\frac{1}{\omega+i\eta-(E_n-E_0)}$，于是整个表达式变成”若干个洛伦兹峰的叠加”。**这正是谱函数的 Lehmann 表示。**

（2）第二步：用 $\eta\to 0^+$ 的恒等式取虚部。

$$\frac{1}{\omega-\epsilon\pm i\eta}\xrightarrow{\eta\to 0^+}\mathcal{P}\Big(\frac{1}{\omega-\epsilon}\Big)\mp i\pi\delta(\omega-\epsilon).$$

这是**索霍茨基–普莱梅利公式**（Sokhotski–Plemelj formula）。关键在于：**只有 $-i\pi\delta$ 这一项是纯虚的**，主值部分是实的。所以取虚部就只剩下 δ 函数：

$$\operatorname{Im}\Big[\frac{1}{\omega-\epsilon+i\eta}\Big]=-\pi\delta(\omega-\epsilon).$$

幻灯片里那个 $-\frac{1}{\pi}\mathrm{Im}$ 前面的负号，正是用来抵消这里的 $-\pi$，使得**谱函数是正的**（态密度必须非负）。

（3）Lehmann 表示：谱函数的物理内容。

$$\boxed{\rho_{j,\sigma}(\omega)=\sum_n\big|\langle\Phi_n|c_{j,\sigma}^\dagger|\Phi_0\rangle\big|^2\delta[\omega-(E_n-E_0)]}$$

这个式子包含了全部物理：

因子	含义
E_n-E_0	**峰的位置**：在格点 j、自旋 σ 上**添加一个电子**所需的能量
$\lvert\langle\Phi_n\lvert c_{j,\sigma}^\dagger\rvert\Phi_0\rangle\rvert^2$	**峰的权重**：这个激发在探针下的”可见度”

因子	含义
δ 函数	离散谱（有限尺寸）的**理想**线形

三个重要推论：

- **总权重 $=\mathbf{1}$**：由
$$\int \rho_{j,\sigma}(\omega)\,d\omega = \sum_n \left|\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle\right|^2 = \langle\Phi_0|c_{j,\sigma}c^\dagger_{j,\sigma}|\Phi_0\rangle = 1-\langle\Phi_0|n_{j,\sigma}|\Phi_0\rangle.$$
这就是**求和规则**（sum rule），一个必须做的校检。

  注意：权重之和不是 1，而是 $1-\langle n_{j,\sigma}\rangle$！当格点被占据时（$\langle n\rangle=1$），加法谱的权重为 0——**你不能往一个已经满了的格点上再加电子**（泡利阻塞）。这解释了第 25 页为什么"加法谱"和"减法谱"的权重各为 N（半满时）。

- **只有"有重叠"的激发才可见**：若 $\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle=0$（例如对称性禁戒），这个态**不出现**在谱里。所以谱是**投影过的**能谱，不是完整能谱。
- **离散 δ 峰是有限尺寸的产物**：真实系统（$N\to\infty$）的谱是连续的。第 25、26 页用 η 把 δ 抹成洛伦兹峰，就是为了"模拟"连续谱。

(4)"局域"（local）的含义。

下标 jj 表示**同一个格点** j。所以 $\rho_{j,\sigma}$ 只探测格点 j。这与**动量分辨**的谱函数 $A(k,\omega)$（第 28 页）相对：后者要**先做傅里叶变换**到动量空间：
$$A(k,\omega)\propto\sum_{ij}e^{ik(i-j)}\langle\Phi_0|c_i\frac{1}{\omega+i\eta-H+E_0}c^\dagger_j|\Phi_0\rangle.$$

两者的关系：$A(k,\omega)=\sum_j\rho_{j,\sigma}$ 的傅里叶变换（更准确说是空间关联函数的变换）。**第 21–26 页用局域的 $\rho_{j,\sigma}$，第 28 页用 $A(k,\omega)$。**

提示 / 易错

- **恒等式里的 $\mp$ 号方向极易搞错**：$\frac{1}{\omega-\epsilon+i\eta}$ 对应 $-i\pi\delta$，$\frac{1}{\omega-\epsilon-i\eta}$ 对应 $+i\pi\delta$。幻灯片用 $\pm i\eta$ 统一写，阅读时要注意**同序配对**（上面取上号）。
- **$C^\dagger_{jj,\sigma}$ 是 $C_{jj,\sigma}$ 的厄米共轭**。幻灯片里第二个等号用了 $\mathrm{Im}\,C=(C-C^\dagger)/(2i)$。对厄米算符的期望值，$C^\dagger$ 就是复共轭，所以 $\mathrm{Im}\,C=(C-C^*)/(2i)$ ——**这是标准的"虚部"定义**。
- **$\mathcal{P}$（主值）不能丢**。它在实数轴上定义了"绕过极点"的方式。在数值计算中，因为 η 是有限的（不取极限），主值部分**自动被洛伦兹函数的实部包含**，不需要单独处理。这就是有限 η 让计算变简单的地方。
- **δ 峰是"理想化"的**。实际计算（有限 η）给的是
$$\rho_{j,\sigma}(\omega)=\sum_n|\langle\Phi_n|c^\dagger_{j,\sigma}|\Phi_0\rangle|^2\frac{1}{\pi}\frac{\eta}{(\omega-(E_n-E_0))^2+\eta^2}.$$
每个 δ 变成一个洛伦兹峰，峰高 $\propto 1/\eta$、总权重不变。这解释了"η 越小峰越尖、但积分不变"。
- **谱函数必须非负**：$\rho_{j,\sigma}(\omega)\geq 0$。如果算出负值，说明代码有 bug（或者 η 太大导致数值误差）。**这是一条有用的校检。**—

第 22 页 · 谱函数

Spectral function

- local density of states

$$\rho_{j,\sigma}(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}C_{jj,\sigma}(\omega+i\eta) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}\langle\Phi_0|\,C_{j,\sigma}\frac{1}{\omega+i\eta-H+E_0}C^\dagger_{j,\sigma}|\,\Phi_0\rangle$$

- density of states $\rho(\omega)=\sum_{j,\sigma}\rho_{j,\sigma}(\omega)$

- in general, the spectral function is given by

$$I(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}C(\omega+i\eta) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\{\mathrm{Im}[\langle\Phi_0|A\frac{1}{\omega+i\eta-H+E_0}A^\dagger|\,\Phi_0\rangle]\}$$

- spectral function can be probed in scattering experiments such as photoemission or neutron scattering

name	notation	operators	experiment
single-particle spectral weight	$A(\mathbf{k},\omega)$	$A=c_{\mathbf{k},\sigma}$	photoemission
structure factor	$S_{zz}(\mathbf{q},\omega)$	$A=S^z_{\mathbf{q}}$	neutron scattering
optical conductivity	$\sigma_{xx}(\omega)$	$A=j_x$	optics
4-spin correlation	$R(\omega)$	$A=\sum_{\mathbf{k}}R_{\mathbf{k}}\mathbf{S}_{\mathbf{k}}\cdot\mathbf{S}_{-\mathbf{k}}$	Raman scattering

图 22: 幻灯片第 22 页

这一页写了什么

- **局域态密度**

$$\rho_{j,\sigma}(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}\,C_{jj,\sigma}(\omega+i\eta) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}\left\langle\Phi_0\middle|c_{j,\sigma}\frac{1}{\omega+i\eta-H+E_0}c^\dagger_{j,\sigma}\middle|\Phi_0\right\rangle$$

- **态密度**

$$\rho(\omega)=\sum_{j,\sigma}\rho_{j,\sigma}(\omega)$$

- **一般地，谱函数由下式给出**

$$I(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\mathrm{Im}\,C(\omega+i\eta) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\left\{\mathrm{Im}\left[\langle\Phi_0|A\frac{1}{\omega+i\eta-H+E_0}A^\dagger|\Phi_0\rangle\right]\right\}$$

  （幻灯片用**红框**圈出）
- 谱函数可以在**散射实验**中被测量，例如**光电子发射**（photoemission）或**中子散射**（neutron scattering）。

页面底部有一个**四种探针对照表**：

name（名称）	notation（记号）	operators（算符）	experiment（实验）
single-particle spectral weight（单粒子谱权重）	$A(\mathbf{k},\omega)$	$A = c_{\mathbf{k},\sigma}$	photoemission（光电子发射）
structure factor（结构因子）	$S_{zz}(\mathbf{q},\omega)$	$A = S^z_{\mathbf{q}}$	neutron scattering（中子散射）
optical conductivity（光电导）	$\sigma_{xx}(\omega)$	$A = j_x$	optics（光学）
4-spin correlation（四自旋关联）	$R(\omega)$	$A = \sum_{\mathbf{k}} R_{\mathbf{k}} \mathbf{S}_{\mathbf{k}} \cdot \mathbf{S}_{-\mathbf{k}}$	Raman scattering（拉曼散射）

要点展开

（1）从”局域”到”总”：为什么直接求和就够。

$$\rho(\omega) = \sum_{j,\sigma} \rho_{j,\sigma}(\omega).$$

注意这里没有权重因子——它是**字面的求和**，不是平均。所以半满时的总权重是 $\sum_{j,\sigma}(1 - \langle n_{j,\sigma}\rangle)$。

> **一个重要的实践细节**：如果系统有**平移对称性**（例如环上的非简并基态），那么所有格点等价，理论上**只算一个格点再乘** N 就够了。**但当基态简并时，这个捷径会出错**（见下）。更微妙的是：**求和**（$\sum_j$）永远是对的，而”一格点 $\times N$“只有在格点等价时才成立。**稳妥的做法是直接求和**——参考实现就是这么做的。

（2）一般形式：$I(\omega)$ 与算符 A 的关系。

$$I(\omega) = -\frac{1}{\pi} \lim_{\eta \to 0^+} \mathrm{Im} \left\langle \Phi_0 \middle| A \frac{1}{\omega + i\eta - H + E_0} A^\dagger \middle| \Phi_0 \right\rangle.$$

这个公式的美妙之处在于”换一个算符就换一种实验”。底部那张表就是这句话的展开：

你选 A	得到的谱	对应的实验
$c_{\mathbf{k},\sigma}$	单粒子谱 $A(\mathbf{k},\omega)$	ARPES / IPES
$S^z_{\mathbf{q}}$	结构因子 $S_{zz}(\mathbf{q},\omega)$	中子散射
j_x（电流）	光电导 $\sigma_{xx}(\omega)$	光学测量
$\sum_{\mathbf{k}} R_{\mathbf{k}} \mathbf{S}_{\mathbf{k}} \cdot \mathbf{S}_{-\mathbf{k}}$	四自旋关联 $R(\omega)$	拉曼散射

> **本讲的计算全部围绕第一行**（$A = c_{j,\sigma}$，即单粒子谱）。但方法对其它三行**完全一样**——只要你能算 $A|\Phi_0\rangle$ 和 H 的矩阵–矢量乘。这是本讲方法的通用性所在。

（3）为什么谱函数”可以在散射实验中测量”——物理图像。

以 ARPES 为例：

1. 一束光子打入样品，**打出一个电子**（所以叫 photo**emission**）；
2. 测量这个逃逸电子的**动能**和**动量**；

3. 由能量守恒，电子在固体里原来的能量 = 测到的动能 + 功函数 − 光子能量；
4. 由动量守恒（在平行于表面的方向），得到它在固体里的**动量 k**。

测到的强度正比于 $A(\mathbf{k},\omega)f(\omega)$（$f$ 是费米分布，因为只有占据态能被打出）。**所以 ARPES 直接测的就是谱函数。**

> **这正是 ED + Lanczos 的用武之地**：它是**少数能从第一性原理算出** $A(k,\omega)$**、并与 ARPES 直接对比**的方法。第 28 页的 TTF-TCNQ 就是这样的例子。

(4) $\rho(\omega)$ **与** $A(\mathbf{k},\omega)$ **的记号关系。**

教材里这两者有时混用，本讲的用法是：

记号	范围	用法
$\rho_{j,\sigma}(\omega)$	**局域**（实空间，格点 j）	第 21、25、26 页
$\rho(\omega)=\sum_{j,\sigma}\rho_{j,\sigma}$	**总**（求和后）	第 22、25 页
$A(\mathbf{k},\omega)$	**动量分辨**	第 28 页
$I(\omega)$	**一般的谱函数**（任意算符 A）	本页

它们的本质是同一个东西（resolvent 的虚部），只是"怎么取矩阵元"不同。

(5) 一个必须记住的"陷阱"：权重不是 1。

由第 21 页的求和规则：

$$\int \rho_{j,\sigma}(\omega)\,d\omega = 1-\langle n_{j,\sigma}\rangle.$$

半满时 $\langle n_{j,\sigma}\rangle = 1/2$，所以**每个** $\rho_{j,\sigma}$ 的积分是 $1/2$；对 j 求和（N 个格点）后是 $N/2$；再对 σ 求和（2 个自旋）后是 N。

> **总权重** $= N$**（半满）**，这正是第 25 页要校检的量（$N=8$ 时应得 $w_{\rm add}=w_{\rm rem}=8$）。**注意这里只算了一支（加法或减法）**——因为 $\rho_{j,\sigma}$ 只含 $c^\dagger$（加法）。要得到减法谱，需要把算符换成 c（见下）。

(6) 加法谱与减法谱：完整图像。

本页的公式用的是 $A=c^\dagger_{j,\sigma}$（加法），得到"往系统里**加**一个电子"的谱。但实验上还有另一半："从系统里**拿走**一个电子"（ARPES）。

谱	算符	极点在	对应实验
加法（addition）	$c^\dagger_{j,\sigma}$	$E_n(N+1)-E_0(N)$	IPES（逆光电子谱）
减法（removal）	$c_{j,\sigma}$	$E_0(N)-E_m(N-1)$	ARPES（光电子谱）

总态密度是两者之和：$\rho(\omega)=\rho^{\rm add}(\omega)+\rho^{\rm rem}(\omega)$。**第 25、26 页的图正是两条谱叠在一起**（$U=0$ 时它们关于 $\omega-\mu=0$ 对称）。

提示 / 易错

- **注意减法谱的极点符号**：是 $E_0(N) - E_m(N-1)$（**正**的量，因为 $E_0(N) < E_m(N-1)$ 通常成立——拿走一个电子要花能量）。写代码时若把符号搞错，谱会**镜像反转**（左右对调），但**总权重仍然守恒**，所以求和规则抓不到这个错误。**必须用 $U = 0$ 的解析基准来抓**（这就是作业里那条校检的作用）。
- $A(\mathbf{k}, \omega)$ **里的 k 是动量**，不是第 20 页的算符 A！同一讲里用了同一个字母表示两个不同的东西：
  - 第 20–22 页：A = **算符**（如 $c_{j,\sigma}$）；
  - 第 22 页表格、第 28 页：$A(\mathbf{k}, \omega)$ = **谱函数**（一个数）。**读的时候要靠上下文区分**，这是原文献的记号习惯。
- $\eta \to 0^+$ **在数值上不能真的取** 0：取 0 会得到 δ 函数，无法在有限网格上表示。实践上取 $\eta \sim 0.1t$，并且要检查"η 减半后谱形是否稳定"（除峰宽外）。
- 表格里的 $\sigma_{xx}(\omega)$ 用的是**光电导的实部**（耗散部分），这也符合"谱函数 = 响应函数的虚部"的一般模式。—

第 23 页 · 用 Lanczos 计算谱函数

Spectral function using Lanczos

- we are interested in calculating quantities such as

$$I(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\{\mathrm{Im}[\langle\Phi_0|A^\dagger\frac{1}{\omega+i\eta-H+E_0}A|\Phi_0\rangle]\} = -\frac{1}{\pi}\lim_{\eta\to 0^+}\{\mathrm{Im}[\langle\Psi_0|\frac{1}{z-H}|\Psi_0\rangle]\}$$

where $|\Psi_0\rangle = A|\Phi_0\rangle$, and $z = \omega + i\eta + E_0$

we normalize $|\Psi_0\rangle$ into $|\phi_0\rangle = |\Psi_0\rangle/\alpha$, where $\langle\Psi_0|\Psi_0\rangle = \alpha^2$

- we restart from $|\phi_0\rangle$ to construct a new Krylov space

z - H can be written in a tridiagonal form

$$z-H = \begin{pmatrix} z-a_0 & -b_0 & 0 & \cdots & 0 \\ -b_0 & z-a_1 & -b_1 & \ddots & \vdots \\ 0 & -b_1 & z-a_2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & -b_{n-1} \\ 0 & \cdots & 0 & -b_{n-1} & z-a_n \end{pmatrix}$$

- the (0,0) element of the inverse of the above matrix gives $\langle\phi_0|\frac{1}{z-H}|\phi_0\rangle$

图 23: 幻灯片第 23 页

这一页写了什么

- 我们感兴趣的是计算形如

$$I(\omega) = -\frac{1}{\pi}\lim_{\eta\to 0^+}\left\{\mathrm{Im}\left[\langle\Phi_0|A^\dagger\frac{1}{\omega+i\eta-H+E_0}A|\Phi_0\rangle\right]\right\} = -\frac{1}{\pi}\lim_{\eta\to 0^+}\left\{\mathrm{Im}\left[\langle\Psi_0|\frac{1}{z-H}|\Psi_0\rangle\right]\right\}$$

的量，其中 $|\Psi_0\rangle = A|\Phi_0\rangle$，且 $z = \omega + i\eta + E_0$。

- 我们把 $|\Psi_0\rangle$ **归一化**为 $|\phi_0\rangle = |\Psi_0\rangle/\alpha$，其中 $\langle\Psi_0|\Psi_0\rangle = \alpha^2$。（幻灯片用**红框**圈出这一步）
- 我们**从** $|\phi_0\rangle$ **重启**，构造一个新的 **Krylov 空间**。$z - H$ 可以写成三对角形式

$$z - H = \begin{pmatrix} z-a_0 & -b_0 & 0 & \cdots & 0 \\ -b_0 & z-a_1 & -b_1 & \ddots & \vdots \\ 0 & -b_1 & z-a_2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & -b_{n-1} \\ 0 & \cdots & 0 & -b_{n-1} & z-a_n \end{pmatrix}$$

- 上面矩阵的逆的 $(0,0)$ 元给出 $\langle\phi_0|\frac{1}{z-H}|\phi_0\rangle$。

要点展开

（1）这一页是”两次 Lanczos”的连接点——本讲最关键的结构。

对比第 21 页与本页：

	第 21 页	第 23 页
目标	求 $\rho_{j,\sigma}(\omega)$	求 $I(\omega)$
resolvent	$\frac{1}{\omega+i\eta-H+E_0}$	$\frac{1}{z-H}$，$z = \omega + i\eta + E_0$
起始矢量	$c^\dagger_{j,\sigma}\|\Phi_0\rangle$ **未归一化**	$A\|\Phi_0\rangle$ **归一化**为 $\|\phi_0\rangle$
手段	插入完备性、Lehmann 展开	**对 H 做 Lanczos、得到 T**

核心思路：Lehmann 展开（第 21 页）需要对 H **完整对角化**才能算出（因为要求和所有 $|\Phi_n\rangle$）。**Lanczos 让我们不用完整对角化**：只需构造一个新 Krylov 空间（起点是 $|\phi_0\rangle$），在这个子空间里 H 就是三对角矩阵 T。

> **注意这里是”新”的 Krylov 空间**：我们**先**算基态（那是第一次 Lanczos），**再**从 $|\phi_0\rangle$ 出发**第二次** Lanczos。幻灯片用“we **restart** from $|\phi_0\rangle$”强调这一点。

（2）为什么必须归一化，以及 α^2 为什么必须乘回来。

这是本讲**最容易出错**的地方。仔细看：

$$|\Psi_0\rangle = A|\Phi_0\rangle, \qquad \alpha^2 = \langle\Psi_0|\Psi_0\rangle, \qquad |\phi_0\rangle = |\Psi_0\rangle/\alpha.$$

于是

$$\langle\Psi_0|\frac{1}{z-H}|\Psi_0\rangle = \alpha^2\,\langle\phi_0|\frac{1}{z-H}|\phi_0\rangle.$$

为什么必须归一化？ 因为 Lanczos 递推要求起始矢量归一化（第 8 页：“start from an arbitrary **normalized** state”）。不归一化递推就不成立（a_0 和 b_0 的定义都依赖归一化）。

为什么 α^2 必须乘回来？ 因为 α^2 是**归一化之外的权重因子**。Lanczos 只能告诉你 $|\phi_0\rangle$ 上的矩阵元；而物理上要的是 $|\Psi_0\rangle$ 上的，两者差一个 α^2。

漏掉 α^2 的症状：谱形完全正确，只是整条曲线的幅度乘错一个常数。这是最阴险的一类 bug——曲线看起来"很像"，峰位全对，只有绝对幅度错。**而幅度正是被求和规则（第 21 页）约束的量**：$\int \rho\, d\omega$ 必须等于 $1 - \langle n \rangle$（按 $\alpha^2 = \|\Psi_0\|^2$ 算）。所以**求和规则校检是抓这个 bug 的唯一办法**。

（3）$z - H$ 的三对角形式：注意负号。

$$z - H = \begin{pmatrix} z - a_0 & -b_0 & & & \\ -b_0 & z - a_1 & -b_1 & & \\ & -b_1 & z - a_2 & \ddots & \\ & & \ddots & \ddots & -b_{n-1} \\ & & & -b_{n-1} & z - a_n \end{pmatrix}$$

关键观察：- **对角元**是 $z - a_m$（因为 H 的对角元是 a_m）；- **非对角元是** $-b_m$（因为 H 的非对角元是 $+b_m$，而这里是 $z - H$，所以带上负号）。

这个负号在连分数里会"平方掉"因为连分数里用到的是 b_m^2，而 $(-b_m) \times (-b_m) = b_m^2$。所以最终的连分数形式是

$$\cfrac{1}{z - a_0 - \cfrac{b_0^2}{z - a_1 - \cfrac{b_1^2}{\ddots}}}$$

——**全是 b_m^2（正号）**。这解释了为什么第 24 页的连分数里没有显式的负号。

（4）为什么"逆的 $(0,0)$ 元"就够了。

我们要求的是 $\langle \phi_0 | \frac{1}{z-H} | \phi_0 \rangle$。在 Lanczos 基下，$|\phi_0\rangle$ 就是**第一个基矢** $\mathbf{e}_1 = (1, 0, \cdots, 0)^{\mathsf{T}}$。于是

$$\langle \phi_0 | \frac{1}{z - H} | \phi_0 \rangle = \mathbf{e}_1^{\mathsf{T}} \, (z - H)^{-1} \, \mathbf{e}_1 = \left[(z - H)^{-1} \right]_{00}.$$

所以只需要求逆矩阵的左上角一个元素！这是一个巨大的简化：不需要求整个逆矩阵（n^2 个元素），只要一个。

第 24 页就是专门算这个元素的——用分块矩阵求逆把它化成一个**连分数**。

（5）"重启"的两种含义（容易混淆）。

本讲里"restart"出现了两次，含义不同：

位置	含义
第 15 页 implicitly restarted	**算法层面**的重启（为控制正交性/内存）
第 23 页	**物理层面**的第二次 Lanczos：从 $A\|\Phi_0\rangle$ 出发，而不是从基态出发

第 23 页的重启不是为了提高精度，而是因为「我们问了一个不同的问题」：第一次 Lanczos 问"基态是什么"，第二次问"在基态上加一个电子后，系统如何响应"。

提示 / 易错

- $z = \omega + i\eta + E_0$ **的符号要小心。**因为

$$\frac{1}{\omega + i\eta - H + E_0} = \frac{1}{(\omega + i\eta + E_0) - H} = \frac{1}{z - H},$$

所以 z 里是 $+E_0$（不是 $-E_0$）。这个 $+E_0$ 保证了极点在 $E_n - E_0$（相对能量），而不是 E_n（绝对能量）。

- **减法谱要额外小心。**对减法（光电子）谱，习惯上取 $z = -\omega + i\eta + E_0$ 或等价地取 $\omega \to -\omega$。参考实现里的处理是：对减法取 $z = -\omega + i\eta + E_0$，并且 **把 η 保留为正**（否则会破坏解析性）。**这一步是作业里最容易出错的地方之一。**
- **起始矢量 $|\phi_0\rangle$ 一般不是任何本征态**，所以不会像第 9 页那样“$b_0 = 0$ 一步终止”。**这是谱函数计算能顺利进行的前提。**（反过来说：如果你不小心从**基态**出发做谱函数，会立刻终止——参考实现里专门保留了这个演示作为对照。）
- **注意 a_m, b_m 是”第二次”Lanczos 的系数，与第一次（算基态的）完全不同。**它们是 H 在 $\{A|\Phi_0\rangle\}$ 生成的 Krylov 空间里的投影。同一个 H、不同的起点 → 不同的 T。**不要复用第一次的 a_m, b_m。**

—

第 24 页 · 连分数：分块矩阵求逆

Spectral function using Lanczos

- the inverse of a block matrix is given by

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix}^{-1} = \begin{pmatrix} (A - BD^{-1}C)^{-1} & -(A - BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A - BD^{-1}C)^{-1} & D^{-1} + D^{-1}C(A - BD^{-1}C)^{-1}BD^{-1} \end{pmatrix}$$

- z - H satisfies the following relation

$$z - H = \left(\begin{array}{c|ccc} z - a_0 & -b_0 & 0 & \cdots & 0 \\ \hline -b_0 & z - a_1 & -b_1 & \ddots & \vdots \\ 0 & -b_1 & z - a_2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & -b_{n-1} \\ 0 & \cdots & 0 & -b_{n-1} & z - a_n \end{array}\right) = \begin{pmatrix} z - a_0 & B \\ C & z - H_1 \end{pmatrix}$$

- we can show that

$$[(z - H)^{-1}]_{00} = \frac{1}{z - a_0 - b_0^2[(z - H_1)^{-1}]_{00}} = \frac{1}{z - a_0 - \frac{b_0^2}{z - a_1 - b_1^2[(z - H_2)^{-1}]_{00}}}$$

$$= \frac{1}{z - a_0 - \cfrac{b_0^2}{z - a_1 - \cfrac{b_1^2}{z - a_2 - \cfrac{b_2^2}{\ddots}}}}$$

E. Dagotto, RMP 66 763 (1994)

图 24: 幻灯片第 24 页

这一页写了什么

- **分块矩阵的逆**由下式给出

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix}^{-1} = \begin{pmatrix} (A-BD^{-1}C)^{-1} & -(A-BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A-BD^{-1}C)^{-1} & D^{-1}+D^{-1}C(A-BD^{-1}C)^{-1}BD^{-1} \end{pmatrix}$$

- $z-H$ **满足下面的关系**（把第一行/列分开，右下角蓝色高亮的部分是 $z-H_1$）

$$z-H = \left(\begin{array}{c|cccc} z-a_0 & -b_0 & 0 & \cdots & 0 \\ \hline -b_0 & z-a_1 & -b_1 & & \vdots \\ 0 & -b_1 & z-a_2 & \ddots & 0 \\ \vdots & & \ddots & \ddots & -b_{n-1} \\ 0 & \cdots & 0 & -b_{n-1} & z-a_n \end{array}\right) = \begin{pmatrix} z-a_0 & B \\ C & \boxed{z-H_1} \end{pmatrix}$$

- 我们可以证明

$$\big[(z-H)^{-1}\big]_{00} = \frac{1}{z-a_0-b_0^2\big[(z-H_1)^{-1}\big]_{00}} = \frac{1}{z-a_0-\dfrac{b_0^2}{z-a_1-b_1^2\big[(z-H_2)^{-1}\big]_{00}}} = \frac{1}{z-a_0-\dfrac{b_0^2}{z-a_1-\dfrac{b_1^2}{z-a_2-\cdots}}}$$

幻灯片右下角给出文献：**E. Dagotto, RMP 66, 763 (1994)**。

要点展开

(1) 分块求逆公式的用法：只取左上角。

分块矩阵公式里，左上角是 $(A-BD^{-1}C)^{-1}$。在我们的情形：

$$A = z-a_0 \quad (\text{一个数}), \qquad B = (-b_0,\ 0,\ \cdots,\ 0) \quad (\text{一行}),$$

$$C = (-b_0,\ 0,\ \cdots,\ 0)^{\mathsf{T}} \quad (\text{一列}), \qquad D = z-H_1.$$

于是

$$A-BD^{-1}C = (z-a_0)-(-b_0)\big[(z-H_1)^{-1}\big]_{00}(-b_0) = z-a_0-b_0^2\big[(z-H_1)^{-1}\big]_{00}.$$

取逆即得

$$\big[(z-H)^{-1}\big]_{00} = \frac{1}{z-a_0-b_0^2\big[(z-H_1)^{-1}\big]_{00}}.$$

这就是第一次”剥皮” $n\times n$ 的问题变成了 $(n-1)\times(n-1)$ 的问题。

(2) 递归下去就得到连分数。

对 $z-H_1$ 重复同样的操作（它的左上角是 $z-a_1$，第一行/列是 $-b_1$），得到

$$\big[(z-H_1)^{-1}\big]_{00} = \frac{1}{z-a_1-b_1^2\big[(z-H_2)^{-1}\big]_{00}}.$$

代入即得幻灯片第二个等号。继续下去：

$$\boxed{\big[(z-H)^{-1}\big]_{00} = \cfrac{1}{z-a_0-\cfrac{b_0^2}{z-a_1-\cfrac{b_1^2}{z-a_2-\cdots}}}}$$

注意所有的负号都消失了：$(-b_m)\times(-b_m)=+b_m^2$。所以连分数里**只有 b_m^2（正数）**——这就是第 23 页那个负号"平方掉"的后果。

(3) 这个连分数为什么是"递归"的——计算顺序。

连分数是**嵌套**结构：

$$g_0=\frac{1}{z-a_0-b_0^2\,g_1},\qquad g_1=\frac{1}{z-a_1-b_1^2\,g_2},\qquad \cdots$$

注意 g_0 依赖 g_1，g_1 依赖 g_2，……所以计算必须**从最深层开始**。设用到 $a_0,\dots,a_M$ 与 $b_0,\dots,b_{M-1}$（即 T 是 $(M+1)\times(M+1)$ 的，连分数里出现了 b_{M-1}^2），则

$$g_M=\frac{1}{z-a_M},\qquad g_m=\frac{1}{z-a_m-b_m^2\,g_{m+1}},\qquad m=M-1,\ M-2,\ \cdots,\ 0.$$

最深层怎么初始化？两种写法相差整整一层，必须分清：

- **(i) 用上 a_M**：显式初始化 $g_M=\dfrac{1}{z-a_M}$，再往回迭代 $m=M-1,\dots,0$。
- **(ii) 把 g 的初值取 0、循环里对每个 m（含 $m=M$）都用同一个公式**：$g\leftarrow 1/(z-a_m-b_m^2 g)$。因为第 M 层的 b_M 不存在（约定 $b_M=0$），最深层自动退化为 $g_M=1/(z-a_M)$——**与 (i) 完全等价**。

真正要避免的是"差一层"(off-by-one)：写成"$g_M=0$，然后从 $m=M-1$ 迭代到 0"，就等于**丢掉了 a_M 那一层**，只用 T 的左上 $M\times M$ 子块求逆。用本课程参考实现记录的 8 个 a_m,b_m 实测（$z=5+0.11i$）：

写法	用到的层数	与精确 8×8 逆的偏差
(i)/(ii)，从 $g_7=1/(z-a_7)$ 起	8	1.1×10^{-16}
差一层，从 $g_7=0$ 起（只用到 $a_0..a_6$）	7	3.5×10^{-1}

结论：两种写法本身都没错，**错的是层数与 M 不一致**。说"截断到第 M 层"就必须把第 M 层的 a_M 用上；想少用一层应当把 M 减小 1，而不是把最深层置零。（这也解释了为什么"$g_M=0$"看起来无害、实际会带来 $O(1)$ 偏差：它悄悄少算了一层，而不是省掉一个可忽略的小量。）**本课程参考实现用的是 (i) 的显式形式。**

这就是"反向递归"(backward recursion)。

> **本讲最重要的实现陷阱**：如果写成**正向**循环
>
> ```
> g = 0
> for m in range(len(a)):            # 错：从浅层迭代到深层
>     g = 1/(z - a[m] - b[m]**2 * g)
> ```
>
> 它算的**不是**正确的 $[(z-H)^{-1}]_{00}$：它等价于 **把系数顺序整个反过来**（$a_M,\dots,a_0$ 配 $b_M,\dots,b_1$）之后同一个连分数的值，即**另一个三对角矩阵**的 00 元。极点位置会系统性漂移（实测最大漂移 0.567，在 $z=-1.3+0.11i$ 处甚至连符号都反了），**谱是错的**。

它的报错行为取决于 b 的长度约定：若 b 比 a 短一个（即 `len(b) == len(a)-1`，本课程参考实现与多数教材的约定），上面的循环会在 `m = len(a)-1` 处抛 `IndexError`——**这反而是幸运的**，因为错误立刻暴露。若 b 与 a 等长（或补了 $b_M = 0$），它就**静默**给出错误结果，不报错、不产生 `nan`、不变复数。**后者才是危险的**，只能靠 $U = 0$ 解析基准抓出来。

正确写法（两种等价形式，注意**最深层一定要用上** a_M）：

```
M = len(a) - 1                    # T 是 (M+1)x(M+1)，用到 b_0..b_{M-1}
g = 1.0/(z - a[M])                # 最深层：1/(z - a_M)，不是 0！
for m in range(M-1, -1, -1):
    g = 1.0/(z - a[m] - b[m]**2 * g)
```

或者（约定 $b_M = 0$，让最深层自动退化）：

```
g = 0.0
for m in range(M, -1, -1):        # 含 m = M
    bm = b[m] if m < len(b) else 0.0
    g = 1.0/(z - a[m] - bm**2 * g)
```

注意 `range` 的起点：若写成 `range(M-1, -1, -1)` 且把 g 初始化成 0，就把 a_M 那一层丢掉了，偏差达 $O(1)$（实测 3.5×10^{-1}）。

(4) 连分数的收敛性：什么时候可以截断。

第 26 页会详细展示"增加 Krylov 维度 L"的效果。这里先给关键结论：

- z **离能谱越远，收敛越快**。因为此时 $\frac{1}{z-H}$ 变化平缓，用少数的矩（moments）就能刻画。
- z **落在能谱密集处，收敛越慢**。此时 resolvent 变化剧烈，需要很多 Krylov 矢量。

本课程参考实现的实测数据（$N = 8$、$U = 4$ Hubbard，$(4, 4)$ 块，维度 4900，从 $\mathbf{e}_1$ 出发做 Lanczos）：

z	实部半径 0.5 内的能级数	Lanczos 50 步	100 步	200 步	400 步
$0.7 + 0.11i$	124	1.2×10^{-6}	5.2×10^{-8}	3.0×10^{-15}	1.4×10^{-17}
$-1.3 + 0.11i$	46	2.6×10^{-9}	2.1×10^{-17}	6.9×10^{-18}	6.9×10^{-18}
$5 + 0.11i$	325	2.3×10^{-3}	2.2×10^{-4}	3.3×10^{-5}	3.7×10^{-8}
$-10 + 0.11i$	0	2.7×10^{-20}	2.7×10^{-20}	2.7×10^{-20}	2.7×10^{-20}
$25 + 0.11i$	0	2.2×10^{-19}	2.2×10^{-19}	2.2×10^{-19}	2.2×10^{-19}

（表中的数是连分数与直接求解 $(z - H)x = \mathbf{e}_1$ 的偏差。）

读数：- z 在谱**外**（-10、25）：**几步就到机器精度**（$\sim 10^{-20}$）。- z 在谱**内稀疏处**（-1.3）：50 步就很好。- z 在谱**内最密处**（5，实部半径 0.5 内有 325 个能级）：**400 步才到** 10^{-8}。- 本块的谱跨度是 $[-4.6035,\ 20.6035]$——**注意** $5 + 0.11i$ **是谱内最密处之一**。

"能级数"怎么数：参考实现数的是 $\{|E_n - \mathrm{Re}\, z| < 0.5\}$（只比**实部**）。若改成比复距离 $|E_n - z|$，同一批 z 给出的数会略小（例如 $z = 5 + 0.11i$ 变成 319）。**两者都合理，关键是表里的数和代码里的判据要一致**；结论（z 附近能级越多、收敛越慢）不随这个细节改变。

> η **在这里的作用**：谱函数取 $z=\omega+i\eta+E_0$，$\eta=0.11$ 把 z 推离实轴。**正是这个有限的 η 使得有限步数足够**。若取 $\eta\to 0^+$（比如 10^{-6}），同样的步数会差得多——因为那时 z 几乎落在实轴上，resolvent 出现尖锐的极点结构。

（5）Dagotto 1994 这篇综述的地位。

Elbio Dagotto 的 "*Correlated electrons in high-temperature superconductors*", *Rev. Mod. Phys.* **66**, 763 (1994)，是**用 ED + Lanczos 研究强关联电子系统**的经典综述。它系统总结了：

- 怎么用 Lanczos 算基态和低激发态；
- 怎么用连分数算各种谱函数（单粒子谱、自旋谱、光电导）；
- 怎么处理有限尺寸效应。

本讲第 21–28 页的内容基本都在这篇综述里，推荐作为深入阅读。

> 顺带一提：Dagotto 也是**相分离**（phase separation）与**条纹相**（stripe）在 Hubbard/t–J 模型中研究的先驱——这与第 30 页的条纹电荷密度工作在物理问题上有直接联系。

提示 / 易错

- **连分数的层数 = Lanczos 步数**。"截断在第 M 层"等价于"用 M 步 Lanczos"。所以第 26 页说" increasing the dimension of the Krylov space from 5 to 100"就是在说连分数的层数从 5 增加到 100。
- b_m^2 **而不是** b_m。这是最常见的抄写错误。若误写成 b_m，连分数的量纲都不对（b 有能量量纲，b^2 才有能量平方，与分母 $z-a$ 的量纲匹配）。**量纲检查是一个快速的自检手段。**
- **分块求逆公式里的 $A-BD^{-1}C$ 是 Schur 补**（Schur complement）。这个名字在数值线性代数里很重要（第 3 页的 `eigs` 里 `sigma` 参数用的 shift-invert 就涉及它）。见到这个名字不必陌生。
- **连分数在复平面上的解析性**：因为 $\eta>0$，z 落在复平面的上半平面，分母 $z-a_m-b_m^2 g_{m+1}$ **不会为零**（极点都在实轴上）。所以连分数在计算过程中**永不发散**。这是 $\eta>0$ 的另一个好处。
- **递归的深度与数值稳定性**：很深的连分数（M 很大）会有累积舍入误差。但由于每层都是"分母加上正数 $b_m^2 g_{m+1}$"，通常稳定。实践中 $M=100\sim 400$ 是常见范围。
- **最后一个 a_M 必须用上（最常见的 off-by-one）**。最深层的初始化是 $g_M=\dfrac{1}{z-a_M}$。若写成"$g_M=0$"再从 $m=M-1$ 往下迭代，等于丢掉 a_M 那一层、只用左上 $M\times M$ 子块，会带来 $O(1)$ 偏差（实测 3.5×10^{-1}，见本页推导部分）。想少用一层就减小 M，而**不是**把最深层置零。
- **两种等价的写法**：(i) 显式初始化 $g_M=1/(z-a_M)$ 再往回循环；
  (ii) 从 $g=0$ 开始，对**每个** m（含 $m=M$）都用同一个公式 $g\leftarrow 1/(z-a_m-b_m^2 g)$，并约定 $b_M=0$——这样最深层自动退化为 $g_M=1/(z-a_M)$。**本课程参考实现用的是 (i) 的显式形式**；两者数值完全一致。—

第 25 页 · 态密度：一维 Hubbard 链与 Mott 绝缘体

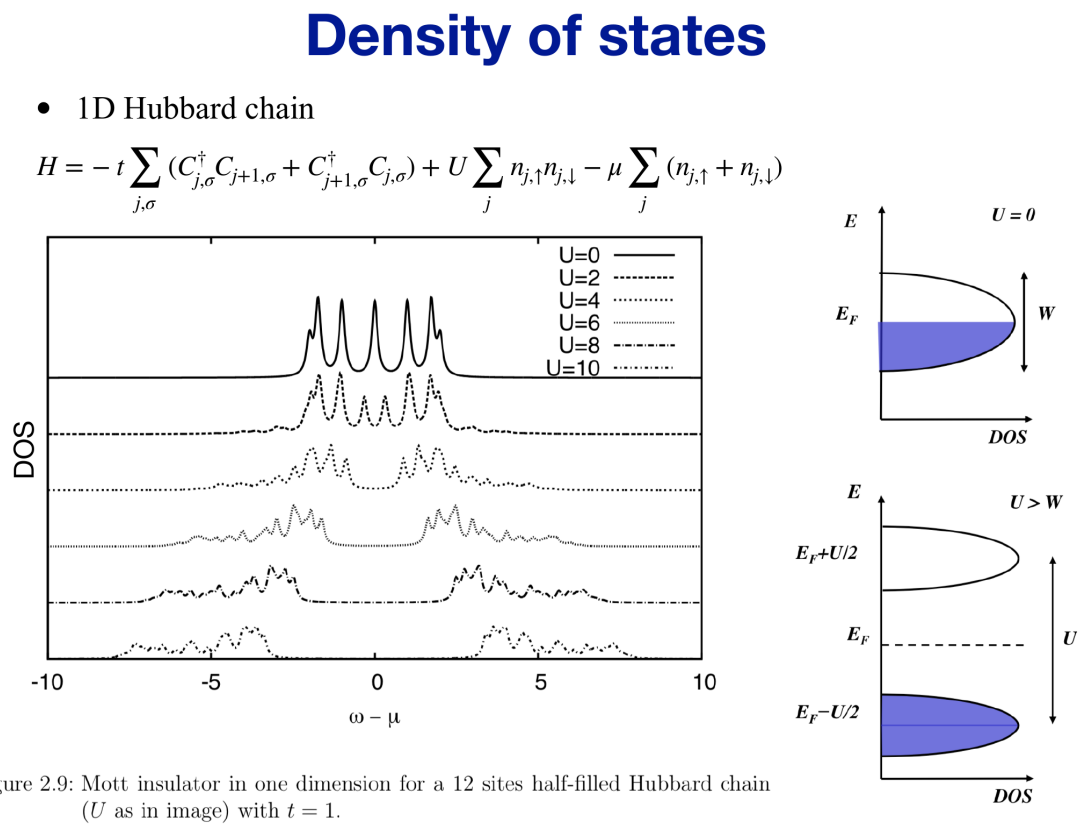


Figure 2.9: Mott insulator in one dimension for a 12 sites half-filled Hubbard chain (U as in image) with $t = 1$.

图 25: 幻灯片第 25 页

这一页写了什么

- 标题 *Density of states*，正文一句：**一维 Hubbard 链**。
- 哈密顿量

$$H = -t\sum_{j,\sigma}(c^{\dagger}_{j,\sigma}c_{j+1,\sigma} + c^{\dagger}_{j+1,\sigma}c_{j,\sigma}) + U\sum_{j} n_{j,\uparrow}n_{j,\downarrow} - \mu\sum_{j}(n_{j,\uparrow}+n_{j,\downarrow})$$

- 主体是 **Figure 2.9**：

  Figure 2.9: Mott insulator in one dimension for a **12 sites** half-filled Hubbard chain (U as in image) with $t = 1$.

- 图中曲线标注 $U = 0$（实线）、$U = 2$、$U = 4$、$U = 6$、$U = 8$、$U = 10$ 六条。
- 右侧两个小示意图，画的是**能量 E vs 态密度 DOS** 的示意：

情形	图示内容
$U = 0$	一条连续的带，E_F 在带宽 W 的中间（紫色填充区域从带底到 E_F）
$U > W$	带**劈裂成上下两支**：上支从 $E_F + U/2$ 开始，下支到 $E_F - U/2$ 结束，中间是能隙 U

图里画了什么

- **主图**：横轴 $\omega-\mu$（-10 到 10），纵轴 DOS。六条曲线**上下错开堆叠**（为了看清，每条加了不同的垂直偏移），所以**只能纵向比较”每条曲线自己”的形状与相对峰高，不能跨曲线比较绝对高度**（纵轴也没有标出数值刻度）。可比较的定量指标是每条曲线自己的 $\rho(0)/\rho_{\max}$（见下方”要点展开”）。
  - $U=0$**（最上，实线）**：一条**扁平**的曲线，在约 -2 到 $+2$ 之间是一块**平台**，边缘陡峭；平台上能看到一串**尖峰**。**这些尖峰的位置就是单粒子能级** $\varepsilon_k=-2t\cos(2\pi k/12)$：$\pm2$，$\pm\sqrt{3}\approx\pm1.73$，$\pm1$，0（即 $\omega-\mu\approx-2,-1.73,-1,0,1,1.73,2$ 附近）。**峰高不齐**：±2 只对应一个 k 值（权重 2），$\pm\sqrt{3}$、±1、0 各对应**两个** k 值（权重 4），所以后者的峰高约为前者的**两倍**（$4/(\pi\eta)\approx11.57$ vs $2/(\pi\eta)\approx5.79$）。图上最外侧的两个峰明显偏矮，正是这个原因。
  - $U=2$：原来的平台开始**中间下陷**，形成两个”肩”。
  - $U=4$：中间明显凹陷，两侧各有一组峰。
  - $U=6$：已经**分成两支**，$\omega-\mu=0$ 处 DOS 接近零。
  - $U=8$：两支分得更开，中间是清晰的**能隙**。
  - $U=10$**（最下，点线）**：两支几乎完全分离，下支集中在 $\omega-\mu\approx-4$ 到 -2，上支在 $+2$ 到 $+4$。

要点展开

（1）$U=0$ 的尖峰是”一维自由链的能级结构”。

$U=0$ 时模型是自由费米子，单粒子能级是（环上）

$$\varepsilon_k=-2t\cos(2\pi k/N),\qquad k=0,1,\cdots,N-1.$$

对 $N=12$：$\varepsilon_k=-2\cos(2\pi k/12)$，取值 -2，$-\sqrt{3}$，-1，0，1，$\sqrt{3}$，2，$\sqrt{3}$，1，0，-1，$-\sqrt{3}$。

去重后：±2（各 1 个）、$\pm\sqrt{3}$（各 2 个）、±1（各 2 个）、0（2 个）。**注意** $\pm\sqrt{3}\approx\pm1.732$、$\pm1$——**这些正是主图上那些尖峰的位置。**

> **这提供了一条最有用的校检**：用 $U=0$ 的解析结果 $\rho(\omega)=2\sum_k\frac{1}{\pi}\frac{\eta}{(\omega-\varepsilon_k)^2+\eta^2}$ 去对照数值结果。**本课程参考实现的实测偏差是** 4.37×10^{-14}**（**$N=8$**、网格** $[-6,6]$ **2001 点）——机器精度。**同一套代码在更宽网格（$[-10,10]$ 4001 点，即复现幻灯片 25 用的设置）上给出 4.45×10^{-14}，$N=12$ 时给出 5.3×10^{-13}——**都是机器精度量级**（最大偏差这个量对网格不敏感，因为它是逐点比较、两边用同一网格）。这条校检同时锁定了**跳跃幅度** t**、边界条件、**η**、权重归一化**四件事，是本讲**最强的校检**（见本页”提示 / 易错”）。

（2）纵轴偏移的读图规则（很重要）。

六条曲线是**堆叠**画的，所以**不能直接比较不同** U **在同一条水平线上的高度**。但每一组峰的**形状、宽度、相对高度**可以比较。

正确的比较方式：看**每一条曲线自己**的 $\rho(0)/\rho_{\max}$（即”费米面处的态密度相对于该曲线的峰值”）。参考实现的实测（$N=8$、$\eta=0.11$）：

U	$\rho(0)$	$\rho_{\max}$	$\rho(0)/\rho_{\max}$
0.0	11.7490	11.8459	9.92×10^{-1}
2.0	0.9195	9.8843	9.30×10^{-2}

U	$\rho(0)$	$\rho_{\max}$	$\rho(0)/\rho_{\max}$
4.0	0.2097	7.6140	2.75×10^{-2}
6.0	0.0864	6.6487	1.30×10^{-2}
8.0	0.0448	6.2740	7.13×10^{-3}

这个表就是本页的定量版本：$\rho(0)/\rho_{\max}$ 从 $U = 0$ 的 ≈ 1 迅速塌缩到 $U = 8$ 的 7×10^{-3}——**能隙打开的直接证据**。

(3) $U > W$ **时为什么能隙是** U。

这是 Hubbard 模型的**原子极限**（$t \to 0$）图像。先看**一个格点**：上面有一个电子（能量 0）。再放第二个电子上去，要付库仑能 U。

- **加法谱（IPES）**：往半满系统里加一个电子，它必须落在**已经被占据的格点**上（因为每个格点已有一个电子），所以要付 U——峰在 $E_F + U/2$。
- **减法谱（ARPES）**：拿走一个电子，留下一个空位（空穴），这个过程**释放** U 中的一部分——峰在 $E_F - U/2$。
- **能隙**：$(E_F + U/2) - (E_F - U/2) = U$。

幻灯片右侧下方的示意图正是这个图像：上支从 $E_F + U/2$ 开始，下支到 $E_F - U/2$ 结束，中间宽度 U。

> **注意** $\mu = E_F = U/2$ **（半满）**：这就是幻灯片横轴用 $\omega - \mu$ 的原因。用 $\omega - \mu$ 作横轴，能隙就**恰好关于 0 对称**。若用 ω 作横轴，各条曲线的能隙中心会随 U 移动，无法对齐比较。**本课程参考实现验证了** $\mu = [E_0(N+1) - E_0(N-1)]/2 = U/2$ **精确成立**（$U = 4$ 时实测 2.0000000000，机器精度）——这是粒子–空穴对称性的结果。

(4) $U = 0$ **时上下两支为什么对称。**

$U = 0$ 时粒子–空穴对称（在二分晶格上）意味着 $\rho^{\text{add}}(\omega) = \rho^{\text{rem}}(-\omega)$。所以总谱关于 $\omega - \mu = 0$ 对称。

参考实现的实测：$U = 0$ 时 $w_{\text{add}} = w_{\text{rem}} = 8.00000000$（$N = 8$，半满）——**恰好各等于** N（第 22 页的求和规则）。

> **权重必须"分开"检查**：$w_{\text{add}} + w_{\text{rem}} = 2N$ 这条**总和**校检抓不到"一格点 $\times N$"的错误（错误配错后总和仍精确守恒）。**必须分别验证** $w_{\mathbf{add}} = N$ **且** $w_{\mathbf{rem}} = N$。

(5) 从"金属"到"Mott 绝缘体"的物理。

- $U = 0$：$\rho(0)/\rho_{\max} \approx 1$，费米面处态密度**有限** $\to$ **金属**。
- U 增大：$\rho(0)$ **迅速塌缩**，$\omega - \mu = 0$ 处打开能隙 $\to$ **Mott 绝缘体**。
- **Mott 绝缘体的特殊性**：它不是"能带理论预言"的绝缘体（$U = 0$ 时它是金属），而是**电子关联**驱动的绝缘体。这正是 Hubbard 模型最重要的物理内容之一。

提示 / 易错

- **本页的横轴范围是** $\omega - \mu \in [-10, 10]$，**共 4001 个点**，$N = 12$ 环，$\eta = 0.11$。这些参数决定了峰宽（$\propto \eta$）和能看到多少结构。**改变** η **会显著改变图的外观。**
- **不要用肉眼比较不同曲线的绝对高度**（它们是偏移堆叠的）。正确的定量比较要用 $\rho(0)/\rho_{\max}$（见上表）。

- $\rho(0)$ **的小值不等于严格的零。** $N=12$ 是**有限尺寸**，能级是离散的，$\omega-\mu=0$ 处可能有少量谱权重。说"打开了能隙"要谨慎——**严格地说应该是"DOS 在费米面处被强烈压低"。**参考实现里明确写了这条告诫。
- **峰高受网格分辨率影响。** $\eta=0.11$ 的峰很窄，采样点太少会低估峰高。以**作业用的** $N=8$ **环**（$\eta=0.11$、$[-6,6]$）为例：1201 点给 $\rho_{\max}=11.846$，2001 点给 11.863，16001 点给 11.865。（本页图是 $N=12$，峰值 ≈ 12.75，取值不同，但同样的规矩适用。）所以**峰高要在足够细的网格上取，或直接由极点解析给出**；而"最大偏差"这类逐点比较的校检对此不敏感（两边用同一网格）。
- **奇偶性与** k、$-k$ **简并：** $N=12$ 环上 $\varepsilon_k=\varepsilon_{-k}$，所以除 $k=0$ 和 $k=N/2$ 外的能级都是**二重简并**。这解释了为什么有些峰高（权重 4）而有些低（权重 2）：峰高 $=\frac{2n_{\rm deg}}{\pi\eta}$，其中 $n_{\rm deg}$ 是该能级的 k 值个数、因子 2 来自自旋。例如 $\varepsilon=\pm2$（$n_{\rm deg}=1$）峰高 $\frac{2}{\pi\eta}=5.79$；$\varepsilon=\pm\sqrt{3}$（$n_{\rm deg}=2$）峰高 $\frac{4}{\pi\eta}=11.57$。
- μ **项在计算中的角色：**本页哈密顿量显式含 $-\mu\sum(n_\uparrow+n_\downarrow)$。但在 ED 计算里**通常不把** μ **项放进** H，而是先算 μ 值（由 $E_0(N\pm1)$ 定出），再把谱画在 $\omega-\mu$ 轴上。两种做法等价，但**后者数值上更干净**（少一次平移）。—

第 26 页 · 态密度：Krylov 空间维度从 5 增到 100

Density of states

- increasing the dimension of the Krylov space from 5 to 100

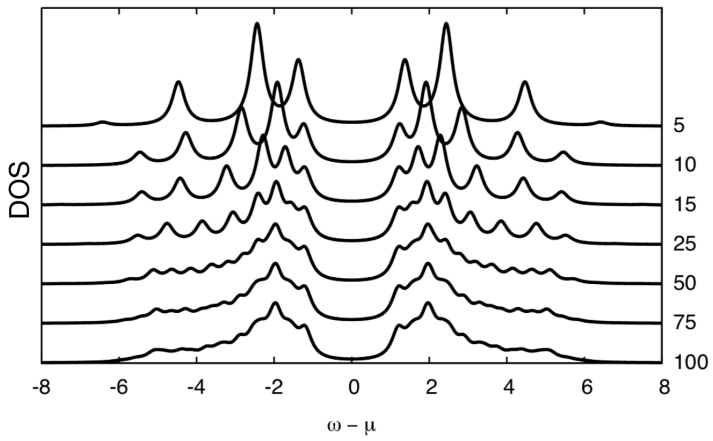


Fig. 4: *Convergence of the spectral function with increasing number of Lanczos steps, L=5, 10, 15, 25, 50, 75, and 100, for a 14-site Hubbard chain with* $U=5t$ *at half filling. With increasing L, more and more moments of the photoemission and inverse photoemission part of the spectrum are reproduced correctly.*

图 26: 幻灯片第 26 页

这一页写了什么

- 标题 *Density of states*，正文一句：**把 Krylov 空间的维度从 5 增加到 100**。

- 主体是一张图，图注 **Fig. 4**：

  Fig. 4: Convergence of the spectral function with increasing number of Lanczos steps, $L = 5$, 10, 15, 25, 50, 75, and 100, for a **14-site Hubbard chain** with $U = 5t$ at half filling. With increasing L, **more and more moments of the photoemission and inverse photoemission part of the spectrum are reproduced correctly.**

图里画了什么

- 横轴 $\omega - \mu$（-8 到 8），纵轴 DOS。
- 七条曲线**从上到下**对应 $L = 5, 10, 15, 25, 50, 75, 100$（**依次向下偏移堆叠**）。
- **关键的演化趋势**（从上往下看）：
  - $L = 5$（**最上**）：只有几个**宽而平滑**的鼓包，大致在 $\omega - \mu \approx -2.5$ 和 $+2.5$ 处各有一个宽峰，中间 -1 到 $+1$ 是一片**平滑的低谷**；细节全部丢失。
  - $L = 10$：宽峰开始**分裂**，出现两三个子结构。
  - $L = 15$：分裂更明显，峰变窄。
  - $L = 25$：出现更多小峰，形状更"毛糙"。
  - $L = 50$：在 $\omega - \mu \approx \pm 2$ 处峰已经很尖锐，并且**上下两支的边界变得清晰**（中间 -1.5 到 $+1.5$ 的低谷更平）。
  - $L = 75$：细节继续增加，出现很多小尖峰。
  - $L = 100$（**最下**）：谱形最"丰富"，有很多尖锐的峰；$\omega - \mu = 0$ 附近的**能隙结构**很清楚。

要点展开

(1) 这张图是第 24 页连分数收敛性的"可视版"。

图注那句话是核心：> "**more and more moments …are reproduced correctly**"> （**越来越多的矩被正确重现**）

"**矩**"（**moments**）指的是谱的积分量：

$$m_k = \int_{-\infty}^{\infty} \omega^k \rho(\omega)\, d\omega.$$

Krylov 方法与矩的精确关系是 Lanczos 理论的一个漂亮结果：**L 步 Lanczos 精确重现谱的前 $2L$ 个矩。**（因为 $\langle \phi_0 | H^k | \phi_0 \rangle$ 对 $k < 2L$ 与真实值一致。）

于是：- L 小 → 只有低阶矩正确 → 谱只能给出**大尺度形状**（宽鼓包）；- L 大 → 高阶矩也正确 → 谱能重现**精细结构**（尖锐小峰）。

> **这解释了为什么 $L = 5$ 的曲线那么平滑**：5 步 Lanczos 只保证前 10 个矩正确，对 $N = 14$ 的复杂谱来说远远不够。而 $L = 100$ 保证前 200 个矩，细节就出来了。

(2) "光电子与逆光电子两部分"为什么都要。

图注特别说"the **photoemission and inverse photoemission** part"——即**减法谱与加法谱**都要重现。回顾第 22 页：

部分	算符	极点	实验
photoemission（光电子）	$c_{j,\sigma}$	$E_0(N) - E_m(N-1)$	ARPES（拿走电子）
inverse photoemission（逆光电子）	$c^\dagger_{j,\sigma}$	$E_n(N+1) - E_0(N)$	IPES（加入电子）

所以这张图是把两支谱拼在一起画的。每支都需要自己的 Lanczos 过程（因为起点 $c|\Phi_0\rangle$ 与 $c^\dagger|\Phi_0\rangle$ 不同，属于不同的粒子数扇区）。**参考实现的实测**：$N = 8$、$U = 4$ 时两支的权重各为 $8.00000000 = N$。

(3) $N = 14$ 意味着多大的计算量。

$N = 14$ 半满，$(7, 7)$ 块维度是

$$\binom{14}{7}^2 = 3432^2 = 11\,778\,624 \approx 1.18 \times 10^7.$$

这个规模完全对角化是做不到的（需要 $\sim 10^{14}$ 个矩阵元的存储），但 Lanczos 只需要存 100 个长度为 1.18×10^7 的矢量：

$$100 \times 1.18 \times 10^7 \times 8 \text{ 字节} \approx 9.4 \text{ GB}.$$

> **注意**：这正好是第 14 页说的"重正交化的内存代价"。所以对 $N = 14$ 这种规模，**要么用朴素递推（存 2 个矢量）、要么用分块重启（第 15 页）**，不能盲目地存所有矢量。实践中 $L = 100$ 的朴素递推是可行的（存储 ~ 1 GB）。

(4) $U = 5t$ 的选择与参数表。

- $U = 5t$：处于**中等关联**区域。U 太小时谱接近自由链（结构简单，收敛快）；U 太大时谱分成两支很远的峰（也相对简单）。$U \sim 5t$ 附近谱结构最丰富，**是最考验收敛性的参数**。
- 横轴 $\omega - \mu \in [-8, 8]$，环上（周期性边界）。
- 半满，所以 $\mu = U/2 = 2.5t$。

(5) 与第 24 页收敛表的联系。

第 24 页的表给出的是**单个 z 点**的收敛速度；本页给的是**整条谱曲线**的收敛情况。两者一致：

- z 在谱密集处收敛慢（第 24 页的 $z = 5 + 0.11i$）对应**谱的精细结构需要大 L**（本页）。
- z 在谱外收敛快（第 24 页的 $z = -10 + 0.11i$）对应**谱的整体轮廓很快出现**（本页 $L = 5$ 就有轮廓）。

> **实用结论**：**如果你只需要谱的整体轮廓（例如判断是否有能隙），$L \sim 20-50$ 就够了；如果要看精细的多峰结构，需要 $L \sim 100$ 以上。**这也是第 12 页"能量收敛比其它观测量快"的又一个体现。

提示 / 易错

- **七条曲线是偏移堆叠的**，纵轴刻度不能直接跨曲线比较。要看的是**每条曲线自己的形状**如何随 L 变化。
- **L 在这里是"Lanczos 步数"，也就是连分数的层数，也就是 T 的维数。**三个说法是同一个量。图注用"Lanczos steps"，第 24 页用"层"，本讲义混用，你需要能自由切换。

- **注意横轴范围的差别**：本页 $\omega-\mu\in[-8,8]$（14 格点、$U=5t$），第 25 页是 $[-10,10]$（12 格点、U 到 10）。**两页的图不能逐点对比**——它们用的是不同的 N 和 U。
- **不要以为”L 越大越好”没有代价**。L 增大不仅增加内存，也让正交性问题更严重（第 13–16 页）。**实践中有一个最优的 L**，超过之后谱不再改善（甚至因鬼本征值而变差）。
- **本页没有给出参考曲线**（不像第 28 页有实验对照）。判断”是否收敛”要靠**自洽性**：$L=75$ 与 $L=100$ 的差别是否已小于你要的精度。参考实现里对 $N=8$ 的情形做过类似比较，结论是 **能量 40 步到 10^{-7}、60 步到机器精度，而谱形需要更多步**。

第 27 页 · 自旋-电荷分离

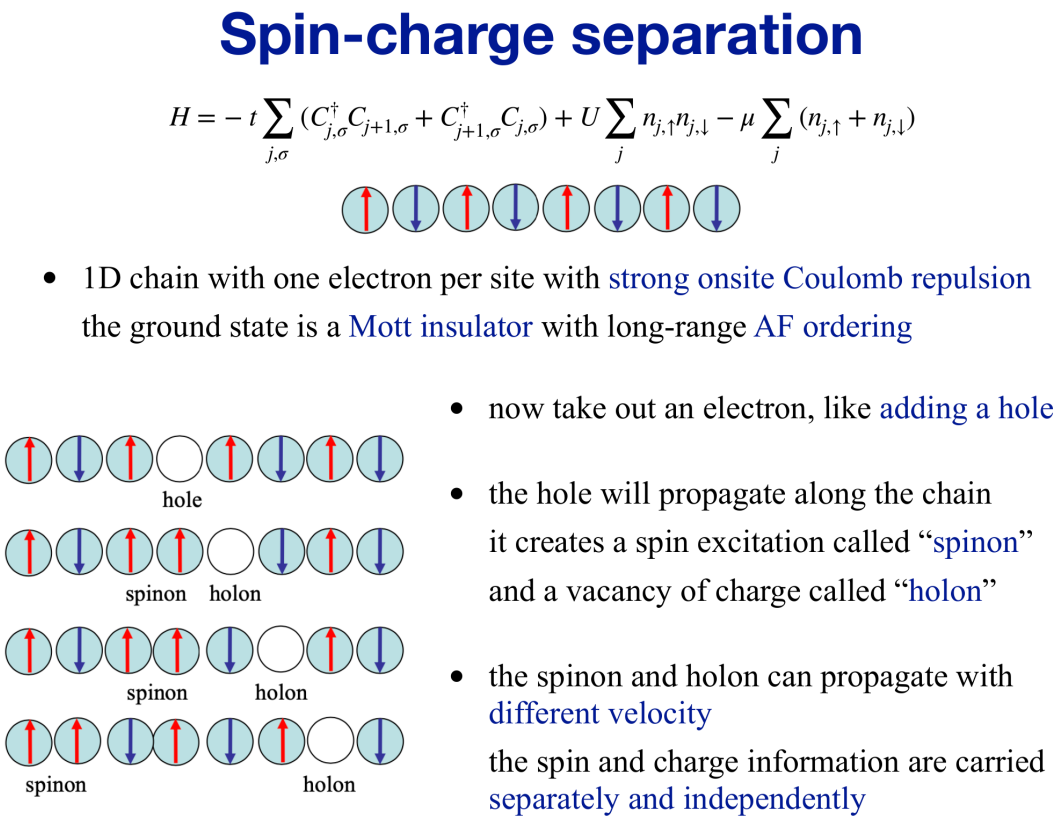


图 27: 幻灯片第 27 页

这一页写了什么

- 哈密顿量与第 25 页相同（一维 Hubbard 链）。
- 图中有**一排 8 个圆圈**，里面画红（向上）蓝（向下）箭头，表示自旋。
- 正文：
  - 一维链、每格点一个电子、**强在位库仑排斥**（strong onsite Coulomb repulsion）；**基态是 Mott 绝缘体，具有长程反铁磁（AF）序**。
- 下方左侧是四行示意图，展示”**取出一个电子**（即加入一个空穴）“的过程：

图	内容
第 1 行	8 个格点中第 4 个是**空位**（hole），其余是 ↑↓↑ ∘ ↑↓↑↓
第 2 行	空位右移一位，左侧标注 **spinon**（自旋子），空位处标注 **holon**（空穴子）
第 3 行	空位继续右移，spinon 与 holon 分开更远
第 4 行	空位到最右（标注 holon），spinon 在左端

- 下方右侧是文字说明：
  - 现在取出一个电子，相当于**加入一个空穴**；
  - 空穴会**沿链传播**；它产生一个称为 “**spinon**”的自旋激发和一个称为 “**holon**”的电荷空位；
  - spinon 与 holon 可以**以不同速度传播**；**自旋与电荷信息被分开、独立地携带**。

图里画了什么

- **顶部的 8 个圆圈**：↑↓↑↓↑↓↑↓——交替的自旋排列，正是**反铁磁序**（相邻自旋反向）的直观表示。这对应 U 很大时的 Heisenberg 极限（每个格点一个电子、自旋反铁磁排列）。
- **左侧四行**：从”8 个格点中一个空位”出发，让空位**逐行向右移动**。注意**空位移动时，左侧的自旋排列发生了变化**：第 1 行是 ↑↓↑ ∘ ↑↓↑↓，第 2 行变成了 ↑↓↑↑ ∘ ↓↑↓——**空位左边的自旋序列多了一个** ↑。这就是”空位移动留下了自旋激发”的图示。
- **spinon 与 holon 的距离逐行拉大**：第 2 行它们相邻，第 3 行隔开一格，第 4 行分别在两端。**这直观地展示了”自旋与电荷分离”。**

要点展开

（1）自旋-电荷分离（spin-charge separation）是什么。

在一维相互作用电子系统里，**一个电子被”劈成”两个独立的激发**：

激发	携带	电荷	自旋	类比
holon（空穴子）	电荷	$+e$（空穴）	0	电荷的”载体”
spinon（自旋子）	自旋	0	$\frac{1}{2}$	自旋的”载体”

关键点：它们**以不同的速度传播**，所以**会分开**。

> **这与高维（二维、三维）截然不同。**在 2D/3D 的费米液体中，电子是一个**完整的准粒子**（带着自己的电荷和自旋一起运动），电荷与自旋**不分离**。**自旋-电荷分离是一维特有的现象**，因为它来自一维的 **Luttinger 液体**（Tomonaga–Luttinger liquid）理论。

（2）为什么一维会分离——物理图像。

在一维，粒子**不能互相绕过**（没有横向空间）。于是：- 一个电子的运动**必然推挤**其它电子（“交通堵塞”效应）；- **电荷的运动**表现为**所有电子同步的集体位移**（一个 holon 传播）；- **自旋的运动**则是**相邻自旋交换**的传播（一个 spinon 传播）。

两者的”传播机制”不同，所以速度不同。在 Hubbard 模型里：- 电荷速度 v_c 与 t 有关（跳跃驱动）；- 自旋速度 v_s 与 t^2/U 有关（超交换驱动，$J \sim 4t^2/U$）。

在强耦合极限 $U \gg t$ 下，$v_c \gg v_s$（因为超交换被 U 压低）。

（3）如何用谱函数”看到”自旋-电荷分离。

这是本页与第 25、26、28 页的直接联系：

> **在 $A(k,\omega)$ 里，自旋-电荷分离表现为”一个电子峰劈裂成两个”。**

- **非相互作用**（$U = 0$）：$A(k,\omega)$ 是**一个** δ 峰（在 ε_k）。
- **一维相互作用**：$A(k,\omega)$ 劈裂成**两个峰**，一个对应 holon（色散关系与电荷速度有关），一个对应 spinon（色散关系与自旋速度有关）。
- **第 28 页 TTF-TCNQ 实验图上那些标着 c（charge）与 s（spin）的曲线** 就是这个劈裂的直接观测。

> **这是本讲最有物理冲击力的结论**：ED + Lanczos 算出的 $A(k,\omega)$ 能**定量**重现 ARPES 看到的自旋-电荷分离。

（4）“长程反铁磁序”在一维的含义。

幻灯片说基态是“Mott insulator with **long-range AF ordering**”。**在一维，严格的（长程）反铁磁序实际上是不存在的**——一维连续对称性不能自发破缺（Mermin–Wagner 定理）。

所以这句话要谨慎理解：它指的是：- **短程**反铁磁关联很强（$S(q = \pi)$ 附近有峰）；- 在**有限尺寸**的 ED 计算里，关联长度可能超过系统尺寸，于是看起来像”长程序”。

> **这是一个值得注意的”过度宣称”风险。**参考实现在讨论 Mott 能隙时也明确提醒：$N = 8$ 是有限尺寸，应该说”与 Mott 图像一致”，不能说”证明了它是绝缘体”。**同样的谨慎适用于”长程 AF 序”这个说法。**

（5）与第二讲的关系。

第二讲第 21 页介绍了 Hubbard 模型和费米子符号。本页是那个模型的**物理结果**：- 半满 + 强 $U \to$ Mott 绝缘体 + 反铁磁关联；- 掺杂（加空穴）$\to$ 自旋-电荷分离。

这也是第 30 页（条纹电荷调制）的物理背景：在**二维**掺杂 Mott 绝缘体里，空穴不是均匀分布，而是形成**条纹**（stripe）——**自旋与电荷在空间上分离的另一种形式**。从一维的”spinon/holon 分离”到二维的”条纹相”，物理机制不同，但”自旋与电荷行为不同”这个主题是相通的。

提示 / 易错

- **注意图中那排圆圈的读法**：每个圆圈是一个**格点**，里面的箭头是**该格点上的自旋**，空圆圈（◦）表示**没有电子**。**圆圈不是”电子”，格点才是素描单位。**
- **“holon”与“hole”（空穴）的区别**：空穴是**静态的**”少了一个电子”；holon 是**动态的**、携带动量的**集体激发**（它会传播）。图中左侧标注的“hole”是静态图像，“holon”是动态图像。
- **自旋-电荷分离只在 1D 严格成立**（Luttinger 液体）。在准一维材料（如 TTF-TCNQ，第 28 页）里，它**近似**成立，链间耦合会引入修正。所以第 28 页的图是”准一维”的验证。
- **本页没有出现任何新公式**，是一页**纯物理图像**的幻灯片。它的作用是解释”为什么我们要算 $A(k,\omega)$“——因为 $A(k,\omega)$ 里藏着自旋-电荷分离的直接证据。
- 一维 Hubbard 模型的**精确解**（通过 Bethe ansatz，Lieb–Wu 1968）给出了谱函数的精确形式，可作为 ED 结果的对照。**这也是”一维”特别受青睐的原因之一**：有解析结果可以验证数值方法。—

第 28 页 · 谱函数 $A(k,\omega)$ 与 TTF-TCNQ 实验

Spectral function $A(k,\omega)$

- TTF-TCNQ, quasi-1D conductor
  1D Hubbard model, spin-charge separation

$$A(k,\omega)=\frac{1}{\pi}\mathrm{Im}\langle\Phi_0|C^{\dagger}_{k,\sigma}\frac{1}{\omega-i\eta+H-E_0}C_{k,\sigma}|\Phi_0\rangle$$

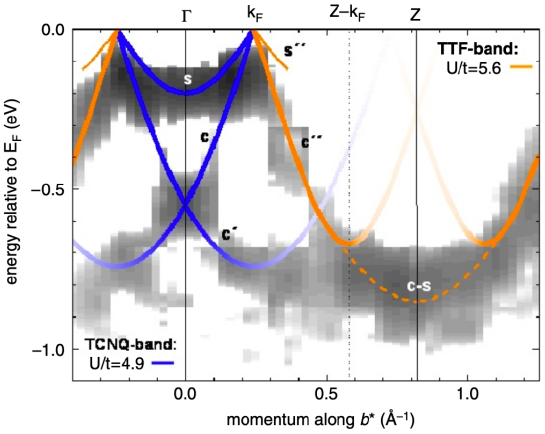
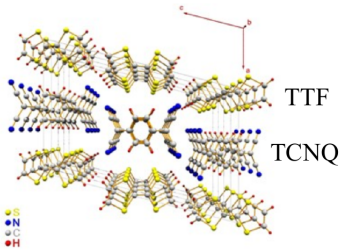
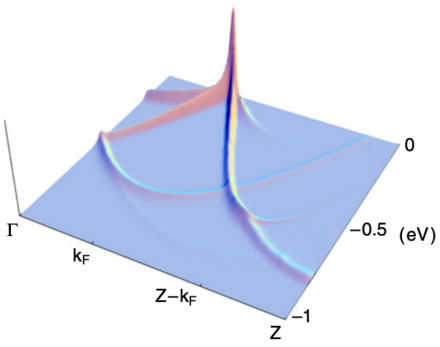


Figure 1. Experimental peak dispersions (gray scale) obtained by ARPES on TTF–TCNQ along the easy-transport axis as given in figure 7 of [4] and matching theoretical branch and border lines.





H. Benthien *et al*, PRL 92, 256401 (2004)
D. Bozi *et al*, J. Phys.: Condens. Matter 20, 022205 (2008)

图 28: 幻灯片第 28 页

这一页写了什么

- 标题 *Spectral function*，右上角标出 $A(k,\omega)$。
- 正文：
  - **TTF-TCNQ**，准一维导体（quasi-1D conductor）；
  - 一维 Hubbard 模型，**自旋-电荷分离**。
- 谱函数的动量分辨形式

$$A(k,\omega)=\frac{1}{\pi}\mathrm{Im}\left\langle\Phi_0\middle|c^{\dagger}_{k,\sigma}\frac{1}{\omega-i\eta+H-E_0}c_{k,\sigma}\middle|\Phi_0\right\rangle$$

- 右上角是 **TTF-TCNQ 的晶体结构图**（标注 TTF 与 TCNQ 两种分子层）。
- 左下是 **Figure 1**：

  Figure 1. Experimental peak dispersions (gray scale) obtained by ARPES on TTF-TCNQ along the easy-transport axis as given in figure 7 of [4] and matching theoretical branch and border lines.

- 右下是一张 **3D 曲面图**：Γ–k_F–Z–k_F 动量轴上画 $A(k,\omega)$ 的立体峰形。
- 图下标出两条文献：
  - **H. Benthien et al, PRL 92, 256401 (2004)**
  - **D. Bozi et al, J. Phys.: Condens. Matter 20, 022205 (2008)**

图里画了什么

- **晶体结构图**：TTF（四硫富瓦烯）与 TCNQ（四氰基对醌二甲烷）分子**分层堆叠**，形成**沿一个方向的一维链**。这是"准一维"的结构基础——沿链方向的跳跃积分很大，链间很小。
- **左下 ARPES 图**：
  - 横轴：动量（沿 b^*，单位 Å^{-1}，0 到约 1.2）；
  - 纵轴：相对 E_F 的能量（0 到 -1.0 eV）；
  - **灰阶背景**是 ARPES 实验数据（深色 = 强度大）；
  - 上面叠加了多条**彩色曲线**：
    - **橙色实线**：标"TTF-band: $U/t = 5.6$"——理论计算的 TTF 能带；
    - **蓝色实线**：标"TCNQ-band: $U/t = 4.9$"——理论计算的 TCNQ 能带；
    - 曲线上有标注 s（spin）、c（charge）、c^*、s^*、$c-s$（虚线）等；
  - 竖直虚线标出 k_F 与 $Z-k_F$、Z 等动量点。
- **右下 3D 图**：把 $A(k,\omega)$ 画成一个**曲面**，在 Γ、k_F、$Z-k_F$、Z 四个动量点上有**尖锐的峰**，峰的位置随动量**色散**（dispersion）。

要点展开

（1）动量分辨谱函数 $A(k,\omega)$ 的定义与来历。

本页的公式与第 22 页的 $I(\omega)$ 结构相同，但算符换成了**动量空间**的 $c_{k,\sigma}$。实空间与动量空间通过傅里叶变换连接：

$$c_{k,\sigma} = \frac{1}{\sqrt{N}} \sum_j e^{-ikj} c_{j,\sigma}.$$

于是

$$A(k,\omega) = \frac{1}{N} \sum_{ij} e^{ik(i-j)} \left\langle \Phi_0 \middle| c_{i,\sigma} \frac{1}{\omega - i\eta + H - E_0} c^\dagger_{j,\sigma} \middle| \Phi_0 \right\rangle.$$

> **注意本页公式的符号细节**：幻灯片写的是 $\frac{1}{\omega - i\eta + H - E_0}$（$-i\eta$ **和** $+H$），而第 22 页写的是 $\frac{1}{\omega + i\eta - H + E_0}$（$+i\eta$ **和** $-H$）。**两者是同一个东西**：把分子分母同乘 -1 即得。这个写法上的差异源于不同文献对"推迟格林函数"的约定，**计算时只要保持 η 的符号使结果收敛（衰减）即可**。

（2）计算上的关键：必须先做傅里叶变换还是可以直接算。

有两种实现路径：

路径	做法	代价
逐个 k	构造 $c_{k,\sigma}\|\Phi_0\rangle$，对它做 Lanczos	每个 k 一次 Lanczos
先算实空间	算所有格点的关联函数 $\langle c_i \cdots c_j^\dagger \rangle$，再傅里叶变换	一次 Lanczos 给出所有 k

路径二的效率高得多（这也是为什么第 25、26 页用局域谱）。但在标准的 $A(k,\omega)$ 计算里，**路径一**更常用（因为 $c_{k,\sigma}|\Phi_0\rangle$ 本身就是个好起点，Lanczos 收敛快）。

> **参考实现的选择**：本课程的参考实现走的是**实空间局域谱 + 求和**的路线（算 $\sum_{j,\sigma} \rho_{j,\sigma}$），得到总态密度。这与第 25、26 页的图对应。要得到 $A(k,\omega)$ 需要额外的傅里叶变换步骤。

（3）TTF-TCNQ 是什么，为什么是理想的验证对象。

TTF-TCNQ = tetrathiafulvalene–tetracyanoquinodimethane，是**第一个被发现的高温有机超导体候选**（1970 年代，$T_c \approx 60$ K 附近有争议），也是**准一维导体的原型材料**。

它的结构特点：- TTF 分子堆成**一维链**，TCNQ 分子堆成**另一条一维链**；- 链内跳跃积分 t 远大于链间跳跃；- 所以它**近似是一维系统**——是检验一维 Hubbard 模型的理想平台。

为什么用它验证自旋-电荷分离：因为一维 Hubbard 模型的预言（自旋-电荷分离）可以**直接在 ARPES 上看到**，而 TTF-TCNQ 是当时最好的准一维样品。

（4）图上那些标注的含义（本页最重要的读图信息）。

标注	含义	色散关系
s	spinon（自旋激发）	由自旋速度 v_s 决定
c	holon（电荷激发）	由电荷速度 v_c 决定
c^*、s^*	次级/高阶的自旋与电荷支	多体效应
$c-s$（**虚线**）	自旋-电荷的**组合**激发	两者能量的和/差

这就是自旋-电荷分离的实验证据：如果电子是完整准粒子，图上应该只有**一条**色散曲线（$U = 0$ 的自由电子带）。**但实际上看到了多条**——一条 c、一条 s——**这就是”电子劈裂”的直接图像**。

> **第 27 页的 spinon/holon 图像在这里变成了可测量的曲线。**第 27 页是”什么”，本页是”怎么测”。

（5）两张理论文献的分工。

- **Benthien et al, PRL 92, 256401 (2004)**：用**量子蒙特卡罗 + 最大熵解析延拓**（QMC + maximum entropy）计算一维 Hubbard 模型的 $A(k,\omega)$。这是”无偏但需要解析延拓”的路线。
- **Bozi et al, J. Phys.: Condens. Matter 20, 022205 (2008)**：用**精确对角化 + Lanczos**（就是本讲的方法！）计算 $A(k,\omega)$。这是”有有限尺寸限制但直接给出实频率谱”的路线。

两条路线的对比本身就是本讲方法的一次定位：

	ED + Lanczos（本讲）	QMC + 最大熵
有限尺寸	有（N 小）	可以大
实频率谱	**直接得到**（η 展宽）	需要**解析延拓**（有系统误差）
符号问题	无	有（一维还好）
谱的细节	有限尺寸下是离散峰	连续谱

> **本讲方法的优势正是”直接给出实频率谱”**——不需要解析延拓，这是它至今在谱函数计算中不可替代的原因。

（6）3D 曲面图的信息。

右下角的 3D 图是 $A(k,\omega)$ 的**完整图像**：- 两个水平轴：动量（$\Gamma \to k_F \to Z - k_F \to Z$）和能量（0 到 -1 eV）；- 竖直轴：$A(k,\omega)$ 的强度；- **看到的峰是”色散曲线”在 (k,ω) 平面上的投影**。

它与左下二维 ARPES 图是同一份数据的两种画法：二维图用灰阶/颜色表示强度（实验常用），三维图用高度表示强度（理论常用）。

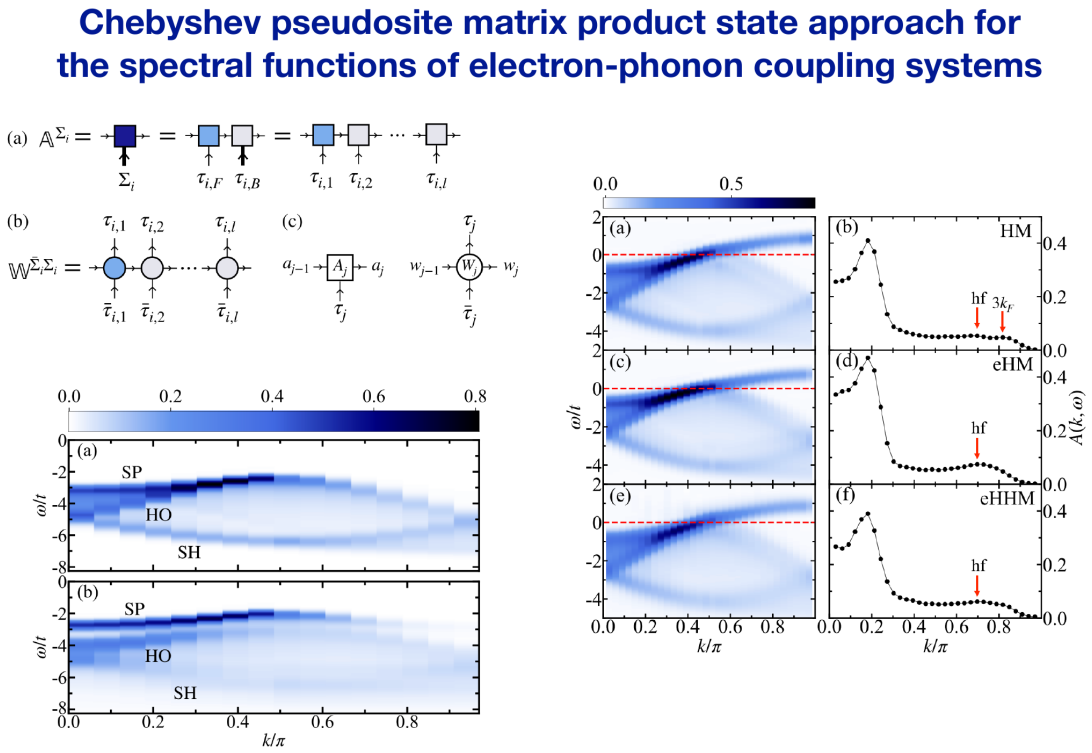
提示 / 易错

- **动量 k 的单位是 Å^{-1}**（实验图），而**理论计算通常用无量纲的 k/π**。对比理论与实验时必须换算（涉及晶格常数）。第 26 页的横轴是 $\omega - \mu$（无量纲），本页实验图是 eV——**注意单位。**
- **图上的 k_F 附近有多条曲线交叉**。这是自旋-电荷分离最显著的标志：c 支与 s 支在 k_F 附近**分叉**。**如果看到的是单一曲线，说明没有分离。**
- **“匹配”（matching）的程度不要过度解读**：图注说“matching theoretical branch and border lines”，这只是”曲线对上了”，**不等于”理论完全解释了实验”**准一维材料还有链间耦合、电子-声子耦合等效应。
- **本页公式里的 $c_{k,\sigma}$ 是动量空间的算符**，与第 20–23 页的实空间算符 $A = c_{j,\sigma}$ 不同。但方法**完全一样**（Lanczos + 连分数），只是起点矢量不同。
- **注意这个公式里 $A(k,\omega)$ 与算符 A 的记号冲突**（第 22 页已提醒）。本页 $A(k,\omega)$ 是**谱函数**，不是算符。
- **PRL 92, 256401 (2004) 的 Benthien 等人用的是 QMC**，这一点值得注意：**同一物理问题可以有完全不同的数值方法**，而它们的结果互相验证（这正是第一讲”ED 是裁判”精神的体现）。

第六部分：研究前沿（第 29–30 页）

这两页把本讲的方法放到**当前研究**的语境里。第 29 页是”方法的推广”（Lanczos 之外的谱函数方法），第 30 页是”物理的应用”（用谱函数研究掺杂 Mott 绝缘体）。它们都不是考试内容，但能帮你理解”为什么要学这些”。

第 29 页 · 研究前沿（一）：Chebyshev 赝 site 张量网络方法



Pei-Yuan Zhao, Ke Ding, and Shuo Yang, Phys. Rev. Res. 5, 023026 (2023)

图 29: 幻灯片第 29 页

这一页写了什么

标题：**Chebyshev pseudosite matrix product state approach for the spectral functions of electron-phonon coupling systems**（用于电子-声子耦合系统谱函数的 **Chebyshev 赝 site 矩阵乘积态**方法）。

页面由三部分组成：

- **左上 (a)(b)(c)**：**张量网络示意图**。
  - (a) $\mathbb{A}^{\Sigma_i}$：一个方形张量，下方有 Σ_i 标记；
  - (b) $\mathbb{W}^{\Sigma_i}_{\tau_i}$：一串圆圈（代表矩阵乘积态 MPS 的局域张量），下方标注 $\tau_{i,1},\tau_{i,2},\cdots,\tau_{i,l}$ 与 $\bar{\tau}_{i,1},\bar{\tau}_{i,2},\cdots,\bar{\tau}_{i,l}$；
  - (c) 两个算符符号 A_j（连 $a_{j-1}\to a_j$）与 W_j（连 $w_{j-1}\to w_j$）。
- **左下 (a)(b)**：两张 k/π（0 到 0.8）对 ω/t（0 到 -8）的**强度图**，强峰（深色）标有 **SP**、**HO**、**SH** 三个区域。
- **右侧 (a)–(f)**：三组对比图。
  - (a)(c)(e)：k/π 与 ω/t 的强度图（二维色图，深蓝到白）；
  - (b)(d)(f)：$A(k,\omega)$ 随 k/π 的曲线（点 + 线），标有 **HM**、**eHM**、**eHHM** 三种模型，并标出 **hf** 与 $3k_F$（红色箭头）。

- 页面底部给出文献：**Pei-Yuan Zhao, Ke Ding, and Shuo Yang, Phys. Rev. Res. 5, 023026 (2023)**。

图里画了什么

- **两组 ω/t–k/π 图（左下的 (a)(b)）**：横轴 k/π 从 0 到 0.8，纵轴 ω/t 从 0 向下到 -8。深色（黑/深蓝）表示 $A(k,\omega)$ 强，白色表示弱。能看到**三条主要的色散带**，分别标注 SP（最上面，约 -2 到 -3）、HO（中间，约 -4 到 -5）、SH（最下面，约 -6 到 -7）。上图和下图看起来**几乎一样**（这是两种计算方法的对比）。
- **右侧三组图**：
  - (a)(c)(e) 是三张二维强度图（对应三种模型 HM、eHM、eHHM），都显示出**从** $(\omega/t=0, k/\pi=0)$ **附近向** $(\omega/t\approx-4, k/\pi\approx0.5)$ **倾斜下降的亮带**（一条主色散带）；
  - (b)(d)(f) 是沿某条 k 路径的 $A(k,\omega)$ 曲线，都有一个**主峰**（在 $k/\pi\approx0.15$ 附近最高），以及侧翼；标出了 **hf**（high frequency?）与 $3k_F$ 的位置。
- **三组图的差别**：从 HM → eHM → eHHM，主带的位置与形状**略有不同**（eHHM 里主带更靠下），$3k_F$ 处的特征也更明显。

要点展开

（1）这一页在研究什么：电子-声子耦合。

本讲前面（第 25–28 页）讲的都是**纯电子**的 Hubbard 模型。但真实材料里**电子与晶格振动（声子）耦合**，这会带来全新的物理：

- **极化子**（polaron）：电子带着晶格畸变一起运动，有效质量变大；
- **声子边带**（phonon sidebands）：谱函数上出现等间距的额外峰（因为电子可以同时激发整数个声子）；
- **SP / HO / SH** 这些标注正是这些结构的名称。

> **注意**：电子-声子耦合让希尔伯特空间变成 电子 $\otimes$ 声子，**维度爆炸得更厉害**（声子可以是无穷多能级，实践中截断到 N_{ph}）。这就**超出了 Lanczos 单打独斗的能力范围**，需要新方法。

（2）Chebyshev 方法：Lanczos 之外的谱函数路线。

Chebyshev 多项式展开是计算谱函数的另一条经典路线：

$$\rho(\omega)\approx\frac{1}{\pi\sin\theta}\Big[\mu_0+2\sum_{n=1}^{N-1}\mu_n\cos(n\theta)\Big],\qquad\theta=\arccos\Big(\frac{\omega-E_0}{a}\Big),$$

其中**矩** $\mu_n=\langle\phi_0|T_n(\tilde{H})|\phi_0\rangle$（$T_n$ 是 Chebyshev 多项式，$\tilde{H}$ 是缩放后的 H）。

与 Lanczos 连分数的对比：

	Lanczos + 连分数	Chebyshev
基	Krylov 基 $\{H^k\|\phi_0\rangle\}$	Chebyshev 基 $\{T_n(\tilde{H})\|\phi_0\rangle\}$
系数递推	三项递推（a_m, b_m）	三项递推（Chebyshev 的固定递推）
收敛	依赖 z（第 24 页）	**一致**（Chebyshev 是"最优一致逼近"）

	Lanczos + 连分数	Chebyshev
数值稳定性	正交性会丢（第 13–16 页）	**更好**（不需要内积正交化）
需要谱范围	不需要	**需要**（要先知道 $[E_{\min}, E_{\max}]$）

> **Chebyshev 的最大优点是数值稳定**——它不需要 $a_m = \langle\phi_m|H|\phi_m\rangle$ 这种内积，而是用**递归定义**的多项式，所以**没有正交性丢失问题**。代价是必须先估计谱的上下界。

(3)“赝 site”（pseudosite）是什么意思。

这是**张量网络语言**里的技巧。在 DMRG/MPS 计算里，要处理**长程相互作用**或**声子**时，可以把一个"复杂的自由度"用一个**辅助格点**（pseudosite）来表示：

- 电子-声子耦合里，**声子的局域希尔伯特空间**可以映射成一个 pseudosite；
- 这样整个系统变成一个**格点模型**（电子格点 + 声子格点交替），可以直接用 MPS 的标准算法处理。

“赝 site MPS”就是”把声子当作额外的格点来处理”的 MPS 方法。

(4) MPS（矩阵乘积态）与本讲方法的关系。

	ED + Lanczos（本讲）	MPS / DMRG
维度	严格处理全希尔伯特空间	**截断纠缠**，只保留最重要的分量
一维能力	$N \sim 14-20$	$N \sim$ 几百到上千
谱函数	**直接**（连分数）	需要额外技巧（Chebyshev + pseudosite）
误差来源	有限尺寸 + 浮点	有限尺寸 + **纠缠截断**

本页方法的动机：把"Lanczos 能算谱函数"和"MPS 能算大系统"的优点结合起来，用 **Chebyshev + pseudosite MPS** 处理电子-声子耦合（本讲方法做不到的大系统）。

(5) 图上 SP / HO / SH 的含义（声子边带结构）。

在这类模型里，谱函数的结构来自"电子 + 若干声子"的激发：

标注	可能含义
SP	single phonon（单声子）激发
HO	某个内禀（holon-like 或 higher order）激发
SH	更高阶/次级结构

> **这些标注的具体含义需要查原文献**（Phys. Rev. Res. **5**, 023026 (2023)）。本讲义不给猜测性解释——**如果你要引用，请核对原文**。重要的是理解**结构的存在**：谱不是单一色散带，而是**多条平行的带**，这正是电子-声子耦合的特征（每条带相差一个声子能量）。

(6) 三种模型 HM / eHM / eHHM 的递进。

- **HM**：Hubbard model（纯电子）；
- **eHM**：**e**xtended Hubbard model（加近邻相互作用 V）；
- **eHHM**：**e**xtended **H**ubbard–**H**olstein model（再加声子耦合 Holstein 项）。

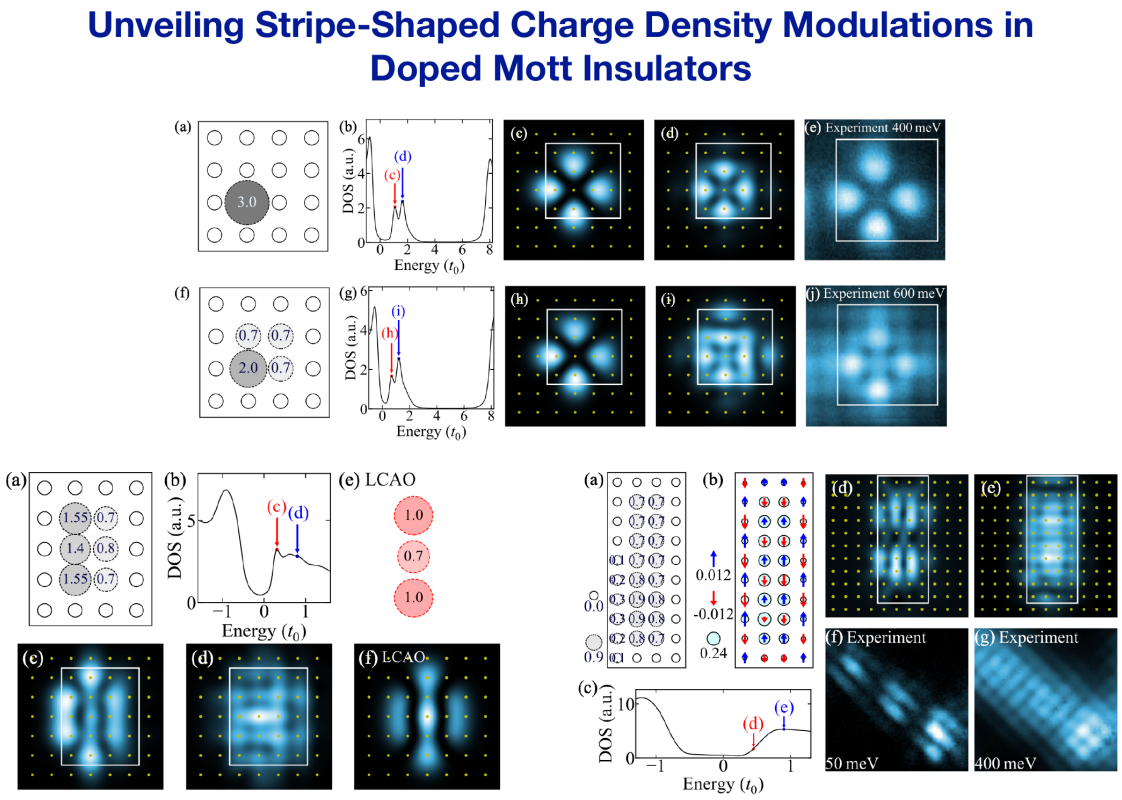
这是一个典型的”逐步加物理”的研究策略：从最简单的模型出发，逐个加入相互作用，观察谱函数如何变化。**图 (a)(c)(e) 的差别就是”加了什么物理、谱怎么变”的直接展示。**

提示 / 易错

- **本页是研究前沿介绍，不是考试内容。**目的是让你知道“本讲学的方法不是终点，还有更强的方法（但思想相通）”。
- **不要试图从图上读定量数字**：这些图是定性展示色散结构，横纵轴的刻度存在但精度有限。
- **作者 Shuo Yang 就是本课程教师。**这篇工作是课程组自己的研究，写在课件里是”把科研带进课堂”的做法。**遇到不懂的地方，可以直接在课上问。**
- **Chebyshev 与 Lanczos 不是竞争关系**，而是**互补**：两者都是 Krylov 型方法（Chebyshev 是”预定义多项式”的 Krylov），都精确重现前若干阶矩。
- **物理单位**：这里横轴是 ω/t（无量纲），纵轴是 k/π（无量纲的动量）——与第 26 页的风格一致。

—

第 30 页 · 研究前沿（二）：掺杂 Mott 绝缘体中的条纹电荷调制



Ning Xia, Yuchen Guo, and Shuo Yang, Phys. Rev. Lett. 135, 116504 (2025)

图 30: 幻灯片第 30 页

这一页写了什么

标题：**Unveiling Stripe-Shaped Charge Density Modulations in Doped Mott Insulators**（揭示掺杂 Mott 绝缘体中的**条纹状电荷密度调制**）。

页面由四组图组成，每组都包含"格点示意图 + DOS 曲线 + 空间强度图"：

- **左上组**（单空穴）：
  - (a) 4×4 格点，其中一个格点标 **3.0**（空穴浓度）；
  - (b) DOS vs Energy（t_0），标出 (c)(d) 两个能量位置；
  - (c)(d) 两张计算得到的空间强度图；
  - (e) **Experiment 400 meV**（实验对照图）。
- **左中组**（多空穴，0.7/0.7/2.0/0.7）：
  - (f) 格点图，各格点标不同的空穴浓度；
  - (g) DOS，标出 (h)(i) 位置；
  - (h)(i) 空间强度图；
  - (j) **Experiment 600 meV**。
- **左下组**：
  - (a) 格点图（1.55/0.7、1.4/0.8 等）；
  - (b) DOS；
  - (e) **LCAO** 表示的三个圆（1.0/0.7/1.0）；
  - (c)(d) 空间强度图；
  - (f) **LCAO** 图。
- **右下组**：
  - (a) 格点图（0.9/0.8/0.7 等）；
  - (b) 自旋/电荷分布示意（红蓝箭头）；
  - (c) DOS；
  - (d)(e) 空间强度图；
  - (f)(g) **Experiment 50 meV / 400 meV**。

页面底部给出文献：**Ning Xia, Yuchen Guo, and Shuo Yang, Phys. Rev. Lett. 135, 116504 (2025)**。

图里画了什么

- **空间强度图**（多张）：深蓝色背景上，黄色小点表示格点位置，中间有一个**白色方框**（表示视场范围），方框内是**四个亮的蓝色斑点**（呈正方形排列）或**条纹状（stripe）亮带**。
- **与实验的对比**（(e)、(j)、(f)(g)）：实验图也是深蓝背景、亮斑，与计算图**在形状和位置上高度相似**。
- **关键的形态演化**：
  - **单空穴**（左上）：四个亮斑呈**正方形状**分布（各向同性）；
  - **多空穴**（左中）：亮斑开始**沿一个方向拉长**；
  - **右下**：明显的**条纹**（沿竖直方向的亮带），与 **Experiment 50 meV** 的条纹图对应。

要点展开

（1）这一页在研究什么：掺杂 Mott 绝缘体中的条纹相。

物理背景（连接第 27 页）：

- **半满** Mott 绝缘体：每个格点一个电子，自旋反铁磁排列（第 27 页顶部图）。
- **掺杂**（移走一些电子，产生空穴）：空穴**不均匀分布**，而是自发组织成**条纹**（stripe）——**电荷与自旋在空间上分离**。

这与第 27 页的自旋-电荷分离是同一个主题的二维版本：一维里是"spinon/holon 以不同速度传播"，二维里是"电荷形成条纹，自旋在条纹间保持反铁磁"。**从一维到二维，自旋与电荷的行为依然不同。**

铜氧化物高温超导体（cuprates）里，条纹相被认为是理解 **赝能隙**（pseudogap）和**高温超导**机制的关键之一（这一争论持续了三十多年）。

(2)"条纹"（stripe）的具体含义。

条纹相的特征是**电荷密度与自旋密度的空间调制**：

$$\langle n_j \rangle \sim n_0 + \delta n \cos(\mathbf{Q} \cdot \mathbf{r}_j), \qquad \langle S_j^z \rangle \sim m \cos(\mathbf{Q}' \cdot \mathbf{r}_j),$$

其中 $\mathbf{Q}$（电荷）与 $\mathbf{Q}'$（自旋）的周期**不同**——通常电荷周期是自旋周期的一半（"half-filled stripes"）。

图上的表现：亮斑/亮带就是 $\langle n_j \rangle$ 或谱权重**大**的地方，它们排列成周期性的条纹。

(3)计算方法的定位。

本页的工作用的是**精确对角化 + Lanczos**（本讲的方法!）来计算：

- **基态**（用 Lanczos）；
- **局域态密度** $\rho_{j,\sigma}(\omega)$（用第 21–24 页的连分数方法），空间分辨地画出来——这就是那些空间强度图。

  这正是第 21 页"局域态密度"的实战应用：因为 $\rho_{j,\sigma}$ **依赖于格点** j，所以它可以直接显示"哪些格点的态密度高"——**这就是条纹相的空间图像。**

  如果只算**总**态密度 $\rho(\omega) = \sum_{j,\sigma} \rho_{j,\sigma}$（第 22 页），空间信息就被求和抹掉了。**这是"局域"谱函数不可替代的地方。**

(4)"Energy (t_0)**"与 DOS 曲线的含义。**

- 横轴是能量（单位 t_0，即最近邻跳跃积分）；
- DOS 曲线上的 (c)(d) 等标记表示**选定的能量切片**；
- 空间强度图就是**在这个能量上的** $\rho_j(\omega = \text{固定值})$。

换句话说：空间图是 DOS 的"能量分辨的二维切片"。**不同能量切片对应不同的空间图案**——这正是条纹相的特征（电荷条纹与自旋条纹出现在不同能量）。

(5)与实验的对比：为什么可信。

图中多处给出 **Experiment**（400 meV、600 meV、50 meV）的对照。**计算与实验在形状上高度一致**，这提供了独立验证：

- 计算是**纯理论**（Hubbard 模型 + ED）；
- 实验是**真实的**扫描隧道谱（STS）或类似测量；
- 两者一致 → 说明"掺杂 Mott 绝缘体中的条纹"这个物理图像是**有实验支持的**。

  这与第 28 页（TTF-TCNQ）是同一个研究范式：用 ED/Lanczos 算出空间或动量分辨的谱，与实验直接对比。这是本讲方法在当代凝聚态研究中的典型用法。

(6)“LCAO”的含义。

LCAO = Linear Combination of Atomic Orbitals（原子轨道线性组合）。在图上标注 LCAO 的地方（(e) 与 (f)），画的是用**原子轨道基组**表示的空间分布——即”把连续的电荷密度投影到各个格点的原子轨道上”。

它和前面的空间强度图的关系：空间强度图是实际计算/测量的连续分布；LCAO 图是**用格点轨道展开**的离散表示（圆的大小表示权重）。**两者一致说明”格点模型抓住了主要物理”。**

提示 / 易错

- **本页同样是研究前沿，不是考试内容**，而且比第 29 页更专门。理解”条纹相 = 电荷与自旋的空间调制”这个核心物理就够了。
- **格点图上那些数字**（如 3.0、0.7、1.55）表示**该格点上的空穴浓度**或相关权重，具体定义需查原文。
- **不要混淆”条纹”（stripe）与”条纹相”（stripe phase）**：前者是图案，后者是热力学相。
- **文献是 PRL 135, 116504 (2025)**——这是**很新的工作**（2025 年），说明本讲介绍的方法**正在被用于当前研究**。作者里同样有本课程教师。
- **本页与第 25–28 页的逻辑关系**：第 25 页（Mott 绝缘体的 DOS）→ 第 27 页（自旋-电荷分离的物理）→ **第 30 页（掺杂后的条纹相）。从”半满绝缘体”到”掺杂金属”，是本讲物理线索的终点。**

第七部分：作业（第 31–32 页）

第 31 页 · 作业规则

Homework rules

please submit through http://learn.tsinghua.edu.cn

- please submit the source code, detailed notes explaining your code and results, and your log with AI
- deadline is Oct. 4, 23:00
- if you submit today, you will have more points
- if you submit after the deadline, you will have less points
- if you are an expert in exact diagonalization, this homework may be waived
  please contact me in person and submit something you have done before

图 31: 幻灯片第 31 页

这一页写了什么

- 请通过 **http://learn.tsinghua.edu.cn** 提交。
- 请提交**源代码**、**详细解释你的代码和结果的说明文档**（detailed notes），以及**你与 AI 的对话记录**（your log with AI）。
- 截止日期是 **10 月 4 日 23:00**。
- 如果**今天**提交，会得到更多分数。
- 如果**过了截止日期**提交，会扣分。
- 如果你已经是精确对角化方面的**专家**，这次作业**可以免修**（may be waived）；请**当面联系我**，并提交你以前做过的东西。

要点展开

（1）三样提交物缺一不可。

提交物	作用	对应评分项（第 32 页）
源代码	证明你会实现	可执行 +10、结果正确 +20、可读性 +10

提交物	作用	对应评分项（第 32 页）
说明文档	证明你**理解**	原理 +10、代码 +10、结果 +10、清晰 +10
AI 对话记录	证明你的工作过程	+20

“说明文档”的要求值得特别注意：它要解释**三件事**——(1) 基本原理、(2) 源代码、(3) 结果。**只贴代码不解释，或者只贴结果不解释原理，都会失分。**

(2) 与第二讲作业的对比。

第二讲的作业（本课程之前的部分）与本讲是同一条主线上的连续任务：- **第二讲**：造矩阵（基矢、比特运算、稀疏矩阵、对称性）；- **第三讲**：对角化 + 算谱函数（Lanczos、连分数、$U = 0$ 基准）。

所以**第三讲的作业会用到第二讲的代码**。如果你第二讲的实现有 bug，第三讲会跟着出错。**建议先把第二讲的校检跑通。**

(3)“专家可以免修”的含义。

这不是”偷懒的借口”，而是承认**学生的背景差异**：有些同学（例如做过相关科研的）已经掌握了 ED。对这些人，**重复做一遍没有学习价值**。

处理方式：当面联系 + 提交以前做过的东西。**关键是”当面”**——这是让学生有机会讲清楚自己的工作。

(4) 时间分的设计。

“今天提交得更多分”是一个**激励设计**：鼓励你在**记忆最新鲜**的时候完成，而不是拖到截止日期。这也是本课程一贯的做法（第二讲作业也有类似的”today: +5”）。

提示 / 易错

- **截止日期是 10 月 4 日 23:00**，而讲课日期是 9 月 28 日——**只有 6 天**。考虑到作业包含”造矩阵 + Lanczos + 连分数 + 校检”，**建议尽早开始**。
- **“detailed notes”不是”注释”。**它是一份**独立的文档**，要能让读者（假设是你的同学）看懂你的方法和结果。**本讲义的结构可以作为参考**（原理 → 代码 → 结果 → 校检）。
- **AI 对话记录要”诚实、完整”。**第 32 页给它 +20 分（占比很高），说明课程**鼓励**用 AI，但要求**记录过程。只贴 AI 的正确答案、不写自己怎么改的，可能拿不到全分。**
- **免修需要主动联系**，不是自动生效。

第 32 页 · 本次作业评分标准

Grading of this homework

- the source code can be executed [+10] and can provide correct results [+20]
  the source code has high readability [+10]
- there is a detailed note file to explain (1) basic principle [+10], (2) source code [+10], and (3) results [+10]
  the note file is well-written and easy to understand [+10]
- your log with AI [+20]
- did not use $U(1) \times U(1)$ block decomposition [-20]
- did not use Lanczos algorithm combined with continued fractions for the spectral function [-20]
- absence of analytical benchmark verification at $U = 0$ [-20]
- time-dependent score: today: [+5], after DDL: [-1 per day]
- self-motivation score: new ideas or extra results [+10]

图 32: 幻灯片第 32 页

这一页写了什么

- 源代码**可以执行** [+10]，并且能给出**正确结果** [+20]；源代码有**高可读性** [+10]。
- 有一个**详细的说明文档**来解释 (1) 基本原理 [+10]、(2) 源代码 [+10]、以及 (3) 结果 [+10]；说明文档**写得好、容易理解** [+10]。
- 你的**与 AI 的对话记录** [+20]。
- **没有使用** $U(1) \times U(1)$ **块分解** [−20]。
- **没有使用 Lanczos 算法结合连分数计算谱函数** [−20]。
- **缺少** $U = 0$ **处的解析基准验证** [−20]。
- 时间相关分数：今天 [+5]，过了 DDL 后每天 [−1]。
- 自驱分：新想法或额外结果 [+10]。

要点展开

(1) 评分表的结构：100 分基础 + 加减分。

基础分（100 分）：

项目	分值
源代码可执行	+10

项目	分值
源代码结果正确	+20
源代码可读性	+10
说明文档：基本原理	+10
说明文档：源代码解释	+10
说明文档：结果分析	+10
说明文档写得清楚	+10
AI 对话记录	+20

三项”一票否决”式的扣分（各 −20）：

扣分项	对应的本讲内容
未用 $U(1)\times U(1)$ 块分解	**第二讲第 16–20 页**（对称性与基矢查找）
谱函数未用 Lanczos + 连分数	**本讲第 23–24 页**（核心方法）
缺少 $U=0$ 解析基准验证	**本讲第 25 页**（$U=0$ 的解析结果）

（2）三项扣分的逻辑：它们分别对应”三个必须掌握的技能”。

- $U(1)$ **块分解**：不分解的话，希尔伯特空间是 4^N。$N=8$ 时是 65536，还勉强能算；但**这是”没学会第二讲”的信号**。块分解后是 4900（$(4,4)$ 块），**小 13 倍**。> 分块的技术细节：利用 $[\hat{H},\hat{N}_\uparrow]=[\hat{H},\hat{N}_\downarrow]=0$，> 把矩阵按 $(N_\uparrow,N_\downarrow)$ 分块。> **注意是 $U(1)\times U(1)$（两个独立的粒子数守恒），> 不是单个 $U(1)$**——因为自旋 ↑ 和 ↓ 的粒子数分别守恒。

- **Lanczos + 连分数**：这是**本讲的核心方法**。不用它就意味着**用稠密对角化硬求和**——对 $N=8$ 可能还能做，但对 $N=12$（维度 853776）就**不可能**了。**这条扣分是在检查你” 是否真的学会了本讲”。** > 具体地说：不能用”把 H 完全对角化、然后按 Lehmann 表示 > $\sum_n|\langle\Phi_n|c^\dagger|\Phi_0\rangle|^2\delta(\omega-(E_n-E_0))$ > 求和”的方式算谱函数。**必须**用第 23 页的”从 $A|\Phi_0\rangle$ 出发做 > Lanczos、再用第 24 页的连分数”。

- $U=0$ **解析基准**：这是**唯一的” 独立校检”**。因为 $U=0$ 时模型是自由费米子，谱函数有**解析解**（第 25 页）：

$$\rho(\omega)=2\sum_k\frac{1}{\pi}\frac{\eta}{(\omega-\varepsilon_k)^2+\eta^2},\qquad \varepsilon_k=-2t\cos(2\pi k/N).$$

  这条校检同时锁定四件事（第 25 页）：跳跃幅度 t、边界条件（环 vs 链）、展宽 η、权重归一化。> **为什么这条校检不可替代**：其它校检（厄米性、$\|HV^\top-V^\top T\|$、> 求和规则）都**无法**同时抓住这四类错误。> 例如求和规则对”边界条件搞错”完全无感 > （开链和环的总权重都是 N）。> **只有 $U=0$ 的逐点对照能抓住它。**

（3）为什么 AI 记录给 +20 分这么高。

这与本课程的教学理念有关：**AI 是工具，关键是你会不会用、能不能判断。** 20 分的要求是：

- **逐条记录 prompt 原文**（你问了什么）；
- **AI 返回的要点**（它说了什么）；
- **你改了什么、为什么**（你的判断）。

注意”你改了什么”这一项：这说明课程**不鼓励**直接复制 AI 的代码。AI 的答案经常有**微妙的错误**——本讲至少有三处典型的：连分数的**递归方向**（第 24 页）、α^2 **忘记乘回**（第 23 页）、减法谱的**符号**（第 22 页）。**这些错误 AI 都可能犯，而你的校检应该能抓住它们。 这就是”AI 记录”分的真正含义：展示你抓住了什么。**

(4)“自驱分”(self-motivation score)。

+10 分，给”**新想法或额外结果**”。可能的来源：

- 算额外的东西（例如不同 U、不同 N、不同填充）；
- 用不同的方法交叉验证（例如自己实现一个 Chebyshev 方法对照，第 29 页）；
- 分析一个幻灯片上没讲的物理量（例如自旋关联、动量分布）；
- 优化性能（例如利用稀疏性、分块、或用更好的起始矢量）。

建议：自驱分要**明确写出来**”我额外做了什么”，否则评阅者可能注意不到。

(5)“今天 +5、之后每天 −1”的设计。

这是一个**线性衰减**的时间分。假设你在 DDL 后 d 天提交，净时间分是 $5-1-d=4-d$。**所以迟交 4 天以上，时间分就变成负的了。**

提示 / 易错

- **三项 −20 是本讲的”红线”。**它们的共同点是：**都在检查”你是否真的用了本讲教的方法”。**即使结果正确，用了错误的方法也要扣分——**这体现了”过程与结果同等重要”的评分理念。**
- “$U(1)\times U(1)$”**是两个** $U(1)$：自旋向上和向下的粒子数分别守恒。只用一个 $U(1)$（总粒子数守恒）**不符合要求**——因为那样矩阵维度还是很大。
- **注意”可执行”(+10) 与”结果正确”(+20) 是分开算的。**代码能跑但结果是错的，只能拿 +10。**所以一定要做校检**——这也是为什么 $U=0$ 基准单独列一条扣分。
- **本讲义第 25 页的** $U=0$ **解析式要注意边界条件**：环上是 $\varepsilon_k=-2t\cos(2\pi k/N)$；如果是**开链**，能级是**超越方程的解**（不是简单的余弦）。**用错边界条件会让这条校检失败**——这正是它的价值。—

附录

附录 A ·中英术语对照

中文	English	幻灯片页
迭代对角化	iterative diagonalization	3
完全对角化	complete (full) diagonalization	3
Jacobi–Davidson 算法	Jacobi–Davidson algorithm	3
重启 Arnoldi 方法	restarted Arnoldi method	3
变分原理	variational principle	4、5
波函数泛函	wave-function functional	4
最陡上升	steepest ascent	4
残差 / 梯度	residual / gradient	4
Rayleigh 商	Rayleigh quotient	5、9

中文	English	幻灯片页
Rayleigh–Ritz 变分	Rayleigh–Ritz variational	5、7
幂法	power method	6
极端本征值	extremal eigenvalue	6、7
Krylov 空间	Krylov space	7、23、26
三项递推	three-term recurrence	9、10、11
Lanczos 系数	Lanczos coefficients (a_m, b_m)	9、11
三对角矩阵	tridiagonal matrix	8、11、23
正交基	orthogonal basis	10、11
厄米共轭	Hermitian conjugate	10、11
matrix-free（矩阵实时重算）	matrix-free / on the fly	11
收敛性	convergence	12、16
正交性丢失	loss of orthogonality	13
鬼本征值	ghost eigenvalue	13
简并度错误	erroneous multiplicity	13
修正 Gram–Schmidt	modified Gram–Schmidt	14
重正交化	reorthogonalization	14、16
内存效率	memory efficiency	14
修正 Lanczos 方法	modified Lanczos method	15
隐式重启 Lanczos	implicitly restarted Lanczos	15
重启	restart	15
格林函数	Green's function	17–19
传播子	propagator	18
Heaviside 阶跃函数	Heaviside step function $\theta(x)$	19
时间序算符	time-ordering operator $T[\cdots]$	19
因果格林函数	causal Green's function	19
推迟格林函数	retarded Green's function	19
超前格林函数	advanced Green's function	19
小于 / 大于格林函数	lesser / greater Green's function	19
反对易子	anticommutator	19
关联函数	correlation function	19、20
动力学性质	dynamical properties	20
含时关联函数	time-dependent correlation function	20
傅里叶变换	Fourier transform	20
局域态密度	local density of states (LDOS)	21、22
态密度	density of states (DOS)	22、25、26
谱函数	spectral function	22、28
完备性关系	completeness relation	21、23
Lehmann 表示	Lehmann representation	21
主值	principal value $\mathcal{P}$	21
Sokhotski–Plemelj 公式	Sokhotski–Plemelj formula	21
求和规则	sum rule	21、22
分辨算符	resolvent / resolvent operator	20、23

中文	English	幻灯片页
展宽	broadening (η)	20–26
分块矩阵求逆	block matrix inversion	24
Schur 补	Schur complement	24
连分数	continued fraction	24
矩	moment	24、26
光电子发射	photoemission (ARPES)	22、26、28
逆光电子发射	inverse photoemission (IPES)	22、26
中子散射	neutron scattering	22
结构因子	structure factor $S_{zz}(\mathbf{q},\omega)$	22
光电导	optical conductivity $\sigma_{xx}(\omega)$	22
拉曼散射	Raman scattering	22
四自旋关联	4-spin correlation	22
Mott 绝缘体	Mott insulator	25、27、30
金属–绝缘体转变	metal–insulator transition	25
原子极限	atomic limit	25
粒子–空穴对称性	particle–hole symmetry	25
自旋–电荷分离	spin-charge separation	27、28
自旋子	spinon	27、28
空穴子	holon	27、28
反铁磁序	antiferromagnetic (AF) ordering	27
准一维导体	quasi-1D conductor	28
能带色散	band dispersion	28
Chebyshev 多项式	Chebyshev polynomial	29
矩阵乘积态	matrix product state (MPS)	29
赝 site	pseudosite	29
电子–声子耦合	electron-phonon coupling	29
Holstein 模型	Holstein model	29
极化子	polaron	29
声子边带	phonon sideband	29
条纹相	stripe phase	30
电荷密度调制	charge density modulation	30
扫描隧道谱	scanning tunneling spectroscopy (STS)	30
原子轨道线性组合	LCAO	30

附录 B · 常见错误清单（写 Lanczos + 谱函数代码前先读一遍）

按"从基础到高阶"排列。**前六条是本讲最容易失分的**。

B1 · 三项递推漏项

```
# 错：漏掉 b_{m-1}|φ_{m-1}⟩
w = matvec(v); am = v @ w; w -= am * v
```

症状：残余 $\|HV^\top - V^\top T\|_\infty$ 跳到 $\mathcal{O}(1)$（而不是 10^{-15}）。但**谱形可能看起来仍然"差不多"**，所以必须显式校检。

正确：`w -= am * v + b_prev * v_prev`

B2 · 连分数正向递归（最隐蔽的 bug）

```
# 错：从浅层迭代到深层
g = 0
for m in range(len(a)):
    g = 1/(z - a[m] - b[m]**2 * g)
```

症状：算出的不是正确的 $[(z-H)^{-1}]_{00}$。它等价于**把系数顺序反过来**（$a_M, \dots, a_0$ 配 $b_M, \dots, b_1$）后同一个连分数的值——也就是**另一个三对角矩阵**的 00 元，**极点位置系统性漂移，谱形完全错误**（实测最大漂移 0.567）。

会不会报错取决于 b 的长度：若 `len(b) == len(a)-1`，循环会在 `m = len(a)-1` 处抛 `IndexError`（错误立刻暴露）；若 b 与 a 等长，则**静默**给出错误结果——**后者才危险**。

正确：从最深层往回，且**最深层要用上 a_M**

```
M = len(a) - 1
g = 1.0/(z - a[M])                  # 不是 g = 0!
for m in range(M-1, -1, -1):
    g = 1.0/(z - a[m] - b[m]**2 * g)
```

> **另一个常见写法**：`g = 0`，循环 `for m in range(M, -1, -1)`（**含** $m = M$），并约定 $b_M = 0$，最深层会自动退化成 $1/(z - a_M)$，与上面等价。**但若写成 `range(M-1, -1, -1)` 配 `g = 0`，就丢掉了 a_M 那一层**，偏差达 $O(1)$（实测 3.5×10^{-1}）——这是第二个、独立的 off-by-one 陷阱。

B3 · 忘记乘回 α^2

$$|\Psi_0\rangle = A|\Phi_0\rangle, \quad |\phi_0\rangle = |\Psi_0\rangle/\alpha, \quad \langle\Psi_0|\tfrac{1}{z-H}|\Psi_0\rangle = \alpha^2\langle\phi_0|\tfrac{1}{z-H}|\phi_0\rangle$$

症状：**谱形完全正确，整条曲线只差一个常数因子。**这是最阴险的一类 bug——图看起来"很像"，只有幅度错。**求和规则（$\int \rho\, d\omega = 1 - \langle n\rangle$）是抓它的唯一办法。**

B4 · 自旋目标块搞错

往基态加一个**向下**电子，目标块是 $(N_\uparrow, N_\downarrow + 1)$，**不是** $(N_\uparrow + 1, N_\downarrow)$。

症状：两块维度常常相同（例如都是 70×56），所以**不越界、不报错**，很多校检还照样通过。

正确：把目标块**显式作为参数**传给算符函数，使"加 ↑"与"加 ↓"在代码里成为**两个不同的调用**。

B5 · 减法谱的符号

减法（光电子）谱的极点是 $E_0(N) - E_m(N-1)$。若把 z 的符号搞错，谱会**左右镜像反转**。

症状：**总权重仍然守恒**（所以求和规则抓不到），必须用 $U = 0$ 的解析基准来抓。

B6 · 费米子符号

$$\hat{c}^{\dagger}_{j,\sigma}|m\rangle = (-1)^{\mathrm{popcount}(m \;\&\; (2^j-1))}|m + 2^j\rangle$$

症状：符号错会让矩阵**不再厄米**，或让 $U = 0$ 的能级结构错乱。**厄米性校检能抓住一部分**。

B7 · 只用"一格点 $\times N$"

只有当所有格点等价时才可以（基态是平移本征态）。非简并基态必然如此；**简并基态则不一定**。

判据：$|\langle\Phi|\hat{T}|\Phi\rangle|$。- $U = 4$ 环（非简并）：1.000000000000 → 安全；- $U = 0$ 环（简并）：0.877545257844 → **不安全**。

症状：$U = 0$ 时 $w_{\mathrm{add}}/w_{\mathrm{rem}}$ 变成 8.0373/7.9627 （应各为 8）。**注意总和仍然守恒**（16.0000），所以必须**分开**检查加、减两支。

B8 · 用"能量收敛"判断"谱也收敛"

Ritz 值是**变分量**，收敛快；谱形需要**所有极点**（含权重很小的）都正确，收敛慢得多。

实测（$N = 8$、$U = 4$）：40 步到 10^{-7}、60 步到机器精度；但 $z = 5 + 0.11i$ 处的连分数到 400 步才到 10^{-8}。

结论：**收敛判据要针对你真正要的量。**

B9 · 残余校检取错列数

$$\|HV^{\top} - V^{\top}T\|_{\infty} \text{ 只对前} n \text{ 列成立}$$

（最后一列需要尚未构造的 $|\phi_n\rangle$）。

症状：对全部列检查会得到 $\mathcal{O}(1)$ 的"残差"，**看起来像实现错误，其实是检验本身写错了**。

正确：`resid = abs((H @ V.T - V.T @ T)[:, :len(a)-1]).max()`

B10 · 从严格本征态出发做谱函数

若 $|\Psi_0\rangle$ 恰好是 H 的本征态，则 $b_0 = 0$，递推**一步就停**。

这不是 bug，但要意识到：**谱函数必须从 $A|\Phi_0\rangle$ 出发**（它一般不是本征态）。参考实现里专门保留了这个演示作为对照。

B11 · 忽略正交性丢失

200 步朴素递推的 $\|VV^\top - I\|_\infty = 3.674 \times 10^{-1}$（**不是**机器精度）。

后果取决于你要什么：- 数简并度、要干净能谱 → **必须重正交化**；- 只要一条 $A(\omega)$ → 朴素递推通常够用（鬼被权重求和平均掉）。

B12 · η 取值/网格不当

- η 太小 → 峰太尖，网格采不到，且有限步 Lanczos 不够；
- η 太大 → 峰被抹平，能隙等结构消失；
- 网格太粗 → **峰高被低估**（$\eta = 0.11$ 时：1201 点给 11.846，16001 点给 11.865）。

建议：$\eta \sim 0.1t$；并检查"η 减半后谱形是否稳定"（除峰宽外）。

附录 C · 从本讲出发的下一步

C1 · 想深入 Lanczos 本身

- **C. Lanczos**, *J. Res. Nat'l Bur. Std.* **45**, 255 (1950)——原始文献（第 8 页）。
- **C. C. Paige**, *The Computation of Eigenvalues and Eigenvectors of Very Large Sparse Matrices*, PhD thesis, London University (1971)——正交性丢失的**严格理论**（第 13 页问题的答案）。
- **G. H. Golub & C. F. Van Loan**, *Matrix Computations*——标准的数值线性代数教科书。
- **ARPACK / `scipy.sparse.linalg.eigsh` 文档**——第 3 页 `eigs` 参数的完整说明。

C2 · 想看 ED + Lanczos 在物理里的系统应用

- **E. Dagotto**, *Rev. Mod. Phys.* **66**, 763 (1994)——第 24 页引用的经典综述。**本讲第 21–28 页的内容基本都在这篇里。**
- **H. Benthien et al**, *PRL* **92**, 256401 (2004)——QMC 计算一维 Hubbard 的 $A(k,\omega)$（第 28 页）。
- **D. Bozi et al**, *J. Phys.: Condens. Matter* **20**, 022205 (2008)——用 ED + Lanczos 计算 $A(k,\omega)$（第 28 页）。
- **PRB / PRL 上关于 TTF-TCNQ 的 ARPES 工作**——自旋-电荷分离的实验证据（第 28 页）。

C3 · 想了解本讲方法的现代发展

- **A. Weiße et al**, *Rev. Mod. Phys.* **78**, 275 (2006)——**Chebyshev 方法**（第 29 页）的综述，讲有限温度与谱函数。
- **U. Schollwöck**, *Ann. Phys.* **326**, 96 (2011)——**MPS/DMRG**（第 29 页）的权威综述。
- **Pei-Yuan Zhao, Ke Ding, and Shuo Yang**, *Phys. Rev. Res.* **5**, 023026 (2023)——第 29 页的 Chebyshev pseudosite MPS 工作。
- **Ning Xia, Yuchen Guo, and Shuo Yang**, *PRL* **135**, 116504 (2025)——第 30 页的条纹电荷调制工作。
- **A. Georges et al**, *Rev. Mod. Phys.* **68**, 13 (1996)——动力学平均场理论（DMFT），是"用 ED/Lanczos 当杂质求解器"的重要应用。

C4 · 与本课程其它讲的连接

本讲内容	相关讲次
基矢、比特运算、稀疏矩阵	**第二讲**（第 8–15 页）
对称性、$U(1)$ 分块、基矢查找	**第二讲**（第 16–20 页）
费米子系统、Hubbard 模型、符号	**第二讲**（第 21–22 页）
有限温度、磁化	**第二讲**（第 23–24 页）
实时演化、Lanczos 加速	**第二讲**（第 28–31 页）
张量网络（DMRG）、QMC	后续讲次
动量空间精确对角化	后续讲次

C5 · 一句话总结本讲

把巨大的哈密顿量投影到一个小小的 Krylov 空间上，在投影空间里它变成三对角矩阵；于是"求谱"变成"算一个连分数"。

本讲的所有技术细节，都是在让这句话**在有限精度下真的成立**：三项递推（第 9–11 页）让它成立；正交性丢失（第 13–16 页）让它不成立；α^2 与反向递归（第 23–24 页）让你别把它算错；$U = 0$ 基准（第 25 页）让你知道它到底成不成立。

结语

第三讲是"第一章的下半场"，它把第二讲造好的矩阵**真正用起来**了。结构可以概括成三条线索：

1. **数学线（第 4–11 页）**：变分原理 → Krylov 空间 → Lanczos 三项递推 → 三对角矩阵。这条线是**严格**的数学，与浮点数无关。
2. **数值线（第 12–16 页）**：收敛性 → 正交性丢失 → 重正交化 → 重启。这条线讲的是**同一套数学在浮点算术下会怎样坏**，以及怎么补救。

3. **物理线（第 17–30 页）**：格林函数 → 谱函数 → 连分数 → Mott 绝缘体 → 自旋-电荷分离 → ARPES 实验 → 研究前沿。

三条线在第 23–24 页汇合：那里数学（三对角化）给出了物理（谱函数）所需要的全部信息，而数值（连分数、α^2）决定了它是否可靠。

如果只带走三句话：

1. **Lanczos 的本质是”只存两个矢量，得到整个 Krylov 空间的信息”。**它的效率来自三项递推（第 9–11 页），它的麻烦来自正交性丢失（第 13 页）。
2. **谱函数 = 格林函数的虚部 = 连分数，而连分数必须反向递归。**这一条链上的每一环（α^2、z 的符号、递归方向、b_m^2）都是一个独立的出错机会。
3. **算出数来只完成了一半，验证才算完成。**而本讲最有力的校检只有一条：$U = 0$ **的解析基准**。它同时锁定跳跃幅度、边界条件、展宽、归一化四件事——没有任何其它校检能做到这一点。

作业里那三项各 -20 的扣分，其实就是在检查这三句话。

祝你算得开心。